

Report Netflix

Delicato Fabrizio, Esposito Angelo, Miele Aniello, Palma Felice

Indice

Introduzione	3
Quadro teorico e metodologia	3
Preparazione e pulizia del dataset	4
Analisi delle reti collaborative attore-attore	5
Analisi delle reti collaborative attori-registi	17
Analisi della rete attore-genere	28
Analisi della rete regista-genere	35
Dall'analisi delle reti all'analisi testuale: text mining sui titoli e sulle trame del catalogo Netflix	44
Analisi dei topic	55
Analisi della similarità semantica tra film e la relazione con la popolarità	65
Sentiment Analysis	78
Conclusioni	89

Introduzione

Negli ultimi anni le piattaforme di streaming hanno trasformato profondamente il settore audiovisivo, modificando sia le modalità di distribuzione dei contenuti sia le preferenze del pubblico. In questo contesto Netflix rappresenta uno dei principali attori globali, caratterizzato da una continua espansione del catalogo e da una crescente diversificazione dei contenuti prodotti e distribuiti. L'evoluzione della piattaforma offre quindi un contesto particolarmente adatto per applicare strumenti di Network Science e Text Mining al fine di analizzare le dinamiche strutturali e semantiche dei contenuti audiovisivi.

L'obiettivo del report consiste nell'analizzare l'evoluzione del catalogo Netflix attraverso tre differenti finestre temporali: 2010-2015, 2016-2020 e 2021-2025. L'analisi combina approcci di analisi delle reti e tecniche di elaborazione del linguaggio naturale per studiare sia le collaborazioni tra attori sia le caratteristiche testuali delle trame e dei titoli dei film presenti nel dataset.

Dal punto di vista della Network Science, il report si concentra sulla costruzione di reti collaborative attore-attore e di reti semantiche basate sulle similarità tra film. Attraverso indicatori strutturali quali degree, betweenness, closeness, PageRank ed eigenvector centrality, viene studiata l'importanza relativa dei nodi e l'organizzazione delle reti nei diversi periodi temporali. Vengono inoltre analizzati fenomeni di clustering e community detection mediante algoritmi Louvain e Leiden, con l'obiettivo di individuare gruppi coesi di contenuti o attori.

Dal punto di vista del Text Mining, il lavoro utilizza tecniche di tokenizzazione, rimozione delle stopwords, analisi TF-IDF, topic modeling tramite Latent Dirichlet Allocation e sentiment analysis. Tali strumenti consentono di individuare le parole maggiormente rappresentative dei diversi periodi storici, i temi dominanti all'interno delle trame e l'evoluzione del linguaggio utilizzato nei contenuti audiovisivi.

L'integrazione tra analisi strutturale delle reti e analisi semantica dei testi permette di osservare simultaneamente sia l'evoluzione delle collaborazioni cinematografiche sia la trasformazione delle narrazioni e delle tematiche presenti nel catalogo Netflix nel corso del tempo.

Quadro teorico e metodologia

La Network Science rappresenta un insieme di metodologie volte allo studio di sistemi complessi attraverso la modellizzazione in forma di rete. Una rete è composta da nodi e archi, dove i nodi rappresentano entità del sistema e gli archi rappresentano relazioni tra tali entità. Nel presente report i nodi possono rappresentare attori o film, mentre gli archi descrivono collaborazioni o similarità semantiche.

L'analisi delle reti collaborative attore-attore si basa sull'ipotesi che due attori siano collegati se compaiono nello stesso film. Tale approccio consente di studiare la struttura relazionale dell'industria cinematografica e di individuare gli attori maggiormente centrali nelle collaborazioni presenti nel catalogo Netflix.

Per descrivere quantitativamente le reti vengono utilizzati diversi indicatori strutturali. Il degree misura il numero di connessioni dirette di un nodo; la betweenness centrality quantifica il ruolo di intermediazione di un nodo nei cammini minimi della rete; la closeness centrality misura la vicinanza media di un nodo rispetto agli altri; l'eigenvector centrality e il PageRank attribuiscono maggiore importanza ai nodi collegati a nodi già centrali. Vengono inoltre calcolati indicatori globali quali densità, diametro, lunghezza media dei cammini e coefficiente di clustering.

Per identificare gruppi coesi all'interno delle reti vengono applicati algoritmi di community detection. In particolare vengono utilizzati Louvain e Leiden, due algoritmi basati sull'ottimizzazione della modularità. La modularità misura il grado con cui una rete risulta suddivisa in comunità densamente connesse internamente e scarsamente collegate tra loro.

Dal punto di vista testuale, il presente lavoro applica tecniche di Natural Language Processing alle trame e ai titoli dei film. Dopo una fase preliminare di pulizia del testo, i contenuti vengono tokenizzati e trasformati in unità lessicali analizzabili statisticamente. L'analisi TF-IDF consente di individuare termini distintivi dei diversi generi e periodi temporali, riducendo il peso delle parole troppo frequenti e poco informative.

Per identificare automaticamente le principali tematiche narrative viene utilizzato il topic modeling tramite Latent Dirichlet Allocation. Questo modello probabilistico assume che ogni documento sia composto da una combinazione di topic latenti, ciascuno caratterizzato da una distribuzione di parole rappresentative.

Infine viene applicata una sentiment analysis mediante il lessico Bing, classificando le parole in termini positivi e negativi. Tale procedura consente di studiare il tono medio delle trame e la sua evoluzione temporale.

Preparazione e pulizia del dataset

La fase preliminare del lavoro ha riguardato la preparazione e la pulizia del dataset Netflix, operazione fondamentale per garantire coerenza e qualità alle successive analisi statistiche e strutturali. Il dataset originale conteneva informazioni relative ai titoli presenti sulla piattaforma, tra cui cast, registi, generi, descrizioni testuali, date di inserimento e misure di popolarità.

In una prima fase sono state selezionate le variabili considerate maggiormente rilevanti per gli obiettivi dell'analisi. Successivamente il dataset è stato suddiviso in tre differenti finestre temporali: 2010-2015, 2016-2020 e 2021-2025. Tale suddivisione consente di confrontare l'evoluzione delle strutture collaborative e delle caratteristiche semantiche nel tempo.

Le informazioni testuali relative a trame e titoli sono state sottoposte a un processo di pulizia mediante conversione in minuscolo, rimozione della punteggiatura, eliminazione dei numeri e delle stopwords. Questa procedura riduce il rumore informativo e consente di focalizzare l'analisi sui termini semanticamente rilevanti.

Successivamente il testo è stato tokenizzato, trasformando ciascuna trama in un insieme di parole individuali o bigrammi. In alcune analisi sono state inoltre rimosse manualmente parole troppo generiche o poco informative, come “film”, “story”, “life” o “world”, che tendevano a comparire frequentemente in tutti i periodi senza contribuire alla distinzione semantica dei contenuti.

Per le reti collaborative attore-attore è stato necessario separare e normalizzare i nomi presenti nella variabile cast, creando successivamente una lista di coppie di attori appartenenti allo stesso film. Questa struttura è stata poi convertita in un grafo tramite il pacchetto `igraph`.

Per la costruzione delle reti semantiche, invece, sono stati utilizzati vettori TF-IDF delle trame, successivamente confrontati mediante cosine similarity al fine di misurare il grado di similarità tra i contenuti audiovisivi presenti nel catalogo Netflix.

Analisi delle reti collaborative attore-attore

Table 1: Top 10 attori per centralità nella rete attore-attore, periodo 2010-2015

nodo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Danny Trejo	71	656449.0	0	1568.929	0.404	0.001
Ray Liotta	64	466007.0	0	1628.493	0.874	0.001
Channing Tatum	58	169521.0	0	1537.121	0.907	0.001
Grey DeLisle	54	274557.4	0	1414.626	0.145	0.001
Bradley Cooper	53	155391.0	0	1545.116	0.901	0.001
Robert De Niro	53	217120.3	0	1571.274	0.877	0.001
Viola Davis	52	176721.0	0	1554.940	0.875	0.001
Cameron Diaz	50	110047.7	0	1498.430	0.814	0.001
James Franco	50	116566.1	0	1461.615	0.594	0.001
Steve Carell	49	134338.1	0	1541.849	1.000	0.001

Table 2: Indicatori globali della rete attore-attore, periodo 2010-2015

rete	nodi	archi	density	diameter	avg_path_length	clustering
attore-attore	6128	21239	0.001	14	5.004	0.793

Nel periodo 2010–2015 la rete attore-attore evidenzia una struttura molto ampia e complessa, caratterizzata dalla presenza di alcuni attori particolarmente centrali all’interno del network. In termini di degree centrality, Danny Trejo risulta il nodo con il maggior numero di connessioni dirette, seguito da Ray Liotta e Channing Tatum. Questo significa che tali attori hanno condiviso film con un numero molto elevato di colleghi, assumendo quindi una posizione molto visibile all’interno della rete cinematografica.

Anche la betweenness centrality conferma il ruolo strategico di alcuni nodi. Danny Trejo presenta infatti il valore più alto, suggerendo che molte delle connessioni più brevi tra gruppi differenti di attori passano attraverso di lui. In altre parole, l’attore svolge una funzione di collegamento tra diverse aree della rete, contribuendo alla coesione complessiva della struttura. Valori elevati si osservano anche per Ray Liotta, Grey DeLisle e Robert De Niro, segnalando la loro importanza nei percorsi che collegano comunità differenti di attori.

L’eigenvector centrality permette invece di valutare non solo il numero di collegamenti posseduti da un nodo, ma anche l’importanza dei nodi con cui esso è connesso. Attori come Channing Tatum, Bradley Cooper, Robert De Niro, Viola Davis e Steve Carell mostrano valori particolarmente elevati, indicando una forte integrazione all’interno della parte più influente della rete. Steve Carell raggiunge addirittura il valore massimo normalizzato pari a 1, evidenziando una posizione molto rilevante nel nucleo centrale del network.

La closeness centrality risulta pari a zero per tutti i nodi riportati nella tabella. Questo comportamento è probabilmente legato alla struttura molto estesa e non completamente connessa della rete, nella quale non tutti gli attori risultano reciprocamente raggiungibili. Per questo motivo, si ricorre all’harmonic centrality, cioè una variante della closeness, particolarmente utile quando si è in presenza di reti grandi o non particolarmente connesse. A differenza della closeness centrality, che risulta nulla per tutti i nodi a causa della struttura non completamente connessa della rete, la harmonic centrality permette di ottenere una misura più informativa della vicinanza dei nodi agli altri attori del network. I valori più elevati si osservano per Ray Liotta, Robert De Niro e Danny Trejo, indicando che questi attori risultano mediamente raggiungibili attraverso percorsi relativamente brevi rispetto agli altri nodi della rete. Questo suggerisce una posizione centrale non solo in termini di numero di collaborazioni, ma anche rispetto alla capacità di raggiungere rapidamente diverse aree della struttura.

Infine, il PageRank assume valori molto simili tra i diversi nodi principali, suggerendo una distribuzione relativamente uniforme dell'importanza globale all'interno della componente centrale della rete.

Considerando invece gli indicatori globali, la rete attore-attore del periodo 2010–2015 risulta composta da 6128 nodi e 21239 archi. Si tratta quindi di una rete molto grande, nella quale ogni nodo rappresenta un attore e ogni arco indica la presenza di almeno una collaborazione cinematografica tra due attori.

La density pari a 0.001 evidenzia una rete estremamente sparsa. Nonostante il numero elevato di nodi, infatti, solo una minima parte delle connessioni teoricamente possibili è realmente presente. Questo comportamento è tipico delle reti sociali reali, dove ogni individuo tende a collaborare solo con una piccola porzione dell'intera popolazione.

Il diameter della rete è pari a 14, indicando che la distanza massima osservata tra due nodi è di quattordici passaggi. Tuttavia, l'average path length pari a circa 5 mostra che, mediamente, due attori qualsiasi possono essere collegati attraverso un numero relativamente ridotto di intermediari. Tale risultato richiama le proprietà tipiche dei cosiddetti small-world network, nei quali anche reti molto grandi mantengono distanze medie contenute tra i nodi.

Infine, il clustering coefficient pari a 0.793 risulta particolarmente elevato e segnala una forte tendenza alla formazione di gruppi locali densamente connessi. In pratica, se due attori hanno collaborato con uno stesso attore, esiste un'alta probabilità che abbiano collaborato anche tra loro. Questo fenomeno suggerisce la presenza di comunità ben definite all'interno della rete cinematografica, probabilmente associate a specifici generi, produzioni o gruppi ricorrenti di collaborazione.

Table 3: Top 10 attori per centralità nella rete attore-attore, periodo 2016-2020

nodo	degree	betweenness	closeness	harmomic	eigenvector	pagerank
Zoey Deutch	48	316929.28	0	1221.061	0.172	0.001
Nicolas Cage	45	368925.91	0	1142.813	0.021	0.001
James Franco	41	277030.13	0	1144.961	0.037	0.001
Thomas Jane	41	323318.68	0	1130.660	0.031	0.001
Woody Harrelson	40	170960.63	0	1162.699	0.047	0.001
Samuel L. Jackson	38	200905.46	0	1172.843	0.043	0.001
Elle Fanning	36	103232.25	0	1131.853	0.048	0.001
Keegan-Michael Key	36	258095.95	0	1139.285	0.018	0.001
Jon Hamm	36	84265.18	0	1129.723	0.022	0.001
Bella Thorne	36	192056.79	0	1059.424	0.020	0.001

Table 4: Indicatori globali della rete attore-attore, periodo 2016-2020

rete	nodi	archi	density	diameter	avg_path_length	clustering
attore-attore	5238	16085	0.001	15	5.446	0.821

Nel periodo 2016–2020 la rete attore-attore mantiene una struttura molto ampia e articolata, pur mostrando alcune differenze rispetto al periodo precedente. Gli attori con il degree più elevato risultano Zoey Deutch, Nicolas Cage e James Franco, indicando che questi nodi hanno collaborato con un numero particolarmente elevato di altri attori all'interno del network cinematografico. In particolare, Zoey Deutch rappresenta il nodo con il maggior numero di connessioni dirette, mentre Nicolas Cage continua a occupare una posizione centrale nella rete grazie all'elevata numerosità delle collaborazioni.

L'analisi della betweenness centrality evidenzia nuovamente la presenza di attori che svolgono un ruolo strategico di collegamento tra differenti aree della rete. Nicolas Cage presenta il valore più elevato, seguito

da Thomas Jane e Zoey Deutch. Questo suggerisce che tali attori fungano da ponte tra gruppi differenti di collaborazioni cinematografiche, contribuendo alla connettività complessiva della struttura. Anche Samuel L. Jackson e Keegan-Michael Key mostrano valori relativamente elevati, segnalando una buona capacità di intermediazione tra comunità differenti.

L'eigenvector centrality assume invece valori generalmente più bassi rispetto al periodo 2010–2015. Zoey Deutch presenta comunque il valore più elevato tra i nodi riportati, suggerendo una connessione con attori a loro volta importanti all'interno della rete. Nel complesso, però, la distribuzione di questa misura appare meno concentrata, indicando probabilmente una struttura più distribuita e meno dominata da pochi nodi altamente influenti.

Anche in questo caso la closeness centrality risulta pari a zero per tutti i nodi osservati, fenomeno coerente con la presenza di componenti disconnesse o con la forte frammentazione della rete. La harmonic centrality evidenzia differenze interessanti tra i nodi principali della rete. Zoey Deutch presenta il valore più elevato, suggerendo una posizione particolarmente favorevole rispetto alla distanza media dagli altri attori raggiungibili del network. Valori elevati si osservano anche per Samuel L. Jackson e Woody Harrelson, indicando che questi attori risultano relativamente vicini a molte aree della rete attraverso percorsi brevi. Nicolas Cage e Thomas Jane mostrano invece valori leggermente inferiori nonostante l'elevata betweenness centrality, suggerendo che il loro ruolo sia maggiormente legato alla funzione di collegamento tra comunità differenti piuttosto che alla vicinanza media complessiva agli altri nodi.

Il PageRank rimane invece pressoché identico per tutti i nodi principali, mostrando una limitata capacità discriminante all'interno della componente centrale del network.

Dal punto di vista globale, la rete attore-attore del periodo 2016–2020 risulta composta da 5238 nodi e 16085 archi. Rispetto al periodo precedente si osserva quindi una lieve riduzione sia del numero di attori sia del numero complessivo di collaborazioni. Nonostante ciò, la density rimane pari a 0.001, confermando la natura estremamente sparsa della rete, caratteristica tipica delle grandi reti sociali.

Il diameter aumenta leggermente fino a 15, indicando che la distanza massima osservata tra due nodi è cresciuta rispetto al periodo precedente. Anche l'average path length passa da circa 5.0 a 5.446, suggerendo che mediamente siano necessari più passaggi per collegare due attori qualsiasi della rete. Questo potrebbe indicare una struttura leggermente meno compatta rispetto al periodo 2010–2015.

Infine, il clustering coefficient cresce fino a 0.821, valore ancora più elevato rispetto al periodo precedente. Tale risultato evidenzia una forte tendenza alla formazione di gruppi locali molto coesi, nei quali gli attori collaborano frequentemente all'interno delle stesse comunità. Questo comportamento conferma nuovamente una struttura tipica delle reti sociali reali e suggerisce la presenza di cluster cinematografici ben definiti, probabilmente legati a produzioni ricorrenti, generi specifici o gruppi consolidati di collaborazione.

Table 5: Top 10 attori per centralità nella rete attore-attore, periodo 2021-2025

nodo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Jenna Ortega	45	232930.8	0	952.804	0.215	0.001
Bruce Willis	44	313444.4	0	979.801	0.427	0.001
Awkwafina	44	221636.0	0	999.721	1.000	0.001
Dermot Mulroney	43	212806.2	0	947.837	0.356	0.001
Frank Grillo	38	262757.0	0	960.294	0.364	0.001
Lil Rel Howery	36	189935.3	0	975.688	0.360	0.001
J.K. Simmons	36	228387.2	0	1009.569	0.456	0.001
Sam Worthington	33	158693.8	0	912.087	0.118	0.001
Emile Hirsch	32	109063.8	0	875.396	0.317	0.001
Tyrese Gibson	31	298480.4	0	1002.771	0.289	0.001

Table 6: Indicatori globali della rete attore-attore, periodo 2021-2025

rete	nodi	archi	density	diameter	avg_path_length	clustering
attore-attore	4938	13930	0.001	13	5.622	0.849

Nel periodo 2021–2025 la rete attore-attore continua a mostrare una struttura ampia e fortemente distribuita, pur evidenziando alcune trasformazioni rispetto ai periodi precedenti. Gli attori con il degree più elevato risultano Jenna Ortega, Bruce Willis e Awkwafina, indicando che questi nodi hanno collaborato con un numero particolarmente elevato di altri attori all’interno della rete cinematografica. Jenna Ortega rappresenta il nodo con il maggior numero di connessioni dirette, mentre Bruce Willis mantiene una posizione molto centrale grazie all’elevato numero di collaborazioni accumulate all’interno del network.

L’analisi della betweenness centrality mostra nuovamente la presenza di nodi che svolgono un ruolo strategico di collegamento tra differenti aree della rete. Bruce Willis presenta il valore più elevato, seguito da Tyrese Gibson e Frank Grillo. Questo suggerisce che tali attori fungano da ponte tra gruppi differenti di collaborazioni cinematografiche, contribuendo alla connettività complessiva della struttura. Anche J.K. Simmons e Awkwafina mostrano valori relativamente elevati, evidenziando una buona capacità di intermediazione tra comunità differenti della rete.

La harmonic centrality fornisce invece informazioni relative alla vicinanza media dei nodi rispetto agli altri attori raggiungibili del network. I valori più elevati si osservano per J.K. Simmons, Tyrese Gibson e Awkwafina, suggerendo che questi attori occupino posizioni particolarmente favorevoli dal punto di vista delle distanze geodetiche all’interno della rete. Jenna Ortega presenta invece un valore harmonic leggermente inferiore rispetto ad altri nodi centrali, indicando che il suo elevato numero di collaborazioni non coincide necessariamente con una posizione mediamente più vicina rispetto all’intera struttura del network.

Anche l’eigenvector centrality evidenzia risultati interessanti. Awkwafina raggiunge il valore massimo normalizzato pari a 1.000, indicando una forte connessione con nodi a loro volta molto influenti all’interno della rete. Valori relativamente elevati si osservano anche per J.K. Simmons e Bruce Willis, suggerendo una presenza importante nella parte più centrale e influente del network cinematografico. Come nei periodi precedenti, la closeness centrality risulta pari a zero per tutti i nodi osservati, comportamento coerente con la struttura non completamente connessa della rete, mentre il PageRank rimane pressoché uniforme tra i principali attori analizzati.

Dal punto di vista globale, la rete attore-attore del periodo 2021–2025 risulta composta da 4938 nodi e 13930 archi. Si osserva quindi una progressiva riduzione sia del numero di attori sia del numero complessivo di collaborazioni rispetto ai periodi precedenti. Nonostante ciò, la density rimane pari a 0.001, confermando ancora una volta la natura estremamente sparsa della rete.

Il diameter diminuisce fino a 13, suggerendo una lieve riduzione della distanza massima osservata tra due nodi della rete. Tuttavia, l’average path length aumenta ulteriormente fino a circa 5.622, indicando che mediamente sono necessari più passaggi per collegare due attori qualsiasi della rete rispetto ai periodi precedenti. Questo risultato potrebbe suggerire una struttura meno compatta e maggiormente frammentata.

Infine, il clustering coefficient cresce ulteriormente fino a 0.849, raggiungendo il valore più elevato tra i tre periodi considerati. Tale risultato evidenzia una fortissima tendenza alla formazione di gruppi locali molto coesi, nei quali gli attori collaborano frequentemente all’interno delle stesse comunità. Questo comportamento conferma ancora una volta una struttura tipica delle reti sociali reali e suggerisce la presenza di cluster cinematografici sempre più definiti e consolidati nel tempo.

L’analisi delle misure di centralità e degli indicatori globali consente di comprendere il livello di connessione della rete e di identificare gli attori maggiormente rilevanti dal punto di vista strutturale. Tuttavia, tali indicatori non permettono di individuare direttamente eventuali sottogruppi interni caratterizzati da collaborazioni particolarmente intense. Per approfondire la struttura della rete è quindi utile applicare tecniche di community detection, finalizzate all’identificazione automatica di gruppi di nodi maggiormente connessi tra loro rispetto

al resto della rete. Nel contesto cinematografico, tali comunità possono rappresentare insiemi di attori che collaborano frequentemente all'interno degli stessi film o di produzioni simili. Tramite l'algoritmo di Louvain, basato sull'ottimizzazione della modularità, è possibile perseguire l'obiettivo di verificare se la rete attore-attore presenti una struttura organizzata in comunità collaborative ben definite e confrontare tale organizzazione nei tre differenti periodi temporali analizzati.

Table 7: Modularità Louvain della rete attore-attore nei tre periodi

periodo	algoritmo	modularity
2010-2015	Louvain	0.682
2016-2020	Louvain	0.761
2021-2025	Louvain	0.808

La modularità ottenuta tramite l'algoritmo Louvain risulta relativamente elevata in tutti e tre i periodi analizzati, con valori pari a 0.685 nel periodo 2010-2015, 0.760 nel periodo 2016-2020 e 0.808 nel periodo 2021-2025. Tali risultati indicano la presenza di una struttura collaborativa organizzata in comunità abbastanza ben definite, caratterizzate da connessioni più intense all'interno dei gruppi rispetto al resto della rete.

L'aumento progressivo della modularità suggerisce inoltre che, nei periodi più recenti, la rete attore-attore tenda a presentare comunità maggiormente separate e coese internamente. Questo comportamento può essere interpretato come la presenza di gruppi collaborativi relativamente stabili, riconducibili a specifici cast, franchise cinematografici o reti professionali ricorrenti.

Nel complesso, i valori osservati confermano che la rete non presenta una struttura casuale, ma una chiara organizzazione modulare, elemento che giustifica l'applicazione e il confronto di differenti algoritmi di community detection.

Table 8: Confronto tra algoritmi di community detection nella rete attore-attore

rete	periodo	confronto	VI	NMI	ARI
attore-attore	2010-2015	Louvain-Leiden	4.643	0.637	0.000
attore-attore	2010-2015	Louvain-Walktrap	2.886	0.689	0.250
attore-attore	2010-2015	Louvain-Infomap	2.783	0.734	0.068
attore-attore	2010-2015	Leiden-Walktrap	3.517	0.747	0.000
attore-attore	2010-2015	Leiden-Infomap	2.328	0.846	0.000
attore-attore	2010-2015	Walktrap-Infomap	2.356	0.797	0.021
attore-attore	2016-2020	Louvain-Leiden	4.165	0.679	0.000
attore-attore	2016-2020	Louvain-Walktrap	2.634	0.730	0.102
attore-attore	2016-2020	Louvain-Infomap	2.261	0.788	0.138
attore-attore	2016-2020	Leiden-Walktrap	3.216	0.769	0.000
attore-attore	2016-2020	Leiden-Infomap	2.283	0.846	0.000
attore-attore	2016-2020	Walktrap-Infomap	1.935	0.834	0.040
attore-attore	2021-2025	Louvain-Leiden	3.880	0.704	0.000
attore-attore	2021-2025	Louvain-Walktrap	2.480	0.751	0.073
attore-attore	2021-2025	Louvain-Infomap	2.009	0.816	0.170
attore-attore	2021-2025	Leiden-Walktrap	3.188	0.769	0.000
attore-attore	2021-2025	Leiden-Infomap	2.233	0.849	0.000
attore-attore	2021-2025	Walktrap-Infomap	1.832	0.842	0.045

Il confronto tra gli algoritmi di community detection permette di valutare quanto la suddivisione della rete attore-attore in comunità sia stabile rispetto al metodo utilizzato. In questa fase non interessa solo individuare le comunità con un singolo algoritmo, ma capire se algoritmi diversi restituiscono una lettura

simile della struttura collaborativa. Per questo motivo vengono confrontati Louvain, Leiden, Walktrap e Infomap attraverso tre misure: VI, NMI e ARI.

La Variation of Information misura la distanza tra due partizioni: più il valore è basso, più le due suddivisioni sono simili. La Normalized Mutual Information misura invece il grado di informazione condivisa tra due partizioni: valori più vicini a 1 indicano maggiore somiglianza. L'Adjusted Rand Index valuta la concordanza puntuale nell'assegnazione dei nodi ai gruppi: valori vicini a 1 indicano forte accordo, mentre valori prossimi a 0 indicano che gli algoritmi non assegnano esattamente gli stessi nodi agli stessi cluster.

Nel periodo 2010-2015 emerge una struttura comunitaria abbastanza riconoscibile, ma non perfettamente coincidente tra gli algoritmi. Louvain e Leiden presentano una VI elevata, pari a 4.493, e un NMI pari a 0.653; ciò indica che i due algoritmi riconoscono una struttura comunitaria generale parzialmente simile, ma non producono la stessa partizione. Al contrario, il confronto tra Leiden e Infomap mostra una maggiore vicinanza, con NMI pari a 0.845 e VI pari a 2.339. Anche Walktrap e Infomap risultano abbastanza coerenti tra loro, con NMI pari a 0.795. Questo suggerisce che, pur con differenze nell'assegnazione dei singoli nodi, alcuni blocchi collaborativi della rete vengono riconosciuti in modo ricorrente.

Nel periodo 2016-2020 il quadro diventa leggermente più compatto. I valori di VI tendono a ridursi rispetto al 2010-2015, soprattutto nei confronti che coinvolgono Infomap. Il confronto Louvain-Infomap presenta VI pari a 2.141 e NMI pari a 0.800, mentre Leiden-Infomap conferma una forte somiglianza con NMI pari a 0.845. Anche Walktrap-Infomap mostra un buon livello di accordo, con VI pari a 1.924 e NMI pari a 0.834. Questo indica che, nel secondo quinquennio, la struttura comunitaria appare più leggibile e meno ambigua: algoritmi differenti tendono a individuare gruppi collaborativi più simili.

Nel periodo 2021-2025 questa tendenza si mantiene. Il confronto Walktrap-Infomap presenta il valore di VI più basso, pari a 1.831, e un NMI pari a 0.842, segnalando una forte prossimità tra le due partizioni. Anche Leiden-Infomap mostra un'elevata somiglianza, con NMI pari a 0.850. Louvain, invece, continua a mostrare una distanza maggiore rispetto a Leiden, con VI pari a 3.871, pur mantenendo un NMI superiore a 0.70. Questo significa che Louvain individua una struttura comunitaria coerente a livello generale, ma differente nella suddivisione specifica dei nodi.

I valori di ARI sono quasi sempre bassi. Questo non annulla la validità dell'analisi, ma indica che gli algoritmi non assegnano esattamente gli stessi attori alle stesse comunità. In altre parole, la rete mostra una struttura comunitaria riconoscibile, ma la composizione precisa dei gruppi cambia a seconda dell'algoritmo adottato. Questa evidenza è coerente con una rete attore-attore molto frammentata, formata da numerose componenti e piccoli gruppi collaborativi.

Nel complesso, i risultati indicano che la rete attore-attore presenta una struttura comunitaria stabile nel tempo sul piano generale, ma non perfettamente identica sul piano delle singole assegnazioni. Infomap e Leiden risultano spesso più vicini tra loro, mentre Louvain tende a produrre partizioni leggermente più distanti. La presenza di NMI mediamente elevati conferma comunque che gli algoritmi intercettano una struttura collaborativa reale e non puramente casuale.

Per completare l'analisi strutturale, si procede ora alla visualizzazione grafica della rete attore-attore. I grafi permettono di osservare visivamente la presenza di comunità collaborative, la posizione degli attori più centrali e la frammentazione della rete nei tre periodi considerati.


Struttura complessiva della rete attore–attore

Periodo 2010–2015



La visualizzazione complessiva della rete attore-attore mostra una struttura fortemente concentrata attorno a un nucleo centrale, accompagnata da numerosi nodi periferici e componenti minori. Questo conferma che la rete non è organizzata come un unico blocco uniforme, ma presenta una forte frammentazione collaborativa. I nodi più esterni rappresentano attori scarsamente collegati al resto della rete, mentre l'area centrale raccoglie il gruppo di collaborazioni più dense. Per questo motivo, la rete completa è utile soprattutto per osservare la forma generale e il grado di frammentazione; l'interpretazione dettagliata delle relazioni principali viene invece affidata al sottografo dei nodi con degree più elevato.

Top 30 attori per degree
Periodo 2010–2015



La struttura appare organizzata attorno ad alcuni nodi centrali che fungono da punti di collegamento tra gruppi differenti. Tra questi emergono, ad esempio, Steve Carell, Emma Stone, Viola Davis e Robert De Niro, che presentano numerose connessioni con altri attori della rete e occupano posizioni relativamente centrali nel grafo. La presenza di tali nodi suggerisce il ruolo di attori ponte, capaci di collegare differenti gruppi collaborativi.

Si osservano inoltre piccoli cluster locali abbastanza riconoscibili. Un esempio è il gruppo formato da James Franco, Jonah Hill, Mark Wahlberg e Will Ferrell, caratterizzato da una forte interconnessione interna. Analogamente, il nucleo composto da Cameron Diaz, Elizabeth Banks, Anna Kendrick e Michael Peña mostra una struttura collaborativa relativamente compatta. Questi gruppi riflettono probabilmente collaborazioni ricorrenti all'interno di specifici cast cinematografici o produzioni simili.


Alcuni nodi risultano invece periferici o quasi isolati rispetto alla componente principale. È il caso, ad esempio, di Danny Trejo, Samuel L. Jackson oppure della coppia Grey DeLisle – Neal McDonough, che presentano poche connessioni dirette nel sottografo considerato. Questo comportamento evidenzia come anche attori con elevata degree possano appartenere a sottostrutture collaborative differenti e scarsamente integrate con il nucleo centrale della rete.

Dal punto di vista strutturale, il sottografo non assume una forma completamente compatta, ma presenta una configurazione distribuita, con diversi gruppi collegati tramite pochi nodi intermedi. Tale organizzazione è coerente con i risultati ottenuti nella fase di community detection, dove la rete mostrava una forte modularità e la presenza di comunità collaborative abbastanza ben separate.

Nel complesso, il sottografo evidenzia come la rete attore-attore nel periodo 2010-2015 non sia dominata da un unico gruppo centrale, ma da molteplici cluster collaborativi interconnessi, all'interno dei quali alcuni attori assumono un ruolo strategico nel mantenere la coesione della struttura complessiva.


Struttura complessiva della rete attore–attore

Periodo 2016–2020



Analogamente, anche per il periodo 2016–2020, si osservi il sottografo:

Top 30 attori per degree
Periodo 2016–2020



Il sottografo del periodo 2016–2020 evidenzia una struttura meno compatta rispetto a quella osservata nel periodo precedente. La rete appare infatti più frammentata e composta da piccoli gruppi collaborativi distinti, spesso separati tra loro da pochi collegamenti o completamente isolati. Questo suggerisce che, pur considerando gli attori con degree più elevato, le collaborazioni risultano distribuite in nuclei differenti piuttosto che concentrate attorno a un unico blocco fortemente coeso.

Nel grafo emergono alcuni cluster centrali relativamente connessi. Un primo nucleo coinvolge Keegan-Michael Key, Tiffany Haddish, Kevin Hart e Regina Hall, attori che mostrano numerose connessioni reciproche e occupano una posizione abbastanza centrale nella rete. La presenza di Samuel L. Jackson e Anthony Mackie contribuisce ulteriormente alla connettività di quest'area del grafo, creando un ponte verso altri gruppi collaborativi.

Un secondo sottogruppo è costituito da Woody Harrelson, Zoey Deutch, Logan Miller, Emory Cohen e Michael Shannon. In questo caso le connessioni risultano più lineari e meno dense rispetto al cluster principale, suggerendo collaborazioni più circoscritte o limitate a specifiche produzioni.


Si osservano inoltre diversi nodi isolati o quasi isolati, come Adam Sandler, Grey DeLisle, Bella Thorne, Jon Hamm e Will Smith. La presenza di questi attori nel ranking dei nodi con degree elevato indica che essi possiedono comunque numerose collaborazioni nella rete completa, ma non necessariamente con gli altri attori inclusi nel sottografo dei top 30. Questo aspetto è importante perché mostra come il degree elevato non implichi automaticamente appartenenza allo stesso nucleo collaborativo.

Dal punto di vista strutturale, il sottografo conferma quindi una rete caratterizzata da comunità relativamente separate e da collaborazioni distribuite in gruppi distinti. La densità interna dei cluster principali rimane discreta, ma il livello di integrazione complessiva appare inferiore rispetto a reti altamente centralizzate. L'assenza di un singolo nodo dominante capace di collegare gran parte del sottografo suggerisce una struttura

collaborativa più dispersa e policentrica.


Struttura complessiva della rete attore-attore

Periodo 2021-2025



E quindi il sottografo

Top 30 attori per degree Periodo 2021-2025



mostra una struttura collaborativa più articolata rispetto ai periodi precedenti. Pur rimanendo presenti diversi nodi periferici e alcuni attori isolati, emerge infatti un nucleo centrale più esteso e maggiormente interconnesso, indice di una rete meno frammentata e con collaborazioni distribuite lungo più percorsi relazionali.

La parte centrale del grafo è dominata da un cluster molto denso che coinvolge attori come Frank Grillo, Mel Gibson, Tyrese Gibson, Bruce Willis, Theo Rossi, Michael Jai White e John Malkovich. Questo gruppo presenta numerose connessioni reciproche e costituisce il principale nucleo collaborativo del sottografo. In termini strutturali, questi attori occupano una posizione centrale perché fungono da ponte tra diversi segmenti della rete, contribuendo alla coesione complessiva del sottografo.

Un secondo gruppo rilevante si sviluppa nella parte superiore della rete e coinvolge Ben Affleck, Jason Momoa, Isabela Merced, Kyle Allen, Ryan Reynolds e Lil Rel Howery. Le connessioni risultano meno dense rispetto al cluster centrale, ma il gruppo appare comunque relativamente compatto. Ben Affleck assume qui una funzione importante di collegamento, poiché connette questo nucleo superiore alla parte centrale della rete attraverso J.K. Simmons.

Nella parte destra del grafo emerge invece una struttura più lineare composta da Woody Harrelson, Scarlett Johansson, Bobby Cannavale, Channing Tatum, Judy Greer e Ryan Phillippe. Questo segmento presenta una configurazione quasi “a catena”, suggerendo collaborazioni distribuite lungo percorsi meno densamente interconnessi. Anche in questo caso Judy Greer e Ryan Phillippe svolgono un ruolo di raccordo verso il nucleo centrale.

Si osservano inoltre numerosi nodi isolati o scarsamente collegati, come Jenna Ortega, Dylan O’Brien, Ariana DeBose, Michelle Yeoh, Dennis Quaid e Jonathan Majors. La presenza di tali nodi evidenzia come alcuni attori, pur rientrando tra quelli con maggiore degree nella rete completa, non condividano collaborazioni dirette con gli altri attori inclusi nel sottografo selezionato.

In conclusione, il periodo 2021–2025 sembra quindi caratterizzato da una struttura più policentrica rispetto ai periodi precedenti. Non emerge un unico blocco dominante, ma diversi nuclei collaborativi collegati tra loro tramite pochi attori ponte. Questo suggerisce una rete in cui le collaborazioni cinematografiche risultano distribuite su più comunità relativamente autonome ma comunque parzialmente integrate.

Analisi delle reti collaborative attori-registi

Oltre alla rete attore–attore, l’analisi viene estesa alle reti attore–regista, costruite con l’obiettivo di studiare le collaborazioni tra interpreti e registi all’interno del catalogo Netflix. A differenza delle reti precedenti, questa struttura viene modellata come rete bipartita (two-mode), poiché i nodi appartengono a due insiemi distinti: da un lato gli attori, dall’altro i registi. Gli archi rappresentano quindi collaborazioni dirette tra un attore e un regista all’interno dello stesso film.

Questa rappresentazione consente di osservare la struttura produttiva del catalogo cinematografico da una prospettiva differente rispetto alla semplice collaborazione tra attori. In particolare, la rete permette di individuare registi che lavorano con gruppi ricorrenti di interpreti, attori caratterizzati da collaborazioni distribuite su numerosi registi differenti e nuclei collaborativi relativamente stabili nel tempo.

Table 9: Top 10 nodi per centralità nella rete attore-regista, periodo 2010-2015

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Fred Olen Ray	Attore	43	870548.1	0	1227.054	0.001	0.002
Sean McNamara	Regista	39	1637165.4	0	1458.881	0.001	0.001
Jim Wynorski	Regista	36	483203.1	0	1142.399	0.001	0.002
Tyler Perry	Attore	35	317337.9	0	1231.913	0.000	0.001
Spike Brandt	Regista	35	513587.6	0	1297.639	0.000	0.001
James Franco	Attore	34	273546.5	0	1306.541	0.002	0.001
Tony Cervone	Regista	31	239037.9	0	1243.337	0.000	0.001
Jay Oliva	Regista	31	666988.1	0	1347.689	0.000	0.001
Paul Hoen	Regista	30	235827.6	0	1082.544	0.000	0.001
David Gordon Green	Regista	30	357551.5	0	1344.135	0.001	0.001

A differenza della rete attore–attore, in questo caso il degree misura il numero di collaborazioni tra interpreti e registi, consentendo quindi di individuare i nodi che occupano una posizione centrale nella struttura produttiva del catalogo.

Tra i nodi con degree più elevato emerge Fred Olen Ray, che presenta il valore massimo della rete con 43 connessioni. Questo risultato suggerisce una partecipazione estremamente ampia all’interno della struttura collaborativa analizzata. Anche Sean McNamara, Jim Wynorski, Spike Brandt e David Gordon Green occupano posizioni molto rilevanti, confermando il ruolo centrale di alcuni registi nella costruzione della rete. La forte presenza di registi tra i nodi più centrali indica infatti che questi soggetti tendono a collaborare con un numero elevato di attori differenti, diventando veri e propri hub della rete bipartita.

Dal lato degli attori, Tyler Perry e James Franco mostrano valori di degree particolarmente elevati, suggerendo collaborazioni distribuite su molteplici registi. In termini strutturali, questi attori risultano quindi fortemente integrati nella rete produttiva del catalogo Netflix del periodo considerato. I valori di betweenness evidenziano inoltre la capacità di alcuni nodi di fungere da ponte tra differenti nuclei collaborativi. In particolare, Sean McNamara presenta un valore di betweenness estremamente elevato, segnalando una posizione strategica nella rete. Questo significa che molte delle connessioni indirette tra gruppi differenti passano attraverso tale nodo, rendendolo fondamentale per la connettività complessiva della struttura collaborativa. Anche Jay Oliva e Spike Brandt mostrano valori elevati, suggerendo un ruolo importante nella connessione tra differenti sottogruppi della rete.

La closeness centrality risulta invece pari a zero per tutti i nodi mostrati. Questo comportamento è coerente con la presenza di una rete molto frammentata e composta da numerose componenti disconnesse. In una struttura di questo tipo, la distanza media tra tutti i nodi non può essere calcolata correttamente per molte osservazioni, rendendo la closeness meno informativa. Per questo motivo, l'analisi viene integrata tramite harmonic centrality, che rappresenta una misura più robusta in presenza di reti disconnesse. I valori elevati osservati per Sean McNamara, Jay Oliva, David Gordon Green e Spike Brandt indicano nodi mediamente vicini a una larga porzione della rete, anche in presenza di componenti separate.

Le misure di eigenvector centrality e PageRank risultano invece molto basse e relativamente omogenee. Questo comportamento suggerisce che la rete non presenta pochi nodi dominanti assoluti circondati da vicini altamente centrali, ma una struttura più distribuita e frammentata, caratterizzata da molte collaborazioni sparse tra gruppi differenti di attori e registi.

Table 10: Indicatori globali della rete attore-regista, periodo 2010-2015

rete	periodo	nodi	archi	density	componenti	diameter	avg_path_length
attore-regista	2010-2015	7770	11881	0	157	20	7.596

Gli indicatori globali della rete attore-regista per il periodo 2010-2015 evidenziano una struttura molto ampia ma fortemente frammentata. La rete è infatti composta da 7770 nodi e 11881 archi, valori che indicano un numero estremamente elevato di collaborazioni tra attori e registi all'interno del catalogo Netflix del periodo considerato.

Nonostante l'elevato numero di connessioni complessive, la density della rete risulta prossima a zero. Questo comportamento è tipico delle reti sociali e collaborative di grandi dimensioni: rispetto al numero massimo teorico di connessioni possibili, soltanto una piccola parte delle collaborazioni potenziali è effettivamente presente. In termini interpretativi, ciò significa che attori e registi collaborano generalmente con sottoinsiemi limitati della rete piuttosto che con l'intero sistema.

La presenza di 157 componenti conferma inoltre un'elevata frammentazione strutturale. La rete non costituisce quindi un unico blocco completamente connesso, ma appare suddivisa in numerosi sottogruppi indipendenti. Questo risultato suggerisce l'esistenza di molteplici nuclei produttivi separati, probabilmente associati a differenti generi cinematografici, produzioni autonome o gruppi collaborativi ricorrenti.

Il diametro pari a 20 indica che, nelle componenti connesse più estese, alcuni nodi possono risultare molto distanti tra loro in termini di percorsi relazionali. In altre parole, per collegare indirettamente certi attori e registi possono essere necessari numerosi passaggi intermedi. Questo comportamento è coerente con una rete ampia e scarsamente compatta.

La lunghezza media dei cammini, pari a circa 7.6, suggerisce invece che i nodi appartenenti alla stessa componente risultano mediamente raggiungibili attraverso un numero relativamente moderato di intermediari. Pur trattandosi di una struttura frammentata, all'interno delle singole componenti le collaborazioni mantengono quindi un certo livello di connettività.

Nel complesso, la rete attore-regista del periodo 2010-2015 appare caratterizzata da una struttura collaborativa estesa, eterogenea e distribuita su numerosi nuclei indipendenti. La combinazione tra bassa densità, alto numero di componenti e cammini medi relativamente contenuti suggerisce la presenza di molti gruppi produttivi separati ma internamente abbastanza collegati.

Table 11: Top 10 nodi per centralità nella rete attore-regista, periodo 2016-2020

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Sam Liu	Regista	43	988031.63	0	1007.743	0.000	0.002

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
James Franco	Attore	29	654542.23	0	990.259	0.000	0.001
Beyoncé	Attore	25	80732.28	0	746.189	1.000	0.001
Peter Sullivan	Regista	25	360528.69	0	879.735	0.000	0.001
Tyler Perry	Attore	24	300574.85	0	930.798	0.000	0.001
Dean McKendrick	Regista	24	149886.65	0	416.871	0.000	0.002
Steven Soderbergh	Regista	24	402972.01	0	960.161	0.001	0.001
Mike Flanagan	Regista	23	493064.30	0	953.461	0.001	0.001
Don Michael Paul	Regista	23	221005.69	0	762.095	0.000	0.001
Timothy Woodward Jr.	Regista	23	734765.43	0	915.630	0.000	0.001

Nel periodo 2016–2020 la rete attore-regista mostra una struttura meno concentrata rispetto al quinquennio precedente e presenta un maggiore equilibrio tra attori e registi nei valori di centralità più elevati. La presenza simultanea di numerosi registi tra i nodi più centrali suggerisce che, in questa fase, il ruolo di coordinamento della rete sia fortemente legato alla capacità dei registi di collaborare con cast differenti, fungendo da veri e propri punti di raccordo tra produzioni diverse.

Il nodo con il degree più elevato è Sam Liu, che raggiunge 43 connessioni. Questo valore indica una forte attività collaborativa e suggerisce una posizione molto centrale all'interno della rete. Anche il valore estremamente elevato della betweenness conferma che il regista occupa una funzione di collegamento strategico tra gruppi differenti della rete. In termini strutturali, Sam Liu appare quindi come un nodo ponte capace di connettere produzioni e collaborazioni che altrimenti risulterebbero separate.

James Franco continua a mantenere una posizione molto rilevante anche nel secondo periodo temporale. Pur avendo un degree inferiore rispetto al primo classificato, presenta valori molto elevati di betweenness e harmonic centrality, segnalando una forte capacità di raggiungere rapidamente altre porzioni della rete e di inserirsi in differenti contesti collaborativi. La sua presenza stabile tra i nodi più centrali nei diversi periodi suggerisce una continuità nella partecipazione a produzioni molto connesse.

La rete evidenzia inoltre la forte presenza di registi come Peter Sullivan, Steven Soderbergh, Mike Flanagan e Don Michael Paul. Questo aspetto è particolarmente interessante perché indica che, nella rete bipartita attore-regista, la centralità non dipende esclusivamente dalla notorietà degli attori ma anche dalla capacità dei registi di lavorare con numerosi interpreti differenti nel corso del tempo. I registi tendono infatti a creare connessioni trasversali tra gruppi di attori, aumentando così il proprio ruolo strutturale nella rete.

Si osserva anche la presenza di Beyoncé e Tyler Perry tra i nodi con degree elevato. In questo caso la centralità suggerisce una partecipazione a produzioni con cast ampi o altamente interconnessi. Tyler Perry, in particolare, mantiene valori elevati sia di degree sia di betweenness, indicando una posizione strutturalmente importante nella rete collaborativa.

I valori di closeness risultano nuovamente pari a zero, fenomeno dovuto alla frammentazione della rete in più componenti sconnesse. In presenza di componenti isolate o non raggiungibili reciprocamente, la misura di closeness tradizionale ancora perde significato operativo, motivo per cui l'analisi si concentra soprattutto su degree, betweenness e harmonic centrality, che risultano più informative in reti di questo tipo.

Nel complesso, il periodo 2016–2020 mostra una rete attore-regista caratterizzata da una forte eterogeneità strutturale, nella quale diversi registi assumono un ruolo centrale nella costruzione delle connessioni collaborative. Rispetto alla rete attore-attore, emerge quindi una struttura meno basata esclusivamente sui cast e maggiormente influenzata dalla capacità dei registi di collegare produzioni differenti.

Table 12: Indicatori globali della rete attore-regista, periodo 2016-2020

rete	periodo	nodi	archi	density	componenti	diameter	avg_path_length
attore-regista	2016-2020	6604	8811	0	173	26	8.778

Nel periodo 2016–2020 la rete attore-regista mostra una lieve riduzione delle dimensioni complessive rispetto al quinquennio precedente, passando a 6604 nodi e 8811 archi. Questa diminuzione suggerisce una struttura collaborativa leggermente meno estesa, pur mantenendo una rete di dimensioni molto elevate.

La densità continua a risultare prossima a zero, indicando una rete estremamente sparsa. Anche in questo caso, la maggior parte dei possibili collegamenti tra attori e registi non è presente.

Il numero di componenti connesse aumenta ulteriormente fino a 173, evidenziando una frammentazione ancora più marcata rispetto al periodo 2010–2015. La rete appare quindi composta da numerosi sottogruppi separati, spesso riconducibili a produzioni indipendenti o insiemi collaborativi che non condividono collegamenti diretti con il resto della struttura.

Anche il diametro cresce, raggiungendo il valore di 26. Questo risultato indica che, nei casi estremi, per collegare due nodi molto distanti possono essere necessari numerosi passaggi intermedi. L’aumento del diametro suggerisce quindi una rete meno compatta e maggiormente dispersa.

L’average path length aumenta fino a circa 8.73, confermando ulteriormente questa tendenza. In media, la distanza tra due nodi collegati risulta più elevata rispetto al quinquennio precedente, segnalando una riduzione della compattezza globale della rete collaborativa.

Riassumendo, gli indicatori globali descrivono una rete attore-regista più frammentata e meno integrata rispetto al periodo 2010–2015. La struttura sembra infatti distribuita in numerosi nuclei collaborativi relativamente autonomi, con collegamenti più deboli tra le diverse componenti della rete.

Table 13: Top 10 nodi per centralità nella rete attore-regista, periodo 2021-2025

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Brad Baruh	Regista	35	535154.0	0	863.455	0	0.002
Tyler Perry	Attore	30	251677.7	0	710.257	0	0.002
Jared Cohn	Attore	25	516772.8	0	771.506	0	0.001
Steven Soderbergh	Regista	25	412489.2	0	792.144	0	0.001
Matt Peters	Regista	24	222064.6	0	685.404	0	0.001
Wes Anderson	Regista	22	265240.5	0	778.483	0	0.001
Justin Lee	Regista	19	130946.4	0	659.583	0	0.001
Michael Feifer	Regista	19	145793.8	0	639.355	0	0.001
Jaume Collet-Serra	Regista	18	257271.7	0	782.437	0	0.001
John Swab	Regista	18	387428.9	0	761.129	0	0.001

Nel periodo 2021–2025 la rete attore-regista continua a mostrare una struttura fortemente frammentata, ma emerge una presenza ancora più marcata dei registi tra i nodi con valori di centralità elevati. Questo suggerisce che, nell’ultima fase temporale analizzata, il ruolo di connessione tra produzioni differenti sia sempre più concentrato nelle figure registiche piuttosto che negli attori.

Il nodo con il degree più elevato è Brad Baruh, che raggiunge 35 connessioni. Il valore molto alto di betweenness indica che il regista occupa una posizione cruciale nella struttura della rete, fungendo da collegamento tra gruppi collaborativi differenti. In termini strutturali, Brad Baruh appare come uno dei principali nodi ponte dell’intera rete.

Anche Tyler Perry mantiene una posizione centrale molto rilevante. Pur essendo un attore, presenta valori elevati sia di degree sia di betweenness, confermando una forte capacità di partecipare a produzioni molto connesse. La sua presenza ricorrente tra i nodi più centrali nei diversi quinquenni suggerisce una continuità collaborativa stabile nel tempo.

La rete evidenzia inoltre la forte centralità di registi affermati come Steven Soderbergh e Wes Anderson. La loro presenza tra i nodi più importanti riflette probabilmente la capacità di collaborare con cast ampi e differenziati, creando collegamenti tra produzioni e gruppi di attori differenti. In una rete bipartita attore-regista, questo comportamento tende ad aumentare sensibilmente sia il degree sia la betweenness.

Un aspetto interessante riguarda la presenza di Jared Cohn, Matt Peters, Justin Lee, Michael Feifer, Jaume Collet-Serra e John Swab, tutti caratterizzati da valori di harmonic centrality relativamente elevati. Questo suggerisce che tali nodi risultino ben posizionati all'interno delle componenti collaborative della rete, riuscendo a raggiungere rapidamente numerosi altri nodi attraverso pochi passaggi intermedi.

Inoltre, i valori di eigenvector centrality risultano prossimi allo zero per tutti i nodi considerati. Questo comportamento suggerisce che la rete non sia dominata da un unico nucleo altamente coeso di nodi reciprocamente centrali, ma piuttosto da numerosi gruppi collaborativi separati. In altre parole, la centralità dei nodi dipende maggiormente dal numero di collaborazioni dirette e dalla capacità di collegare componenti differenti, piuttosto che dall'appartenenza a un unico centro strutturale dominante.

Il periodo 2021–2025 conferma l'evoluzione della rete attore-regista verso una struttura distribuita e frammentata, nella quale i registi assumono un ruolo sempre più importante come elementi di connessione tra produzioni differenti. Rispetto ai periodi precedenti, la rete appare meno compatta ma caratterizzata da numerosi nuclei collaborativi autonomi.

Table 14: Indicatori globali della rete attore-regista, periodo 2021-2025

rete	periodo	nodi	archi	density	componenti	diameter	avg_path_length
attore-regista	2021-2025	6137	7639	0	235	25	9.024

La rete è composta da 6.137 nodi e 7.639 archi, confermando la presenza di una struttura molto ampia che include sia attori sia registi. Le dimensioni della rete risultano leggermente inferiori rispetto ai periodi precedenti, coerentemente con il minor numero di film presenti nel dataset per questo quinquennio.

La densità è estremamente bassa (arrotondata a 0 nella tabella). Questo risultato è atteso nelle reti bipartite di grandi dimensioni: soltanto una piccola frazione dei collegamenti teoricamente possibili tra attori e registi è effettivamente presente. In altre parole, ogni regista collabora con un numero limitato di attori e ogni attore lavora soltanto con una piccola parte dei registi disponibili nel catalogo.

Un elemento particolarmente rilevante è rappresentato dal numero di componenti connesse, pari a 235. Questo valore indica che la rete non forma un'unica struttura completamente collegata, ma è suddivisa in numerosi sottogruppi indipendenti. Tali componenti possono corrispondere a produzioni isolate, piccoli gruppi di collaborazioni che non condividono attori o registi con il resto del catalogo, oppure contenuti molto specifici che rimangono separati dalle produzioni più centrali.

Il diametro pari a 25 suggerisce che, all'interno della componente principale, la distanza massima tra due nodi raggiunge 25 passaggi. Si tratta di un valore relativamente elevato, che evidenzia la presenza di percorsi lunghi tra alcune coppie di attori e registi. Questo risultato è coerente con una rete frammentata e caratterizzata da molte componenti periferiche.

La lunghezza media dei cammini, pari a circa 9.0, conferma ulteriormente questa interpretazione. In media, per collegare due nodi appartenenti alla stessa componente sono necessari circa nove passaggi. Il valore è superiore a quello che si osserva tipicamente nelle reti molto compatte e suggerisce una struttura meno coesa rispetto a una rete fortemente integrata.

Tali indicatori mostrano che la rete attore-regista del periodo 2021-2025 è una rete ampia ma fortemente sparsa, caratterizzata da numerose componenti indipendenti e da una connettività relativamente debole tra le diverse parti del sistema. La struttura appare quindi meno compatta e più frammentata, riflettendo una maggiore eterogeneità delle collaborazioni tra attori e registi presenti nel catalogo Netflix dell'ultimo quinquennio analizzato.

Dopo aver analizzato gli indicatori individuali e globali, si applica nuovamente la community detection tramite algoritmo Louvain. Nella rete attore-regista, le comunità non rappresentano gruppi composti da nodi dello stesso tipo, ma nuclei collaborativi bipartiti formati da attori e registi che tendono a lavorare più frequentemente tra loro. La modularità consente quindi di valutare quanto tali nuclei siano separati dal resto della rete.

Table 15: Modularità Louvain della rete attore-regista nei tre periodi

periodo	algoritmo	modularity
2010-2015	Louvain	0.768
2016-2020	Louvain	0.833
2021-2025	Louvain	0.870

La modularità ottenuta tramite algoritmo Louvain nella rete attore-regista risulta molto elevata in tutti e tre i periodi analizzati e mostra inoltre una crescita progressiva nel tempo, passando da 0.768 nel periodo 2010–2015 a 0.833 nel quinquennio 2016–2020, fino a raggiungere 0.869 nel periodo 2021–2025.

Valori di modularità così elevati indicano che la rete è fortemente suddivisa in comunità ben definite, cioè gruppi di attori e registi che collaborano frequentemente tra loro ma presentano relativamente pochi collegamenti con il resto della rete. Nel contesto di una rete bipartita attore-regista, queste comunità possono essere interpretate come nuclei produttivi o collaborativi relativamente autonomi, spesso associati a specifici insiemi di produzioni, studi, generi cinematografici o gruppi professionali ricorrenti.

L'aumento della modularità nel corso dei tre periodi suggerisce inoltre che la rete sia diventata progressivamente più frammentata e specializzata. In altre parole, le collaborazioni tendono sempre più a concentrarsi all'interno di gruppi distinti piuttosto che distribuirsi uniformemente sull'intera rete. Questo risultato è coerente con quanto osservato negli indicatori globali, che mostravano un aumento del numero di componenti e delle distanze medie tra nodi.

Il valore particolarmente elevato del periodo 2021–2025 indica quindi una struttura molto compartimentalizzata, nella quale i gruppi collaborativi risultano fortemente separati tra loro. Ciò suggerisce che attori e registi tendano a collaborare in cerchie relativamente stabili e meno interconnesse rispetto ai periodi precedenti.

In conclusione, l'analisi della modularità conferma che la rete attore-regista non presenta una struttura globale compatta, ma è organizzata in numerose comunità collaborative ben definite, la cui separazione aumenta progressivamente nel tempo.

Table 16: Confronto tra algoritmi di community detection nella rete attore-regista

rete	periodo	confronto	VI	NMI	ARI
attore-regista	2010-2015	Louvain-Leiden	4.729	0.641	0.000
attore-regista	2010-2015	Louvain-Walktrap	3.081	0.696	0.093
attore-regista	2010-2015	Louvain-Infomap	2.960	0.729	0.088
attore-regista	2010-2015	Leiden-Walktrap	3.034	0.796	0.000
attore-regista	2010-2015	Leiden-Infomap	2.260	0.856	0.000
attore-regista	2010-2015	Walktrap-Infomap	1.732	0.863	0.039
attore-regista	2016-2020	Louvain-Leiden	4.294	0.677	0.000
attore-regista	2016-2020	Louvain-Walktrap	2.865	0.716	0.066

rete	periodo	confronto	VI	NMI	ARI
attore-regista	2016-2020	Louvain-Infomap	2.580	0.769	0.118
attore-regista	2016-2020	Leiden-Walktrap	3.203	0.777	0.000
attore-regista	2016-2020	Leiden-Infomap	2.146	0.861	0.000
attore-regista	2016-2020	Walktrap-Infomap	1.773	0.855	0.037
attore-regista	2021-2025	Louvain-Leiden	3.999	0.702	0.000
attore-regista	2021-2025	Louvain-Walktrap	2.594	0.758	0.075
attore-regista	2021-2025	Louvain-Infomap	2.166	0.809	0.151
attore-regista	2021-2025	Leiden-Walktrap	2.707	0.816	0.000
attore-regista	2021-2025	Leiden-Infomap	2.119	0.862	0.000
attore-regista	2021-2025	Walktrap-Infomap	1.360	0.892	0.081

Il confronto tra gli algoritmi di community detection mostra che la rete attore-regista presenta una struttura comunitaria relativamente stabile, ma con differenze non trascurabili tra le partizioni individuate dai diversi metodi. Nel complesso, i valori degli indicatori suggeriscono che gli algoritmi tendano a riconoscere nuclei collaborativi simili, pur differendo nella granularità e nella separazione delle comunità.

Nel periodo 2010–2015, il confronto tra Louvain e Leiden produce un valore di VI pari a 4.729 e un NMI di 0.641. Questo indica che i due algoritmi identificano strutture comunitarie parzialmente simili ma non completamente sovrapponibili. La differenza è probabilmente dovuta al fatto che Leiden tende a raffinare maggiormente le comunità individuate da Louvain, producendo partizioni più frammentate e coese internamente.

Il confronto tra Walktrap e Infomap mostra invece i risultati più vicini tra loro, con VI pari a 1.732 e NMI pari a 0.863. Questo suggerisce una forte concordanza tra i due algoritmi nella rilevazione delle comunità collaborative. Anche nel contesto della rete attore-regista, Walktrap e Infomap sembrano quindi individuare strutture molto simili, probabilmente perché entrambi riescono a cogliere efficacemente i sottogruppi locali di collaborazione.

Nel periodo 2016–2020 la situazione rimane sostanzialmente stabile. I valori di NMI aumentano leggermente in quasi tutti i confronti, suggerendo una maggiore coerenza tra gli algoritmi. In particolare, Leiden–Infomap raggiunge un NMI pari a 0.861, mentre Walktrap–Infomap mantiene un valore molto elevato pari a 0.855. Questo comportamento è coerente con l’aumento della modularità osservato in precedenza: comunità più nette e separate tendono infatti a essere riconosciute in modo più simile da algoritmi differenti.

Nel periodo 2021–2025 emerge la maggiore convergenza tra gli algoritmi. Il confronto Walktrap–Infomap presenta il valore di VI più basso dell’intera tabella, pari a 1.360, accompagnato da un NMI molto elevato di 0.892. Questo indica che i due algoritmi producono partizioni estremamente simili, segnalando la presenza di comunità collaborative ormai molto ben definite nella rete attore-regista.

Anche i confronti che coinvolgono Louvain mostrano un miglioramento progressivo nel tempo. Ad esempio, il confronto Louvain–Infomap passa da un NMI di 0.729 nel primo periodo a 0.809 nel terzo periodo. Questo suggerisce che, con l’aumentare della frammentazione e della modularità della rete, le comunità individuate tendano a diventare più stabili indipendentemente dall’algoritmo utilizzato.


I valori di ARI rimangono generalmente bassi o pari a zero in molti confronti. Questo fenomeno è relativamente comune nelle reti molto grandi e frammentate, dove algoritmi differenti possono identificare comunità strutturalmente simili ma con assegnazioni locali diverse dei nodi. Per questo motivo, nel contesto dell’analisi svolta, NMI e VI risultano indicatori più informativi rispetto all’ARI.

Dunque, gli algoritmi convergono infatti sempre di più nell’identificazione dei gruppi collaborativi, suggerendo che le collaborazioni tra attori e registi tendano a organizzarsi in nuclei relativamente stabili e ben separati dal resto della rete.

Conclusa l’analisi numerica delle reti two-mode tra attori e registi, si può procedere con l’analisi grafica dei grafi bipartiti.

Ego-network bipartiti attore-regista


Periodo 2010-2015



Degree ● 10 ● 20 ● 30 Tipo di nodo ● Attore ● Regista

Ego-network bipartiti attore-regista

Periodo 2010-2015



Degree ● 10 ● 20 ● 30 Tipo di nodo ● Attore ● Regista

Periodo 2010–2015



Nel primo sottografo emerge Sean McNamara, regista caratterizzato da un numero molto elevato di collaborazioni distribuite su un insieme ampio di attori. La struttura appare relativamente dispersa, suggerendo una rete collaborativa estesa ma non necessariamente composta da attori che collaborano frequentemente anche tra loro. Il regista agisce quindi come principale punto di connessione dell'intero sottografo.


Nel terzo sottografo compare Spike Brandt, anch'egli collocato in posizione centrale rispetto a un insieme molto ampio di attori. La rete mostra una struttura estremamente gerarchica, nella quale il regista rappresenta il vero hub collaborativo del gruppo. La presenza di molti nodi periferici indica collaborazioni numerose ma distribuite, probabilmente associate a produzioni differenti o a collaborazioni occasionali.

Per verificare se la struttura a stella osservata nei principali ego-network del primo periodo rappresenti una caratteristica generale della rete bipartita, sono stati estratti casualmente due registi dai periodi successivi, uno per il 2016–2020 e uno per il 2021–2025. L'estrazione è stata effettuata fissando un seed, così da rendere

la selezione riproducibile.


Ego-network bipartito attore-regista

Regista estratto: Chelsea Stardust – Periodo 2016–2020



Ego-network bipartito attore-regista

Regista estratto: Kyle Balda – Periodo 2021–2025



Anche gli ego-network costruiti a partire da registi estratti casualmente nei periodi 2016–2020 e 2021–2025 confermano la struttura tipica della rete bipartita attore-regista. In entrambi i casi emerge una configurazione fortemente centrata sul regista, che agisce come nodo hub collegando direttamente numerosi attori tra loro non connessi. La disposizione “a stella” evidenzia quindi la natura intrinsecamente bipartita della rete: gli attori non instaurano collegamenti diretti reciproci, ma risultano connessi esclusivamente attraverso il regista comune. Inoltre, il fatto che tale configurazione emerga anche per registi selezionati casualmente suggerisce che questa proprietà non rappresenti un’eccezione limitata ai nodi più centrali, ma una caratteristica strutturale generale della rete attore-regista nei diversi periodi temporali analizzati.

Analisi della rete attore-genere

La rete attore-genere viene costruita come rete bipartita, poiché collega due insiemi distinti di nodi: gli attori e i generi cinematografici. In questo caso, un arco indica che un determinato attore compare in almeno un film appartenente a uno specifico genere. A differenza della rete attore-regista, che descrive relazioni produttive, la rete attore-genere consente di analizzare la distribuzione tematica degli attori e di individuare quali generi risultano più centrali nella struttura del catalogo.

Table 17: Top 10 nodi per centralità nella rete attore-genere, periodo 2010-2015

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Drama	Genere	2708	5984096.5	0	3861.000	1.000	0.067
Comedy	Genere	2402	4937162.2	0	3657.000	0.877	0.058
Thriller	Genere	1933	2950192.3	0	3344.333	0.742	0.044
Horror	Genere	1642	2990814.3	0	3150.333	0.490	0.042
Action	Genere	1622	2155817.9	0	3137.000	0.658	0.035

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Romance	Genere	1267	1138595.1	0	2900.333	0.500	0.029
Science Fiction	Genere	1021	951953.1	0	2736.333	0.392	0.022
Family	Genere	936	776023.7	0	2679.667	0.346	0.020
Adventure	Genere	928	724321.9	0	2674.333	0.397	0.019
Crime	Genere	823	536680.3	0	2604.333	0.367	0.018

La tabella relativa alla rete attore-genere per il periodo 2010–2015 evidenzia una forte centralità dei generi cinematografici più diffusi all’interno del catalogo analizzato. In particolare, Drama rappresenta il nodo più connesso dell’intera rete, con un degree pari a 2708, indicando che un numero molto elevato di attori compare in produzioni appartenenti a questo genere. Valori elevati si osservano anche per Comedy, Thriller, Horror e Action, confermando il ruolo dominante dei generi mainstream nella struttura complessiva della rete.

Anche le misure di betweenness risultano particolarmente elevate per questi generi, suggerendo che essi svolgano una funzione di collegamento tra gruppi differenti di attori. In altre parole, molti attori che non condividono necessariamente gli stessi film risultano comunque indirettamente connessi attraverso generi comuni particolarmente popolari, soprattutto Drama e Comedy.

I valori di eigenvector centrality rafforzano ulteriormente questa interpretazione. Drama presenta infatti il valore massimo possibile (1.000), segnalando non solo un elevato numero di connessioni, ma anche il fatto di essere collegato ad attori altamente centrali nella rete. Lo stesso comportamento, seppur con intensità minore, emerge per Comedy e Thriller.

Nel complesso, la rete appare fortemente organizzata attorno a pochi generi dominanti, che funzionano come veri e propri hub tematici del catalogo cinematografico. Ciò suggerisce che la distribuzione degli attori nei diversi film non sia uniforme tra i generi, ma tenda a concentrarsi soprattutto attorno a categorie narrative molto diffuse e trasversali.

Table 18: Top 10 nodi per centralità nella rete attore-genere, periodo 2016-2020

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Drama	Genere	2234	4513654.5	0	3246.000	1.000	0.067
Comedy	Genere	1828	3189394.6	0	2975.333	0.812	0.053
Thriller	Genere	1737	2569182.8	0	2914.667	0.797	0.049
Horror	Genere	1507	2219731.1	0	2761.333	0.605	0.045
Action	Genere	1306	1627508.3	0	2627.333	0.627	0.035
Romance	Genere	907	760220.6	0	2361.333	0.399	0.026
Science Fiction	Genere	832	663425.7	0	2311.333	0.408	0.022
Crime	Genere	791	598462.8	0	2284.000	0.419	0.021
Adventure	Genere	754	535107.4	0	2259.333	0.396	0.019
Family	Genere	679	501022.9	0	2209.333	0.290	0.017

Il periodo 2016–2020 mostra una struttura molto simile a quella osservata nel quinquennio precedente, confermando la forte centralità dei principali generi cinematografici nella rete attore-genere. Anche in questo caso Drama rappresenta il nodo dominante dell’intera rete, con il degree più elevato e con i valori massimi di eigenvector centrality e PageRank. Questo indica che il genere drammatico continua a coinvolgere il maggior numero di attori e a occupare una posizione centrale nella struttura collaborativa del catalogo.

Subito dopo compaiono Comedy e Thriller, che mantengono livelli molto elevati sia di connessioni sia di betweenness centrality. Tali valori suggeriscono che questi generi fungano da importanti nodi di raccordo tra differenti gruppi di attori, contribuendo significativamente alla connettività complessiva della rete.

Rispetto al periodo 2010–2015 si osserva tuttavia una lieve riduzione generale dei valori di degree per quasi tutti i generi principali. Ad esempio, Drama passa da oltre 2700 connessioni a circa 2200, mentre Comedy e Action mostrano anch'essi una diminuzione della numerosità dei collegamenti. Questo comportamento suggerisce una possibile riduzione della varietà di attori associati ai singoli generi oppure una maggiore frammentazione del catalogo nel secondo quinquennio.

Si nota inoltre una sostanziale stabilità nella gerarchia dei generi centrali: Drama, Comedy, Thriller, Horror e Action continuano infatti a rappresentare i principali hub tematici della rete. Tale continuità evidenzia come la struttura narrativa del catalogo mantenga nel tempo un nucleo relativamente stabile di generi dominanti attorno ai quali si concentra la maggior parte delle produzioni e delle collaborazioni attoriali.

Table 19: Top 10 nodi per centralità nella rete attore-genere, periodo 2021-2025

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Drama	Genere	1816	3450952.4	0	2867.667	0.952	0.060
Comedy	Genere	1727	3070964.1	0	2808.333	0.898	0.054
Thriller	Genere	1697	2418007.5	0	2788.333	1.000	0.052
Horror	Genere	1435	2205467.8	0	2613.667	0.714	0.048
Action	Genere	1353	1765886.1	0	2559.000	0.802	0.040
Science Fiction	Genere	785	645922.3	0	2180.333	0.459	0.022
Crime	Genere	784	646326.7	0	2179.667	0.489	0.023
Mystery	Genere	709	488758.1	0	2129.667	0.421	0.021
Romance	Genere	669	435706.7	0	2103.000	0.339	0.021
Family	Genere	626	390674.5	0	2074.333	0.325	0.017

Nel periodo 2021–2025 la rete attore-genere mantiene una struttura fortemente concentrata attorno a pochi generi dominanti, ma emergono alcuni cambiamenti interessanti rispetto ai quinquenni precedenti. Anche in questo caso Drama rappresenta il nodo con il maggior numero di connessioni, confermandosi il principale hub tematico del catalogo. I valori elevati di degree, betweenness e harmonic centrality indicano che il genere drammatico continua a coinvolgere una quota molto ampia di attori e a occupare una posizione centrale nei percorsi della rete.

Subito dopo si collocano Comedy e Thriller, che mostrano livelli di centralità molto simili tra loro. Tuttavia, un elemento rilevante è che Thriller raggiunge il valore massimo di eigenvector centrality pari a 1.000, superando leggermente Drama. Questo suggerisce che, pur avendo meno connessioni assolute, il genere thriller risulta particolarmente collegato ai nodi più influenti dell'intera rete, assumendo quindi un ruolo strategico nella struttura globale delle collaborazioni.

Nel confronto temporale emerge inoltre una progressiva riduzione generale dei valori di degree rispetto ai periodi precedenti. I principali generi continuano a dominare la rete, ma con una numerosità inferiore di attori associati. Questo andamento può essere interpretato come un segnale di maggiore specializzazione o frammentazione delle produzioni cinematografiche più recenti.

Si osservano anche piccoli cambiamenti nella composizione dei generi più centrali. Mystery entra infatti tra i primi dieci nodi più influenti, sostituendo Adventure, mentre Science Fiction e Crime mantengono una posizione relativamente stabile. Ciò suggerisce un'evoluzione graduale delle preferenze produttive e narrative del catalogo nel periodo più recente.

Nel complesso, la rete attore-genere del quinquennio 2021–2025 conferma quindi una struttura fortemente gerarchica, dominata da pochi generi centrali che continuano a concentrare la maggior parte delle collaborazioni attoriali, pur mostrando segnali di crescente differenziazione interna rispetto ai periodi precedenti.

Si passa ora allo studio degli indicatori globali di tale rete specificamente per i tre periodi oggetto di studio.

Table 20: Indicatori globali della rete attore-genere nei tre periodi

rete	periodo	nodi	archi	density	componenti	diameter	avg_path_length
attore-genere	2010-2015	6159	19612	0.001	1	4	2.963
attore-genere	2016-2020	5262	16110	0.001	1	4	2.999
attore-genere	2021-2025	4963	14712	0.001	1	6	3.029

Come si evince dai risultati, la rete attore-genere mantiene una struttura estremamente compatta e stabile lungo tutti e tre i quinquenni analizzati. In ciascun periodo il numero di componenti è infatti pari a 1, indicando la presenza di una sola giant component in cui tutti i nodi risultano indirettamente collegati. Questo comportamento riflette la natura fortemente interconnessa della rete, dove i generi cinematografici principali fungono da ponte tra migliaia di attori differenti.

Si osserva inoltre una progressiva diminuzione del numero di nodi e archi nel tempo. La rete passa infatti da 6159 nodi e 19612 archi nel periodo 2010–2015 a 4963 nodi e 14712 archi nel quinquennio 2021–2025. Tale riduzione suggerisce una diminuzione complessiva delle collaborazioni registrate nel catalogo più recente oppure una maggiore concentrazione delle produzioni attorno a specifici gruppi di generi.

Nonostante questa riduzione dimensionale, la rete continua a mantenere distanze interne molto contenute. L’average path length rimane infatti sempre vicino a 3, mentre il diametro assume valori molto bassi rispetto alla dimensione complessiva della rete. Questo significa che qualsiasi attore o genere può essere raggiunto attraverso pochissimi passaggi intermedi, confermando la presenza di una struttura tipicamente “small world”.

Nel periodo più recente il diametro aumenta leggermente da 4 a 6, segnalando una lieve crescita della dispersione interna della rete. Tuttavia, l’aumento rimane contenuto e non altera la forte coesione globale del sistema.

Anche la density resta sostanzialmente stabile e molto bassa in tutti i periodi. Questo risultato è normale in reti di grandi dimensioni: pur essendoci una quantità enorme di possibili connessioni teoriche, solo una piccola parte di esse viene effettivamente realizzata. Nonostante ciò, i generi centrali riescono comunque a mantenere la rete completamente connessa.

Quindi, si può concludere che la rete attore-genere presenta una struttura molto più compatta e integrata rispetto alla rete attore-regista, evidenziando come i generi cinematografici costituiscano forti elementi aggreganti all’interno del sistema delle collaborazioni cinematografiche.

Per quanto riguarda la community detection, si analizza anche in questo caso la modularità tramite l’algoritmo di Louvain.

Table 21: Modularità Louvain della rete attore-genere nei tre periodi

periodo	algoritmo	modularity
2010-2015	Louvain	0.309
2016-2020	Louvain	0.336
2021-2025	Louvain	0.352

L’analisi della modularità tramite algoritmo Louvain mostra che la rete attore-genere presenta valori sensibilmente più bassi rispetto alla rete attore-regista. I valori di modularity risultano infatti compresi tra 0.310 e 0.346 nei tre quinquenni analizzati, indicando una struttura comunitaria presente ma relativamente debole.

Questo risultato è coerente con la natura della rete. A differenza della rete attore-regista, dove i registi tendono a collaborare con gruppi relativamente stabili di attori, nella rete attore-genere i generi cinematografici fungono da forti elementi aggreganti e condivisi. Molti attori partecipano infatti contemporaneamente a più generi, creando numerose connessioni trasversali che riducono la separazione netta tra le comunità.

Si osserva comunque un leggero aumento progressivo della modularità nel tempo, passando da 0.310 nel periodo 2010–2015 a 0.346 nel quinquennio 2021–2025. Questo andamento suggerisce una moderata crescita della specializzazione dei gruppi di attori rispetto ai generi cinematografici frequentati. In altre parole, nel periodo più recente la rete tende a organizzarsi in comunità leggermente più distinguibili rispetto al passato.

Nonostante ciò, i valori rimangono relativamente contenuti e confermano che la rete attore-genere mantiene una struttura fortemente integrata e interconnessa. I generi principali, come Drama, Comedy e Thriller, continuano infatti a creare collegamenti tra una grande quantità di attori differenti, limitando la formazione di comunità completamente separate.

Complessivamente, l'analisi della modularità evidenzia quindi una rete caratterizzata da una forte coesione globale, nella quale le divisioni comunitarie risultano meno marcate rispetto ad altre tipologie di reti collaborative analizzate nel progetto.

Analogamente alle altre reti studiate precedentemente, si passa ora al confronto tra i vari algoritmi di community detection.

Table 22: Confronto tra algoritmi di community detection nella rete attore-genere

rete	periodo	confronto	VI	NMI	ARI
attore-regista	2010-2015	Louvain-Leiden	4.729	0.641	0.000
attore-regista	2010-2015	Louvain-Walktrap	3.081	0.696	0.093
attore-regista	2010-2015	Louvain-Infomap	2.960	0.729	0.088
attore-regista	2010-2015	Leiden-Walktrap	3.034	0.796	0.000
attore-regista	2010-2015	Leiden-Infomap	2.260	0.856	0.000
attore-regista	2010-2015	Walktrap-Infomap	1.732	0.863	0.039
attore-regista	2016-2020	Louvain-Leiden	4.294	0.677	0.000
attore-regista	2016-2020	Louvain-Walktrap	2.865	0.716	0.066
attore-regista	2016-2020	Louvain-Infomap	2.580	0.769	0.118
attore-regista	2016-2020	Leiden-Walktrap	3.203	0.777	0.000
attore-regista	2016-2020	Leiden-Infomap	2.146	0.861	0.000
attore-regista	2016-2020	Walktrap-Infomap	1.773	0.855	0.037
attore-regista	2021-2025	Louvain-Leiden	3.999	0.702	0.000
attore-regista	2021-2025	Louvain-Walktrap	2.594	0.758	0.075
attore-regista	2021-2025	Louvain-Infomap	2.166	0.809	0.151
attore-regista	2021-2025	Leiden-Walktrap	2.707	0.816	0.000
attore-regista	2021-2025	Leiden-Infomap	2.119	0.862	0.000
attore-regista	2021-2025	Walktrap-Infomap	1.360	0.892	0.081

Il confronto tra gli algoritmi di community detection nella rete attore-genere mostra un quadro molto diverso rispetto alla rete attore-regista. In questo caso, tutti gli algoritmi individuano comunità meno separate e maggiormente sovrapposte, coerentemente con la natura estremamente connessa della rete.

I valori di NMI risultano generalmente elevati in tutti i periodi, soprattutto nei confronti che coinvolgono Walktrap e Infomap. In particolare, il confronto Walktrap–Infomap raggiunge i livelli di similarità più alti dell'intera tabella, con NMI pari a 0.862 nel periodo 2010–2015 e 0.893 nel periodo 2021–2025. Questo indica che i due algoritmi tendono a identificare strutture comunitarie molto simili nella rete attore-genere.

Anche la Variation of Information conferma questa tendenza. I valori più bassi si osservano infatti proprio nel confronto Walktrap–Infomap, suggerendo una forte concordanza tra le partizioni prodotte dai due algoritmi. Al contrario, i confronti che coinvolgono Louvain e Leiden presentano valori di VI più elevati, evidenziando una maggiore differenza nel modo in cui vengono individuate le comunità.

Un aspetto particolarmente interessante riguarda l'Adjusted Rand Index. I confronti che coinvolgono Leiden mostrano quasi sempre valori prossimi a zero, indicando che Leiden tende a costruire partizioni

significativamente diverse rispetto agli altri algoritmi. Tuttavia, questa differenza non implica necessariamente una migliore qualità interpretativa della soluzione trovata. Nel contesto della rete attore-genere, infatti, la struttura comunitaria è relativamente debole e molto interconnessa; di conseguenza, una maggiore “sostituzione” dell’algoritmo non produce necessariamente risultati più utili dal punto di vista interpretativo.


Si osserva inoltre una progressiva crescita della concordanza tra gli algoritmi nel tempo. Nel periodo 2021–2025 aumentano infatti sia i valori di NMI sia quelli di ARI nei confronti che coinvolgono Louvain, Walktrap e Infomap. Questo suggerisce che, nel periodo più recente, la struttura comunitaria della rete attore-genere diventa leggermente più definita e stabile.

Si può quindi stabilire che la rete attore-genere presenta comunità meno marcate rispetto alla rete attore-regista, ma comunque sufficientemente riconoscibili da produrre risultati coerenti tra diversi algoritmi di community detection. In particolare, Louvain, Walktrap e Infomap mostrano livelli di concordanza relativamente elevati, mentre Leiden tende a individuare partizioni più differenti e meno allineate con gli altri approcci.

Per ciò che concerne la rappresentazione grafica di questo tipo di rete, si provvede nuovamente ad una scelta casuale per scoprire e analizzare le caratteristiche delle ego-network.


Ego-network bipartito attore-genere

Attore estratto: Jennette McCurdy – Periodo 2010–2015




Ego-network bipartito attore-genere

Attore estratto: Brian Quinn – Periodo 2016–2020



Ego-network bipartito attore-genere

Attore estratto: Martin Sensmeier – Periodo 2021–2025



La rappresentazione delle ego-network bipartite attore-genere evidenzia, nei tre periodi considerati, il modo in cui i singoli attori risultano associati ai diversi generi cinematografici presenti nel dataset. Per rendere la visualizzazione più leggibile rispetto alla rete completa, viene selezionato casualmente un attore per ciascun quinquennio e vengono mostrati esclusivamente i collegamenti diretti con i generi a cui ha partecipato.

Nel periodo 2010-2015, l'attore estratto casualmente è Jennette McCurdy, collegata ai generi Comedy, Family, Adventure e TV Movie. La presenza di più connessioni suggerisce una partecipazione a produzioni appartenenti a categorie differenti, mostrando quindi una moderata varietà di ruoli e contesti cinematografici.

Nel periodo 2016-2020 viene invece selezionato Brian Quinn, che presenta un solo collegamento con il genere Comedy. In questo caso la struttura della ego-network è estremamente semplice e riflette una specializzazione più marcata, oppure una presenza nel dataset associata prevalentemente a un unico tipo di produzione.

Infine, nel periodo 2021-2025 l'attore casualmente estratto è Martin Sensmeier, collegato ai generi Western, Crime, Drama e Romance. Anche in questo caso emerge una pluralità di connessioni, indicativa di una partecipazione a produzioni eterogenee appartenenti a più categorie narrative.

Nel complesso, queste visualizzazioni mostrano come le reti bipartite attore-genere permettano di osservare direttamente le relazioni tra interpreti e categorie cinematografiche.

Terminato lo studio di questa rete, si procede ad un'analoga disamina per la rete bipartita regista-genere.

Analisi della rete regista-genere

Anche in questo caso, il primo passo consiste nella descrizione dei primi dieci nodi per centralità.

Table 23: Top 10 nodi per centralità nella rete regista-genere, periodo 2010-2015

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Drama	Genere	751	615710.80	0	1116.000	1.000	0.076
Comedy	Genere	674	530422.48	0	1064.667	0.887	0.066
Thriller	Genere	493	279101.70	0	944.000	0.625	0.045
Action	Genere	377	182611.10	0	866.667	0.519	0.032
Horror	Genere	370	225998.97	0	861.750	0.358	0.037
Romance	Genere	307	83542.25	0	820.000	0.428	0.029
Family	Genere	236	67192.90	0	772.667	0.294	0.019
Adventure	Genere	232	72479.59	0	770.000	0.325	0.019
Science Fiction	Genere	218	64187.85	0	760.667	0.285	0.018
Fantasy	Genere	195	55376.31	0	745.333	0.251	0.016

Nel periodo 2010-2015 si evince che i nodi più centrali della rete sono ancora una volta i generi cinematografici più diffusi del catalogo. In particolare, Drama rappresenta il nodo dominante della rete, con il degree più elevato pari a 751, indicando che questo genere è associato al maggior numero di registi presenti nel dataset.

Anche le altre misure di centralità confermano la posizione predominante di Drama. Il valore massimo di betweenness suggerisce infatti che questo genere agisce come importante punto di collegamento tra diversi gruppi di registi, mentre i valori elevati di harmonic centrality ed eigenvector centrality mostrano come il nodo sia inserito in una zona molto influente della rete.

Subito dopo compaiono Comedy e Thriller, che mantengono livelli di centralità elevati in quasi tutte le metriche considerate. Questo indica che numerosi registi lavorano frequentemente all'interno di questi generi, contribuendo a renderli aree particolarmente dense e connesse della rete.

Generi come Action, Horror e Romance mostrano valori intermedi ma comunque rilevanti, suggerendo una buona capacità di connessione con differenti registi del catalogo. Nella parte inferiore della classifica si trovano invece Family, Adventure, Science Fiction e Fantasy, che pur risultando meno centrali mantengono comunque una presenza significativa nella struttura complessiva della rete.

Nel complesso, la rete regista-genere del periodo 2010-2015 appare fortemente concentrata attorno a pochi generi principali, con Drama e Comedy che svolgono un ruolo dominante nella distribuzione delle relazioni tra registi e generi cinematografici.

Table 24: Top 10 nodi per centralità nella rete regista-genere, periodo 2016-2020

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Drama	Genere	566	401831.40	0	882.000	1.000	0.072
Comedy	Genere	497	322651.49	0	836.000	0.886	0.060
Thriller	Genere	403	185052.52	0	761.483	0.679	0.047
Horror	Genere	339	172643.90	0	730.667	0.501	0.042
Action	Genere	296	126804.98	0	702.000	0.517	0.032
Adventure	Genere	199	58324.92	0	637.333	0.359	0.020
Romance	Genere	199	44713.32	0	636.950	0.346	0.024
Science Fiction	Genere	190	57621.72	0	631.333	0.319	0.020
Crime	Genere	183	53942.67	0	626.667	0.349	0.020
Family	Genere	182	46818.55	0	625.750	0.301	0.019

La rete regista-genere per il periodo 2016-2020 mostra una struttura molto simile a quella osservata nel periodo precedente, con alcuni cambiamenti nei livelli complessivi di centralità. Anche in questo caso, Drama

rappresenta il nodo più importante della rete, registrando il degree più elevato pari a 566. Questo indica che il genere Drama continua ad essere associato al maggior numero di registi del catalogo.

I valori più alti di betweenness, harmonic centrality ed eigenvector centrality confermano inoltre il ruolo centrale di questo genere nella struttura della rete. Drama appare infatti come uno dei principali punti di connessione tra differenti gruppi di registi e occupa una posizione altamente influente all'interno del sistema complessivo delle relazioni.

Subito dopo compaiono Comedy e Thriller, che mantengono livelli di centralità elevati in quasi tutte le metriche considerate. Ciò suggerisce che questi generi continuano a rappresentare aree molto frequentate dai registi presenti nel catalogo, pur con valori inferiori rispetto al periodo 2010-2015.

Si osserva inoltre una riduzione generale dei valori di degree e betweenness rispetto al periodo precedente. Ad esempio, Drama passa da 751 collegamenti a 566, mentre anche gli altri generi mostrano diminuzioni analoghe. Questo comportamento suggerisce una contrazione della rete oppure una minore varietà di connessioni tra registi e generi nel periodo 2016-2020.

Nella parte finale della classifica rimangono presenti generi come Adventure, Science Fiction, Crime e Family, che mostrano valori di centralità più contenuti ma continuano comunque a contribuire alla struttura globale della rete. Nel complesso, la rete mantiene una configurazione fortemente concentrata attorno a pochi generi dominanti, con Drama e Comedy che continuano a rappresentare i principali poli della produzione cinematografica del catalogo analizzato.

Table 25: Top 10 nodi per centralità nella rete regista-genere, periodo 2021-2025

nodo	tipo	degree	betweenness	closeness	harmonic	eigenvector	pagerank
Comedy	Genere	442	262881.22	0	745.000	0.867	0.058
Thriller	Genere	407	179713.08	0	721.667	1.000	0.052
Drama	Genere	404	241181.75	0	719.667	0.762	0.057
Horror	Genere	347	165656.62	0	681.667	0.750	0.047
Action	Genere	314	124105.21	0	659.667	0.748	0.038
Science Fiction	Genere	187	48629.62	0	565.300	0.418	0.023
Crime	Genere	184	54765.98	0	573.000	0.424	0.023
Family	Genere	161	30120.28	0	548.100	0.296	0.019
Adventure	Genere	158	32776.64	0	555.667	0.351	0.018
Mystery	Genere	156	33595.24	0	553.817	0.373	0.019

La rete regista-genere per il periodo 2021-2025 ha subito un'ulteriore riduzione dei valori di centralità rispetto ai periodi precedenti, pur mantenendo una struttura fortemente concentrata attorno a pochi generi principali. In questa fase della rete, Comedy rappresenta il nodo con il degree più elevato, pari a 442, superando leggermente Thriller e Drama. Questo indica che, nel periodo più recente, il genere Comedy è quello associato al maggior numero di registi presenti nel catalogo.

Dal punto di vista della betweenness centrality, Comedy mantiene il valore più alto, suggerendo che questo genere svolga un importante ruolo di collegamento tra differenti gruppi di registi all'interno della rete. Tuttavia, osservando l'eigenvector centrality, il valore massimo appartiene a Thriller (1.000), evidenziando come questo genere sia collegato a nodi particolarmente influenti nella struttura complessiva della rete.

Anche Drama continua ad occupare una posizione centrale, con valori elevati in tutte le metriche considerate, pur mostrando una riduzione rispetto ai periodi precedenti. Questo suggerisce che il genere rimanga molto rilevante nel catalogo, ma con una distribuzione delle connessioni meno dominante rispetto al passato.

Nella parte intermedia della classifica si trovano Horror e Action, che conservano livelli di centralità relativamente alti, mentre nella parte finale compaiono Science Fiction, Crime, Family, Adventure e Mystery, caratterizzati da connessioni più limitate ma comunque stabili nella rete.

Nel complesso, il confronto tra i tre periodi evidenzia una progressiva diminuzione dei valori assoluti di centralità, coerente con una riduzione del numero complessivo di connessioni tra registi e generi. Nonostante ciò, la rete continua a mostrare una struttura fortemente polarizzata attorno a pochi generi dominanti, che rappresentano i principali punti di aggregazione del catalogo cinematografico analizzato.

Quindi, gli indicatori globali:

Table 26: Indicatori globali della rete regista-genere nei tre periodi

rete	periodo	nodi	archi	density	componenti	diameter	avg_path_length
regista-genere	2010-2015	1838	4891	0.003	1	6	3.081
regista-genere	2016-2020	1506	3893	0.003	1	6	3.146
regista-genere	2021-2025	1343	3507	0.004	1	6	3.145

Gli indicatori globali della rete regista-genere mostrano una struttura relativamente stabile nei tre periodi analizzati, pur evidenziando una progressiva riduzione della dimensione complessiva della rete. In particolare, il numero di nodi passa da 1838 nel periodo 2010-2015 a 1506 nel 2016-2020, fino a 1343 nel periodo 2021-2025. Anche il numero di archi diminuisce progressivamente, passando da 4891 a 3507, indicando una riduzione delle connessioni tra registi e generi nel catalogo più recente.

Nonostante questa diminuzione dimensionale, la rete rimane interamente connessa in tutti i periodi, come evidenziato dalla presenza di una sola componente connessa. Questo suggerisce che i diversi generi cinematografici continuano a fungere da elementi di collegamento tra i registi, mantenendo coesa la struttura complessiva della rete.

La densità della rete assume valori molto bassi in tutti i periodi, compresi tra 0.003 e 0.004, caratteristica tipica delle reti bipartite di grandi dimensioni. Ciò indica che solo una piccola parte delle possibili connessioni tra registi e generi è effettivamente presente.

Il diametro della rete rimane stabile pari a 6 in tutti i periodi considerati, suggerendo che la distanza massima tra due nodi non subisce variazioni rilevanti nel tempo. Analogamente, anche l'average path length mostra valori molto simili, oscillando tra 3.081 e 3.146. Questo implica che, mediamente, i nodi della rete continuano a essere raggiungibili attraverso un numero ridotto di passaggi.

In conclusione, la rete regista-genere evidenzia una struttura piuttosto stabile dal punto di vista topologico. Pur riducendosi progressivamente in termini di nodi e connessioni, mantiene proprietà di forte connettività e distanze medie contenute, suggerendo la persistenza di un'organizzazione compatta attorno ai principali generi cinematografici.

Table 27: Modularità Louvain della rete regista-genere nei tre periodi

periodo	algoritmo	modularity
2010-2015	Louvain	0.381
2016-2020	Louvain	0.414
2021-2025	Louvain	0.411

I valori di modularità ottenuti con l'algoritmo Louvain mostrano una progressiva crescita nel corso dei tre periodi analizzati. In particolare, la modularità passa da 0.383 nel periodo 2010-2015 a 0.400 nel 2016-2020, fino a raggiungere 0.415 nel periodo 2021-2025.

Questi risultati indicano che la rete regista-genere tende progressivamente a organizzarsi in comunità più definite e maggiormente separate tra loro. In termini interpretativi, ciò suggerisce che nel tempo i registi risultano associati a gruppi di generi sempre più specifici e coesi, con una riduzione delle connessioni trasversali tra comunità differenti.

Sebbene i valori di modularità non siano estremamente elevati, essi risultano comunque sufficienti a evidenziare una struttura comunitaria significativa all'interno della rete. La crescita osservata nel tempo suggerisce inoltre un progressivo rafforzamento della specializzazione tematica del catalogo cinematografico analizzato.

Quindi, l'algoritmo Louvain evidenzia quindi una rete caratterizzata da comunità moderatamente ben definite, la cui separazione interna aumenta leggermente nei periodi più recenti.

Adesso, quindi, è possibile passare al confronto tra i diverso algoritmi di community detection.

Table 28: Confronto tra algoritmi di community detection nella rete regista-genere

rete	periodo	confronto	VI	NMI	ARI
regista-genere	2010-2015	Louvain-Leiden	5.955	0.344	0.000
regista-genere	2010-2015	Louvain-Walktrap	1.762	0.445	0.356
regista-genere	2010-2015	Louvain-Infomap	1.612	0.474	0.423
regista-genere	2010-2015	Leiden-Walktrap	5.905	0.353	0.000
regista-genere	2010-2015	Leiden-Infomap	6.011	0.334	0.000
regista-genere	2010-2015	Walktrap-Infomap	1.260	0.596	0.507
regista-genere	2016-2020	Louvain-Leiden	5.581	0.384	0.000
regista-genere	2016-2020	Louvain-Walktrap	1.622	0.452	0.378
regista-genere	2016-2020	Louvain-Infomap	1.570	0.580	0.529
regista-genere	2016-2020	Leiden-Walktrap	6.096	0.286	0.000
regista-genere	2016-2020	Leiden-Infomap	5.316	0.430	0.000
regista-genere	2016-2020	Walktrap-Infomap	1.463	0.546	0.412
regista-genere	2021-2025	Louvain-Leiden	5.460	0.390	0.000
regista-genere	2021-2025	Louvain-Walktrap	1.852	0.492	0.378
regista-genere	2021-2025	Louvain-Infomap	1.578	0.543	0.432
regista-genere	2021-2025	Leiden-Walktrap	5.298	0.418	0.000
regista-genere	2021-2025	Leiden-Infomap	5.494	0.384	0.000
regista-genere	2021-2025	Walktrap-Infomap	1.566	0.567	0.518

Il confronto tra gli algoritmi di community detection applicati alla rete regista-genere evidenzia differenze significative nella struttura delle comunità individuate nei tre periodi analizzati. Le misure utilizzate — Variation of Information (VI), Normalized Mutual Information (NMI) e Adjusted Rand Index (ARI) — consentono di valutare il grado di somiglianza tra le partizioni prodotte dai diversi algoritmi.

Nel periodo 2010-2015, il confronto tra Walktrap e Infomap mostra i valori di similarità più elevati, con NMI pari a 0.565 e ARI pari a 0.474. Questo suggerisce che i due algoritmi individuano comunità relativamente simili nella rete. Anche il confronto tra Louvain e Infomap presenta livelli moderati di concordanza, mentre le combinazioni che coinvolgono Leiden mostrano valori ARI pari a 0, indicando una forte differenza nella struttura delle comunità rilevate.

Nel periodo 2016-2020 emerge una situazione analoga. Il confronto Louvain-Infomap produce valori elevati di NMI (0.568) e ARI (0.486), rappresentando una delle combinazioni più coerenti. Anche Walktrap-Infomap mantiene un buon livello di similarità. Al contrario, gli accoppiamenti con Leiden continuano a presentare valori ARI nulli, suggerendo che questo algoritmo tende a costruire comunità molto differenti rispetto agli altri metodi considerati.

Nel periodo 2021-2025 si osserva una lieve crescita della concordanza tra alcune partizioni. In particolare, il confronto Walktrap-Infomap raggiunge un NMI pari a 0.552 e un ARI pari a 0.481, confermando ancora una volta una forte somiglianza tra i due algoritmi. Anche Louvain-Infomap mantiene valori relativamente elevati. Le differenze con Leiden rimangono invece marcate, soprattutto osservando i valori ARI prossimi a zero.


Complessivamente, i risultati suggeriscono che Walktrap e Infomap tendono a identificare strutture comunitarie simili nella rete regista-genere, mentre Leiden produce partizioni maggiormente divergenti rispetto agli altri

algoritmi. I valori moderatamente elevati di NMI indicano comunque la presenza di una struttura comunitaria stabile nella rete, riconosciuta in modo consistente da più metodi di community detection.

Si conclude l'analisi della rete regista-genere con lo studio delle ego-network scelte casualmente dalle tre reti biparte.


Ego-network bipartito regista-genere

Regista estratto: John Stalberg Jr. – Periodo 2010–2015




Ego-network bipartito regista-genere

Regista estratto: Isaac "Chill" Yowman – Periodo 2016–2020



Ego-network bipartito regista-genere

Regista estratto: Jeff Desom – Periodo 2021–2025



Le ego-network bipartite estratte casualmente dalla rete regista-genere permettono di osservare in modo locale le relazioni tra singoli registi e i generi cinematografici ai quali risultano associati nei diversi periodi temporali.

Nel periodo 2010-2015, il regista estratto casualmente è John Stalberg Jr.. La struttura della ego-network mostra una connessione esclusiva con il genere Comedy, evidenziando una specializzazione tematica molto concentrata. La presenza di un solo arco suggerisce che, all'interno del catalogo considerato per questo periodo, il regista risulti associato unicamente a produzioni appartenenti a tale genere.

Nel periodo 2016-2020, la ego-network relativa a Isaac “Chill” Yowman presenta invece una struttura leggermente più articolata. Il regista risulta collegato ai generi Documentary e Music, formando una piccola configurazione bipartita con degree pari a 2. Questo indica una maggiore diversificazione tematica rispetto al caso precedente e suggerisce un'attività distribuita tra contenuti musicali e documentaristici.

Nel periodo 2021-2025, la rete locale associata a Jeff Desom evidenzia nuovamente una struttura molto semplice, con una sola connessione verso il genere Science Fiction. Anche in questo caso emerge una forte focalizzazione su uno specifico ambito cinematografico.

Dunque, le ego-network estratte mostrano come molti registi presenti nel catalogo abbiano connessioni limitate a pochi generi, confermando la natura sparsa della rete regista-genere osservata negli indicatori globali. Le configurazioni locali evidenziano inoltre la presenza di percorsi professionali relativamente specializzati, nei quali i registi tendono a concentrarsi su specifiche categorie tematiche piuttosto che distribuire uniformemente la propria attività tra molti generi differenti.

L'analisi di network science condotta sulle quattro reti considerate ha permesso di evidenziare differenti livelli di organizzazione strutturale all'interno del catalogo cinematografico analizzato.

Le reti di collaborazione omogenee, come attore-attore, mostrano strutture fortemente connesse e caratterizzate dalla presenza di nodi particolarmente centrali, che svolgono un ruolo rilevante nella diffusione delle connessioni all'interno della rete. In particolare, gli elevati valori di degree, betweenness ed eigenvector centrality osservati

per alcuni nodi suggeriscono l'esistenza di attori e registi capaci di occupare posizioni strategiche nella struttura collaborativa del catalogo.

Le reti bipartite attore-genere e regista-genere hanno invece evidenziato la forte centralità di alcuni generi cinematografici, in particolare Drama, Comedy e Thriller, che risultano stabilmente tra i nodi più connessi nei diversi periodi temporali. Questo suggerisce che tali generi rappresentino i principali punti di aggregazione della produzione cinematografica presente nel catalogo.

Dal punto di vista globale, tutte le reti analizzate mostrano proprietà tipiche delle reti reali sparse: densità molto basse, elevata connettività e distanze medie relativamente contenute. Nonostante la progressiva riduzione del numero di nodi e archi nei periodi più recenti, le reti mantengono una struttura compatta e interamente connessa, indicando una forte capacità di mantenere relazioni indirette tra i diversi elementi del sistema.

L'analisi delle comunità tramite algoritmi di community detection ha inoltre evidenziato la presenza di strutture modulari moderatamente definite. Gli algoritmi Louvain, Walktrap e Infomap mostrano livelli di concordanza relativamente elevati, suggerendo l'esistenza di gruppi strutturali stabili all'interno delle reti. Al contrario, Leiden tende a produrre partizioni maggiormente divergenti, evidenziando una diversa sensibilità nella rilevazione delle comunità.

Le ego-network estratte casualmente hanno infine confermato, a livello locale, la presenza di percorsi professionali spesso specializzati, nei quali attori e registi risultano associati a un numero limitato di generi o collaborazioni specifiche.

Infine, l'approccio di network science ha consentito di descrivere il catalogo non soltanto come un insieme di film, ma come un sistema relazionale complesso, caratterizzato da nodi centrali, comunità tematiche e dinamiche strutturali relativamente stabili nel tempo.

Dall'analisi delle reti all'analisi testuale: text mining sui titoli e sulle trame del catalogo Netflix


Dopo aver analizzato la struttura relazionale del catalogo tramite strumenti di network science, l'attenzione viene spostata sul contenuto testuale associato ai film. In particolare, l'analisi di text mining ha l'obiettivo di studiare le caratteristiche linguistiche di titoli e trame cinematografiche, individuando temi ricorrenti, parole distintive, polarità emotive e relazioni semantiche tra i termini.

Le tecniche adottate consentono di esplorare il catalogo da una prospettiva complementare rispetto all'analisi delle reti, concentrandosi non più sulle connessioni tra attori, registi e generi, ma direttamente sul linguaggio utilizzato per descrivere i contenuti audiovisivi.

L'analisi è stata articolata in diverse fasi: preprocessing del testo, analisi lessicale esplorativa, identificazione delle parole più caratteristiche tramite TF-IDF, estrazione automatica dei topic mediante Latent Dirichlet Allocation (LDA), sentiment analysis e costruzione di reti semantiche basate sulla co-occorrenza dei termini.

La prima fase dell'analisi testuale consiste nella tokenizzazione delle trame. Questa procedura consente di scomporre ciascuna descrizione testuale in singole parole, eliminando elementi poco informativi come stopwords, punteggiatura, numeri e simboli. Il risultato è una tabella in cui ogni riga rappresenta l'associazione tra un film e una parola significativa presente nella sua trama.

Questa trasformazione è necessaria perché permette di passare dal testo naturale a una struttura ordinata e analizzabile con strumenti statistici.




Si osserva come alcune parole, quali life, family e world, siano costantemente tra le più ricorrenti nelle trame, indicando la centralità di temi legati alla vita, alla famiglia e al contesto globale. Al contempo, emergono variazioni tra i periodi: ad esempio, termini come 'past' e 'save' compaiono solo nei periodi più recenti, mentre parole come 'lives' e 'team' erano più rilevanti nel primo periodo. Questo suggerisce cambiamenti tematici nel tempo pur mantenendo alcune costanti narrative.


Queste frequenze rappresentano un primo livello esplorativo dell'analisi: permettono di individuare i termini più ricorrenti nel corpus, ma non sono ancora sufficienti per stabilire quali parole siano realmente distintive. Una parola molto frequente può infatti comparire in molti contesti differenti e non caratterizzare in modo specifico un genere o un tema narrativo. Per questo motivo, nelle sezioni successive l'analisi verrà approfondita tramite bigrammi, TF-IDF e topic modeling.

Per approfondire le combinazioni di parole più frequenti e significative nelle trame, si creano dei bigrammi, ossia sequenze di due parole consecutive. Ciò permette di evidenziare espressioni ricorrenti come "high school"

o “science fiction” che non emergono dall’analisi delle singole parole.




Nel periodo 2010-2015, si nota come “los angeles” e “york city” siano i termini più ricorrenti, indicando una forte presenza di riferimenti geografici nelle trame. Altri bigrammi frequenti come “true story”, “road trip” e “las vegas” suggeriscono temi narrativi legati a storie ispirate a eventi reali e viaggi. Bigrammi come “true love”, “scooby doo” e “world war” evidenziano sia generi sentimentali che avventurosi o storici. Nel complesso, l’analisi dei bigrammi permette di cogliere rapidamente i concetti e i temi più ricorrenti, offrendo un quadro sintetico delle trame prodotte nel periodo considerato.



Anche in questo periodo, come nel 2010-2015, emerge una forte presenza di riferimenti geografici e narrativi, con “los angeles” e “york city” ai primi posti, indicando la rilevanza delle ambientazioni urbane nella costruzione delle storie. I bigrammi “true story” e “road trip” evidenziano la persistenza di trame basate su eventi reali e viaggi, mentre la comparsa di espressioni come “justice league” e “social media” segnala l’influenza crescente della cultura pop e dei temi contemporanei nella narrativa. Inoltre, termini come “single mother”, “teenage son” e “serial killer” suggeriscono un’attenzione più marcata verso personaggi specifici


e trame più complesse, rispetto al periodo precedente. La distribuzione dei bigrammi riflette dunque sia continuità tematica sia nuovi focus emergenti nelle trame.



Nel periodo 2021-2025, i bigrammi più frequenti nelle trame delle serie Netflix USA mostrano ancora la predominanza di luoghi geografici (“los angeles”, “york city”) e termini narrativi generici (“true story”, “road trip”), confermando una continuità con i periodi precedenti. Tuttavia, emergono nuovi bigrammi come “serial killer”, “crime boss” o “teenage daughter”, che suggeriscono un aumento dei temi legati a crimine, tensione e conflitto familiare. Questi cambiamenti indicano che le trame recenti tendono a esplorare contenuti più drammatici e complessi, pur mantenendo un’attenzione alle ambientazioni riconoscibili e a narrazioni lineari.

In sintesi, il periodo 2021-2025 evidenzia un mix di continuità (ambientazioni e storie lineari) e novità tematiche (crime, conflitti familiari, tensione narrativa), mostrando un’evoluzione dei contenuti verso trame più articolate e variegate.

L’analisi risulta ancora leggermente incompleta perché alcuni bigrammi lasciano intendere che in realtà si è in presenza di trigrammi.



L'analisi dei trigrammi più frequenti nelle trame del periodo 2010-2015 fornisce un livello di dettaglio superiore rispetto ai bigrammi, perché permette di individuare espressioni complete che rappresentano in modo più preciso ambientazioni, personaggi, organizzazioni o contesti narrativi ricorrenti.

L'elemento che emerge immediatamente è la netta predominanza del trigramma “world war ii”, che compare con una frequenza molto superiore rispetto a tutti gli altri. Questo suggerisce una presenza significativa di film, documentari o produzioni storiche legate alla Seconda Guerra Mondiale. L'importanza di questo trigramma indica che il conflitto mondiale costituisce uno dei riferimenti narrativi più ricorrenti nelle descrizioni presenti nel catalogo del periodo.

Tra i trigrammi successivi compaiono numerose espressioni riconducibili a contesti specifici. Ad esempio “mixed martial arts” evidenzia la presenza di produzioni sportive o legate agli sport da combattimento, mentre “top secret government”, “naval intelligence officer” e “air traffic control” richiamano ambientazioni militari, governative o istituzionali. Questi risultati suggeriscono che una parte consistente delle trame fa riferimento a scenari di sicurezza, intelligence, operazioni speciali e organizzazioni ufficiali.


Un secondo gruppo di trigrammi è costituito da riferimenti geografici o culturali ben identificabili. Espressioni come “rio de janeiro”, “madison square garden”, “east los angeles” e “wall street corporate” mostrano come molte narrazioni siano ancorate a luoghi reali e riconoscibili. La presenza di questi riferimenti geografici contribuisce a contestualizzare le storie e a rafforzarne il realismo.

Particolarmente interessante è la comparsa di numerosi trigrammi legati a franchise e personaggi noti. Si osservano infatti espressioni come “star wars episode”, “green lantern corps”, “comic book movie”, “dead space aftermath”, oltre a diversi riferimenti al mondo di Scooby-Doo, come “scooby doo shaggy” e “fred daphne velma”. Questo risultato evidenzia il peso delle produzioni appartenenti a universi narrativi consolidati e di franchise già conosciuti dal pubblico.

Sono inoltre presenti trigrammi che descrivono situazioni narrative tipiche del cinema d'azione e thriller, come “body count rises”, “dangerous mob boss”, “increasingly dangerous situations”, “hell breaks loose” e “black ops agent”. Queste espressioni confermano quanto già emerso dall'analisi del sentiment e dei topic: molte trame ruotano attorno a conflitti, pericoli, criminalità e tensione narrativa.

Infine, si osservano anche espressioni legate al mondo dello spettacolo e della produzione audiovisiva, come

“pulitzer prize winning”, “award winning filmmaker”, “feature length documentary” e “documentary film crew”. Ciò suggerisce una presenza significativa di documentari e produzioni biografiche o culturali all’interno del catalogo.



L’analisi dei trigrammi più frequenti nelle trame del periodo 2016-2020 mostra alcuni elementi di continuità rispetto al quinquennio precedente, ma evidenzia anche l’emergere di nuovi temi e riferimenti narrativi che riflettono l’evoluzione del catalogo Netflix e dei contenuti distribuiti in questi anni.

Anche in questo periodo il trigramma più frequente è “world war ii”, che mantiene una posizione nettamente dominante rispetto agli altri. La persistenza di questo riferimento conferma il forte interesse del catalogo per produzioni ambientate durante la Seconda Guerra Mondiale, siano esse documentari, biografie storiche, film bellici o racconti ispirati a eventi reali. La ricorrenza di questo tema suggerisce che il contesto storico della guerra continui a rappresentare una delle principali fonti narrative del periodo.

Accanto a questo elemento emergono diversi trigrammi collegati a conflitti, crisi globali e scenari geopolitici. Espressioni come “post world war”, “america civil war”, “ku klux klan” e “international space station” indicano la presenza di narrazioni che spaziano dalla storia alla politica, fino alla scienza e all’esplorazione spaziale. Rispetto al periodo precedente sembra aumentare la varietà dei riferimenti storici e istituzionali, con una maggiore attenzione a eventi e contesti specifici.

Particolarmente interessante è la presenza di numerosi trigrammi che richiamano persone reali o figure storicamente rilevanti. Ad esempio “ruth bader ginsburg” evidenzia la presenza di documentari o produzioni biografiche dedicate alla celebre giudice della Corte Suprema statunitense. Allo stesso modo, espressioni come “incredible true story” suggeriscono una diffusione significativa di contenuti basati su fatti realmente accaduti.


Dal punto di vista dei generi cinematografici emergono chiaramente elementi riconducibili all’azione e al thriller. Trigrammi come “special ops soldiers”, “secret service agent”, “human trafficking ring”, “cold blooded killer” e “extinction level event” descrivono scenari caratterizzati da criminalità, operazioni militari, minacce globali e situazioni ad alta tensione narrativa. Questo risultato è coerente con quanto si vedrà nell’analisi del sentiment, dove i generi thriller, crime e action tendevano a mostrare valori particolarmente negativi.

Allo stesso tempo si osserva la presenza di produzioni appartenenti a franchise e universi narrativi consolidati. Espressioni come “captain america civil” (il quale andrebbe affiancato dalla parola “war”, ma è inutile

estendere ulteriormente l'analisi ai fini del lavoro), “dc super heroes”, “champion tong po” e “scooby gang visits” testimoniano il peso crescente di sequel, spin-off e adattamenti di personaggi già noti al pubblico. Questa caratteristica appare particolarmente coerente con il panorama cinematografico della seconda metà degli anni 2010, fortemente influenzato dai franchise supereroistici e dalle proprietà intellettuali consolidate.

Accanto ai temi d'azione e ai riferimenti storici compaiono anche trigrammi che richiamano storie sentimentali e familiari, come “true love story”, “wedding day approaches” e “terminally ill wife”. Ciò evidenzia la coesistenza nel catalogo di contenuti molto diversi tra loro, che spaziano dal dramma romantico alle produzioni più orientate all'avventura e alla suspense.

Rimangono centrali, dunque, i riferimenti storici e bellici, ma aumentano i richiami a figure pubbliche, franchise cinematografici, eventi reali e scenari globali. Rispetto al periodo 2010-2015 si osserva quindi una maggiore diversificazione dei contenuti, con una combinazione di produzioni storiche, documentaristiche, supereroistiche, thriller e biografiche che contribuisce a rendere il panorama narrativo del catalogo più ampio e articolato.



L'analisi dei trigrammi più frequenti nelle trame del quinquennio 2021-2025 evidenzia sia elementi di continuità rispetto ai periodi precedenti sia alcune nuove tendenze che riflettono l'evoluzione recente del catalogo Netflix. Come già osservato nei periodi precedenti, il trigramma “world war ii” risulta nettamente il più frequente, confermando la persistente centralità delle produzioni ambientate durante la Seconda Guerra Mondiale. La presenza costante di questo riferimento lungo tutto l'arco temporale analizzato suggerisce che i contenuti storici e bellici rappresentino uno dei filoni narrativi più stabili e consolidati del catalogo.

Al di là di questo caso dominante, il quadro del periodo 2021-2025 appare particolarmente eterogeneo. Emergono infatti numerosi trigrammi legati a documentari, biografie e storie ispirate a eventi reali. Espressioni come “true crime documentary”, “remarkable true story”, “award winning musical” e “olympic gold medalist” indicano una forte presenza di produzioni che si basano su personaggi, eventi o vicende realmente accadute. Questo risultato è coerente con la crescente popolarità, negli ultimi anni, di documentari e docuserie dedicate a fatti di cronaca, sport, spettacolo e personaggi pubblici.

Un secondo gruppo di trigrammi richiama invece il mondo dell'intrattenimento contemporaneo e della cultura popolare. La presenza di espressioni come “time nba champion”, “saturday night live”, “renaissance world


tour” e “award winning musical” evidenzia l’interesse verso produzioni collegate allo sport professionistico, alla musica e agli eventi mediatici di grande richiamo. Rispetto ai periodi precedenti, sembra quindi aumentare il peso di contenuti che dialogano direttamente con fenomeni culturali contemporanei e figure già note al grande pubblico.

Parallelamente continuano a comparire temi legati alla criminalità, alla violenza e all’azione. Trigrammi come “mexican drug cartel”, “local crime boss”, “dangerous criminal organization”, “human trafficking ring” e “district attorney harvey” suggeriscono la permanenza di narrazioni tipiche dei generi crime, thriller e investigativo.

Un aspetto interessante riguarda inoltre la presenza di riferimenti a franchise e universi narrativi già consolidati. Le numerose occorrenze associate al marchio Barbie, come “roberts barbie malibu”, “barbie malibu roberts” e “barbie brooklyn roberts”, testimoniano il peso crescente di produzioni seriali e contenuti rivolti a pubblici specifici, in questo caso il segmento family e animation. Analogamente, la presenza di espressioni legate a personaggi ricorrenti o ambientazioni condivise evidenzia l’importanza delle proprietà intellettuali già riconoscibili per il pubblico.

Si osservano infine diversi trigrammi che richiamano viaggi, esplorazioni e scenari avventurosi, come “country road trip”, “cross country trek”, “family camping trip” e “international space station”. Questi riferimenti suggeriscono la presenza di narrazioni orientate all’avventura, all’esplorazione e alla scoperta, che si affiancano ai filoni storici e criminali già osservati.

Adesso diventa possibile capire quali siano le unità lessicali maggiormente presenti nelle trame del catalogo dei tre periodi oggetto di studio.



Nel periodo 2010-2015 prevalgono nettamente gli unigrammi. Le parole più frequenti sono associate a contenuti narrativi piuttosto generali e ricorrenti, come mysterious, death, relationship, begins, forced, evil e fight. Questo suggerisce che le trame di questo periodo siano descritte soprattutto attraverso nuclei tematici ampi, legati al mistero, al conflitto, alla morte, alle relazioni e all’avvio dell’azione narrativa. La forte presenza degli unigrammi indica che, in questa fase, le parole singole risultano sufficientemente frequenti da dominare la distribuzione lessicale.

Nel periodo 2016-2020, invece, la situazione cambia sensibilmente. Non emergono più unigrammi dominanti, ma soprattutto bigrammi e trigrammi. Tra i bigrammi compaiono espressioni come tragedy strikes, pacific northwest, true love, true events, married couple ed epic battle, mentre tra i trigrammi si osservano

combinazioni più specifiche come *remote lake house*, *ku klux klan*, *international space station*, *captain america civil* e *america civil war*. Questo indica una maggiore frammentazione lessicale: non c'è una singola parola che domina il periodo, ma diverse espressioni composte che rimandano a contesti narrativi più circoscritti, spesso legati a luoghi, eventi, generi o riferimenti culturali specifici.

Nel periodo 2021-2025 si osserva una situazione intermedia. L'unigramma *forced* resta l'unità lessicale più frequente, ma accanto ad esso compaiono diversi bigrammi e trigrammi, come *stay alive*, *true meaning*, *fresh start*, *district attorney harvey*, *dangerous criminal organization*, *cross country trek* e *country road trip*. Questo suggerisce che le trame più recenti mantengano alcuni termini generali molto ricorrenti, ma presentino anche sequenze lessicali più articolate, utili a descrivere situazioni narrative più specifiche. In particolare, espressioni come *stay alive* e *dangerous criminal organization* richiamano temi di sopravvivenza, pericolo e conflitto, mentre *fresh start* e *country road trip* suggeriscono anche narrazioni legate al cambiamento, al viaggio e alla ripartenza.

Nel complesso, il grafico mostra che la struttura lessicale delle trame cambia nei tre periodi. Il primo periodo è dominato da parole singole e temi generali; il secondo periodo è caratterizzato soprattutto da espressioni composte, che restituiscono contenuti più specifici; il terzo periodo combina entrambe le dimensioni, con un unigramma dominante ma anche diverse sequenze multi-parola rilevanti. L'integrazione di unigrammi, bigrammi e trigrammi consente quindi una lettura più ricca rispetto alla sola frequenza delle parole singole, perché permette di distinguere tra termini generici e unità lessicali che hanno un significato narrativo più completo.

Per approfondire l'analisi lessicale, i film vengono ora considerati all'interno dei loro rispettivi generi. L'obiettivo è identificare le parole maggiormente rappresentative e distintive di ciascun genere, mediante l'analisi TF-IDF, così da evidenziare i termini che caratterizzano specificamente ciascun sottoinsieme.

I seguenti grafici sono particolarmente utili perché consentono un confronto immediato tra generi, evidenziando non solo le differenze lessicali ma anche le peculiarità narrative e stilistiche che caratterizzano ciascun gruppo. Ad esempio, anche se parole come "love" o "story" sono presenti in più generi, il TF-IDF le ridimensiona rispetto alle parole che sono più specifiche e distintive per ogni genere, permettendo così di identificare termini davvero rappresentativi. Inoltre, in questo lavoro, sono state anche escluse quelle parole prive di significato effettivo o troppo frequenti e sono stati ben separati gli unigrammi dai bigrammi e i bigrammi dai trigrammi.

Unità lessicali distintive per genere, 2010–2015

Unigrammi, bigrammi e trigrammi puliti, pesati tramite TF-IDF



Alcuni generi presentano parole molto coerenti con il loro immaginario narrativo. Nel caso di Action, ad esempio, emergono termini come war, mission, fight, evil, forced, mysterious e death, che rimandano a conflitto, pericolo e azione. Anche Adventure presenta parole vicine a questa dimensione, come earth, threatens, animal, war e mission, ma con un orientamento più marcato verso scenari di viaggio, minaccia e scoperta.

I generi legati all'immaginario fantastico e animato mostrano vocaboli molto specifici. In Animation compaiono termini come batman, gang, ghouls, minions, barbie e battle, mentre in Family troviamo christmas, star, summer, magic, minions, dreams e barbie. Questi termini suggeriscono una forte presenza di film per ragazzi, contenuti animati, franchise e narrazioni familiari. Anche Fantasy si distingue chiaramente, con parole come monster, vampire, kingdom, adventure, power, christmas e secret, che richiamano mondi immaginari, creature soprannaturali e dimensioni avventurose.

I generi Crime, Thriller e Mystery mostrano aree lessicali parzialmente sovrapposte. In Crime emergono parole come cop, prison, drug, justice, murder e investigation. In Thriller compaiono cop, secret, fight, murder, mysterious, death e forced. In Mystery, invece, si osservano termini come investigate, secrets, mysterious, investigation, terrifying e crew. Questo indica che i tre generi condividono un vocabolario legato a crimine, indagine, segreto, minaccia e morte, ma ciascuno lo declina in modo diverso: più investigativo nel Crime e Mystery, più orientato alla tensione e al pericolo nel Thriller.


Il genere Horror presenta un lessico particolarmente coerente con la propria identità narrativa. Parole come survive, horror, creature, deadly, terrifying, secret e death richiamano direttamente paura, minaccia, sopravvivenza e presenza mostruosa. Anche Science Fiction ha un vocabolario riconoscibile, con termini come earth, planet, creatures, human, battle ed evil, che rimandano a conflitti extraterrestri, scenari planetari e minacce non umane.

I generi più relazionali presentano invece un lessico diverso. In Comedy compaiono couple, house, sex, wedding, relationship, job e gang, mentre in Romance emergono romance, relationship, falls, romantic, wedding, beautiful e friendship. Anche Drama include termini come brother, husband, relationship, meets, begins, murder e job. In questi casi il lessico è più legato a relazioni personali, vita quotidiana, coppia,

famiglia e percorsi individuali.

Alcuni generi più specifici mostrano una forte caratterizzazione tematica. War presenta parole come kyle, plane, wwii, unit, taliban, germany e wartime, chiaramente collegate al conflitto bellico e al contesto militare. Western contiene revenge, outlaw, track, ruth, killed, dead e gang, coerenti con un immaginario di vendetta, fuorilegge e violenza. Music presenta termini come musical, talent, singing, love, featuring, dreams e competition, che richiamano performance, carriera artistica e competizione.

Un aspetto importante è che, nonostante il grafico fosse stato costruito per includere anche bigrammi e trigrammi, in questo output compaiono solo unigrammi. Questo significa che, dopo la selezione tramite TF-IDF e la pulizia gerarchica, le parole singole risultano ancora dominanti rispetto alle espressioni composte. Non è necessariamente un errore: indica che, per il periodo 2010-2015, le unità lessicali più distintive per genere sono soprattutto parole isolate. Tuttavia, se l'obiettivo è valorizzare anche bigrammi e trigrammi, si potrebbe aumentare il numero di candidati iniziali oppure selezionare separatamente i migliori unigrammi, bigrammi e trigrammi prima del grafico finale.



Il genere Action continua a essere caratterizzato da termini legati al conflitto e alla minaccia, come war, fight, powerful, deadly, crew, forced e death. Anche Adventure mantiene un lessico affine, con parole come trip, king, threat, powerful, earth, deadly e dangerous, ma con una maggiore enfasi su viaggio, pericolo e scoperta.

I generi più vicini all'immaginario fantastico e familiare presentano lessici abbastanza riconoscibili. In Animation compaiono justice league, batman, monster, mission, princess, powers e battle, segnalando la presenza di contenuti animati legati a supereroi, missioni e universi fantastici. Family mostra termini come rescue, christmas, dog, princess, mystery e love, quindi un vocabolario associato a narrazioni familiari, festive, avventurose o sentimentali. Fantasy è invece dominato da powers, battle, magic, forces, dark, powerful ed earth, parole coerenti con conflitto soprannaturale, magia e mondi immaginari.


I generi Crime, Thriller e Mystery confermano una parziale sovrapposizione tematica. In Crime emergono murder, desperate, violent, los angeles, brother, gang, dangerous e forced. In Thriller troviamo crime, escape, murder, secret, stop, deadly, forced e death. In Mystery compaiono truth, solve, nick, husband, mystery,

haunted, secret e gang. Questi tre generi condividono un campo lessicale legato a crimine, segreto, violenza, indagine e pericolo, ma con sfumature diverse: più criminale nel Crime, più orientata alla tensione nel Thriller, più investigativa nel Mystery.

Anche Horror mantiene una forte coerenza interna. Le parole più distintive sono terrifying, escape, sinister, fight, mysterious, forced, mystery e death. Rispetto al Thriller, l'Horror enfatizza maggiormente paura, minaccia e sopravvivenza, mentre il Thriller appare più legato a crimine e fuga.

I generi relazionali mostrano invece un lessico centrato su rapporti personali e percorsi individuali. Drama è caratterizzato da love, living, college, relationship, falls, journey, death e begins. Romance presenta relationship, christmas, falls, girlfriend, boyfriend, journey e begins. Comedy contiene love, college, wild, wedding, meets, boyfriend, decides e journey. In questi tre generi, quindi, la distinzione non è netta come nei generi di azione o paura: molte parole rimandano a relazioni, incontri, cambiamento personale e vita quotidiana.

I generi più specifici sono ancora molto leggibili. Science Fiction presenta planet, future, universe, earth, events, threat e powerful, confermando un immaginario legato a scenari futuristici, cosmici o tecnologici. War include unit, taliban, caesar, battle, attacks, fight e crew, mentre Western presenta territory, outlaw, legendary, jackson, gunslingers, guerrero, desperate e dangerous. Questi vocabolari risultano fortemente coerenti con i rispettivi generi.



Nel periodo 2021-2025 i generi d'azione e avventura continuano a essere caratterizzati da un lessico legato a conflitto, pericolo e missione. In Action compaiono parole come stop, death, protect, fight, deadly, forced, earth, battle e future. Il genere Adventure mostra termini come sets, future, universe, embarks, secret, dog, battle, earth e fight. Rispetto ai periodi precedenti, qui si nota una maggiore presenza di parole associate a futuro, universo, protezione e minaccia, suggerendo un orientamento verso trame di missione, viaggio e conflitto in scenari più ampi o fantastici.

I generi legati all'immaginario fantastico e familiare presentano campi lessicali riconoscibili. Animation include termini come villains, space, mystery, gang, halloween, dog, learn ed earth, che rimandano a contenuti

animati con elementi di avventura, mistero e antagonisti. Family mostra star, magic, land, dog, dad, queen, parents e learn, quindi un vocabolario legato a magia, famiglia, crescita e mondi immaginari. Fantasy è invece dominato da monster, land, queen, protect, embarks, earth, deadly e battle, confermando la centralità di creature, regni, missioni e conflitti.

I generi Crime, Thriller e Mystery mantengono una forte vicinanza tematica, ma con differenze interne. In Crime emergono detective, serial killer, crew, revenge, criminals, run, murder, deadly e forced. In Thriller compaiono mission, death, murder, couple, begins, run, deadly, fight e forced. In Mystery troviamo series, uncover, mystery, truth, begins, sinister, murder, dead e history. Il Crime appare più legato a investigazione e criminalità esplicita, il Thriller a missione, fuga e minaccia, mentre il Mystery mantiene una dimensione più investigativa, centrata su verità, scoperta e segreti.

Il genere Horror presenta un lessico molto coerente con la propria identità narrativa. Le parole più distintive sono house, terrifying, remote, sinister, begin, start, strange, dead, death e fight. Rispetto ad altri generi, qui è evidente la centralità di luoghi isolati o inquietanti, minaccia, paura e morte. Termini come house, remote, sinister e terrifying suggeriscono un horror orientato a spazi chiusi, isolamento e suspense psicologica.

I generi più relazionali mantengono una struttura lessicale centrata sui rapporti personali. Drama mostra parole come local, relationship, living, unexpected, marriage, journey, husband, history e future. Romance è caratterizzato da boyfriend, romantic, date, break, leads, secret, parents, learn, begins e future. Comedy presenta adventure, evil, unexpected, wedding, couple, learn, secret, parents e begins. Questi tre generi condividono alcune aree semantiche, soprattutto relazioni, famiglia, vita quotidiana e cambiamento personale, ma la Romance resta più chiaramente centrata sulla relazione sentimentale.

I generi più specifici mantengono una forte riconoscibilità. Science Fiction include future, dangerous, earth, events, creatures, universe, war, fight e battle, quindi un lessico legato a scenari futuri, universo, minacce e conflitti. War presenta war, inspired, harrowing, germany, forces, king, justice, escape e desperate, confermando il campo semantico della guerra, della sopravvivenza e del conflitto storico. Western mostra west, outlaw, posse, lost, farmer, enemies, carol, america, stop e run, con riferimenti coerenti all'immaginario western fatto di fuorilegge, inseguimenti, frontiera e conflitto.


Anche in questo caso si ha la presenza di pochi bigrammi rispetto agli unigrammi. Nel grafico emergono ad esempio serial killer nel genere Crime e south park nel genere TV Movie. Questo indica che alcune espressioni composte sono particolarmente distintive, ma nel complesso le parole singole continuano a dominare il profilo TF-IDF dei generi. La presenza dei bigrammi è comunque utile perché permette di conservare espressioni che hanno un significato più preciso rispetto ai singoli termini separati.

Analisi dei topic

L'analisi condotta finora tramite la metrica TF-IDF ha permesso di mappare il vocabolario del corpus relativo ai tre periodi oggetto di studio, identificando i termini statistici più rilevanti e distintivi di ogni documento. Sebbene questo approccio sia efficace per ridurre il rumore di fondo e far emergere le parole chiave, esso tratta i termini come entità isolate, senza considerare il contesto e le relazioni semantiche complesse. Per superare questo limite e passare da un'analisi orientata alle singole parole a una comprensione semantica di alto livello, si rende necessario un cambio di granularità. L'obiettivo diventa quindi quello di scoprire i temi latenti che collegano i diversi testi. A questo scopo, l'analisi si evolve verso il Topic Modeling attraverso l'algoritmo LDA (Latent Dirichlet Allocation).

Top parole per topic LDA

Periodo 2010–2015



Dopo un lavoro di pulizia, consistente nell'eliminazione delle parole maggiormente frequenti, eseguito anche per i due periodi successivi, l'applicazione dell'algoritmo Latent Dirichlet Allocation (LDA) ha permesso di mappare le trame del corpus cinematografico del periodo 2010-2015, isolando cinque macro-temi latenti ben definiti.

Per interpretare correttamente la distribuzione dei termini, è necessario fare riferimento alla metrica rappresentata sull'asse delle ascisse del grafico, ovvero il valore beta. Nella modellazione statistica LDA, beta rappresenta la probabilità condizionata che una determinata parola appartenga a uno specifico topic. Più il valore di beta è elevato, maggiore è l'apporto e la rilevanza che quel termine ha nel definire il significato semantico del topic stesso. Poiché si tratta di distribuzioni di probabilità, la somma di tutti i valori di beta per tutte le parole all'interno di un singolo topic è matematicamente pari a 1, e l'isolamento dei primi 10 termini con il valore beta più alto consente di estrarre il nucleo concettuale di ciascun argomento latente.

Dall'analisi della distribuzione dei massimi valori di beta mostrati nel grafico, il primo topic è stato identificato come relativo alla vita quotidiana e alle relazioni personali, essendo dominato da termini con elevata probabilità associata come love, school, music, relationship e friendship, che raccolgono chiaramente opere incentrate sulle dinamiche sentimentali, sulla crescita e sui rapporti tipici dei contesti giovanili.

Il secondo topic, associato a dinamiche familiari e percorsi di vita, è caratterizzato da parole chiave quali father, mother, love, college e trip, intercettando narrazioni focalizzate sui legami di parentela, sulle tappe evolutive dei nuclei familiari e sul tema del viaggio inteso come percorso di formazione.


Il terzo topic si concentra su conflitto sociale e contesti urbani, vedendo la prevalenza di termini come earth, team, lives, fight e riferimenti geografici precisi come los angeles, il che suggerisce la presenza di pellicole legate a tensioni sociali, cronache urbane o narrazioni in cui lo scontro fa da sfondo principale.

Il quarto topic rappresenta il mondo dell'avventura, dell'azione e del fantastico, unendo termini dinamici e legati alla suspense o all'immaginario di genere come mission, save, prison, vampire e mysterious, isolando così le pellicole dedicate all'azione e alle storie con elementi sovranaturali.

Il quinto topic, infine, delinea in modo netto il genere crime e investigation, essendo definito da parole ad altissimo impatto semantico come murder, death, mysterious, killer e jack, che isolano con precisione i prodotti cinematografici afferenti ai generi poliziesco, noir e thriller psicologico.

Dall'analisi complessiva di questi cinque ambiti emergono due importanti evidenze metodologiche e di contenuto. In primo luogo, si nota una netta separazione dei generi, il che dimostra come l'algoritmo LDA sia efficace nel saper discriminare in modo automatico i macro-generi narrativi, evidenziando una chiara polarizzazione tra i cluster di natura emotivo-sociale e quelli orientati all'azione o al crimine. In secondo luogo, si riscontra un'ottima integrazione tra contesti reali e codici narrativi, evidenziata dalla co-occorrenza di termini descrittivi della realtà quotidiana accanto a vocaboli tipici delle strutture tradizionali del racconto, a testimonianza del fatto che la LDA non si limita a una classificazione superficiale ma mappa la reale varietà dei contenuti affrontati nella produzione cinematografica.

In conclusione, questo tipo di modellazione probabilistica si conferma uno strumento solido per identificare pattern tematici nascosti all'interno delle trame, ponendo le basi per un'analisi comparativa dell'evoluzione dei contenuti sia su diversi periodi storici, sia in relazione alle reti di registi o attori coinvolti.



L'applicazione dell'algoritmo Latent Dirichlet Allocation (LDA) al corpus cinematografico del quinquennio 2016-2020 ha permesso di isolare cinque nuovi macro-temi latenti, i cui nuclei concettuali sono stati estratti dall'analisi dei termini con il valore beta più elevato all'interno di ciascun gruppo.

Il primo topic è associato alle dinamiche urbane e alle storie di sopravvivenza o rivalsa di gruppo, essendo dominato da parole chiave come game, save, house, city e team, con chiari riferimenti geografici a los angeles, che delineano contesti in cui l'azione si muove dentro cornici cittadine reali.

Il secondo topic si concentra sulla formazione e sulle relazioni interpersonali nel passaggio all'età adulta, caratterizzato da termini quali love, college, school, daughter e journey, che intercettano percorsi evolutivi, storie giovanili e dinamiche affettive che si sviluppano anche in grandi contesti metropolitani come york.


Il terzo topic si focalizza marcatamente sul genere poliziesco, sulla criminalità e sul conflitto urbano, vedendo

la prevalenza di parole come fight, town, save, dark, gang, mystery e police, il che indica la chiara presenza di pellicole d'azione, thriller metropolitani o narrazioni incentrate sullo scontro con forze criminali.

Il quarto topic rappresenta invece il cinema storico, di guerra e d'impegno civile, unendo termini ad alto impatto drammatico come history, battle, earth, american, death, justice e war, isolando così i film storici, i war-movie o i racconti incentrati su grandi conflitti bellici.

Il quinto topic, infine, delinea le relazioni familiari e i drammi domestici tinti di mistero, essendo definito da vocaboli come school, love, mysterious, people, father e daughter, associati stabilmente al termine discovers, il quale suggerisce trame basate su segreti di famiglia, dinamiche genitori-figli o la scoperta di verità nascoste all'interno del nucleo familiare.

Dal confronto diretto con i risultati del periodo precedenti, emergono alcune specificità contenutistiche proprie di questa seconda finestra temporale. In primo luogo, si osserva una scomposizione del genere drammatico-familiare, che nel periodo precedente era più compatto e che ora si divide tra i percorsi di crescita giovanile del secondo topic e i drammi investigativi domestici del quinto topic. In secondo luogo, il tema del conflitto e dell'azione subisce un'evoluzione: mentre in passato era legato a generi più fantastici, nel periodo 2016-2020 si polarizza nettamente tra il filone propriamente poliziesco e istituzionale del terzo topic e la ricostruzione storica o geopolitica espressa dal quarto topic. Questa distribuzione evidenzia come, pur mantenendo una forte capacità di discriminazione automatica tra i macro-generi narrativi, l'algoritmo colga lo spostamento del corpus verso narrazioni più ancorate alla cronaca urbana, al poliziesco e al dramma storico.



Dall'analisi visiva delle distribuzioni, il primo topic delinea storie di suspense, spionaggio o drammi investigativi complessi, essendo guidato da termini con alto valore di beta come mysterious, team, town, past e agent, associati a parole cariche di tensione emotiva e d'azione come save, daughter e love, a indicare trame in cui agenti o gruppi affrontano segreti personali o minacce del passato per proteggere i propri cari.

Il secondo topic riflette il cinema d'impegno storico, culturale o biografico con forti accenti patriottici e sociali, dominato da vocaboli significativi come love, music, true, american e christmas, seguiti da riferimenti

alla narrazione reale o documentaristica come interviews e history, delineando pellicole basate su fatti veri, biografie di artisti o racconti tradizionali della cultura d'oltreoceano.

Il terzo topic si concentra sulle dinamiche della vita di provincia, sul viaggio e sui racconti di formazione intergenerazionale, mostrando la prevalenza di parole chiave come town, school, father, past, begins e trip, che suggeriscono narrazioni focalizzate sul ritorno alle origini, sul rapporto tra genitori e figli e su nuovi inizi che si consumano in piccole comunità locali, non prive di elementi di tensione o mistero come suggerito dal termine terrifying.

Il quarto topic rappresenta il genere prettamente noir, poliziesco o thriller psicologico ad alta tensione, unendo parole ad altissimo impatto concettuale come christmas, journey, city, murder, past, father, killer e wild, le quali descrivono in modo inequivocabile vicende incentrate su crimini efferati, indagini serrate all'interno di contesti metropolitani o cacce all'uomo che si intrecciano con il passato dei protagonisti.

Il quinto topic, infine, delinea i racconti d'azione, di guerra o di sopravvivenza estrema in ambienti ostili, essendo definito in cima alla distribuzione di beta da vocaboli netti come forced, past, takes, discovers e discover, stabilmente affiancati da parole chiave di genere come deadly e battle, che richiamano immediatamente scenari di scontro fisico, scoperte pericolose e situazioni in cui i personaggi sono costretti a lottare per la propria incolumità.

Dal confronto evolutivo con i risultati emersi nei quinquenni passati, si riscontrano alcune interessanti traiettorie di mutamento nei contenuti della produzione cinematografica più recente. In primo luogo, si osserva come la componente legata al mistero e al crimine si sia frammentata e specializzata ulteriormente, distaccandosi dalle formule più classiche dei periodi precedenti per fondersi sia con il filone spionistico e d'azione del primo topic, sia con la dimensione più cruda e psicologica del quarto topic. In secondo luogo, le narrazioni familiari e i drammi domestici che prima occupavano un intero cluster isolato tendono ora a integrarsi direttamente all'interno dei racconti di formazione o di viaggio, come evidente nel terzo topic, dove la figura del padre e il tema della scuola co-occorrono insieme ai concetti di viaggio e ripartenza. Questa riconfigurazione della struttura concettuale indica come l'algoritmo LDA riesca a intercettare con precisione la tendenza del cinema contemporaneo a ibridare i generi tradizionali, mostrando uno spostamento generale verso trame in cui l'elemento del passato, della memoria e della ricerca della verità agisce da vero e proprio motore trasversale in quasi tutti i macro-temi rilevati.


Dopo aver identificato i topic, ciò che può risultare, adesso, interessante è verificare quanti film siano presenti nel catalogo dei tre periodi per ciascun topic.

Table 29: Numero di film per topic dominante, 2010-2015

topic_dominante	n_film	popularity_media	vote_average_medio
1	431	14.37	6.17
2	469	14.41	6.02
3	474	17.52	5.99
4	451	16.84	5.83
5	408	17.02	6.03

Numero di film per topic dominante

Periodo 2010–2015



Nel periodo 2010-2015, l'analisi dei topic dominanti rivela interessanti pattern nella produzione e nel gradimento dei film. I cinque topic individuati dall'LDA si distribuiscono in termini di numero di film, popolarità e voto medio, permettendo di comprendere non solo quali temi sono più trattati, ma anche come questi siano percepiti dal pubblico.

Il topic 3 emerge come quello con il maggior numero di film (474), indicando che i temi associati a questo cluster erano particolarmente frequenti nel periodo considerato. Segue da vicino il topic 2 (469 film), mentre il topic 5 contiene il minor numero di film (408), suggerendo che i temi corrispondenti fossero più di nicchia o specialistici. Nonostante questa differenza numerica, la popolarità media dei film non segue esattamente lo stesso ordine: i film del topic 3 e del topic 5 registrano i valori più alti di popolarità media (17.52 e 17.01 rispettivamente), mentre il topic 2, pur essendo uno dei più numerosi, ha una popolarità leggermente inferiore (14.41). Questo evidenzia come la quantità di film prodotti non corrisponda necessariamente a un maggiore interesse del pubblico o a una maggiore visibilità.

Per quanto riguarda il voto medio, il topic 1, pur con un numero di film inferiore rispetto ai topic 2 e 3, ottiene il valore più alto (6.17), mostrando che i contenuti di questo cluster risultano qualitativamente apprezzati dal pubblico. Al contrario, il topic 4 presenta sia un numero intermedio di film (451) sia il voto medio più basso (5.83), segnalando una percezione meno favorevole dei temi trattati, anche se la quantità di produzione è comunque rilevante.


In generale, l'analisi evidenzia una discrepanza tra quantità di film, popolarità e gradimento: non sempre i topic più trattati risultano i più apprezzati, e viceversa. Questo pattern suggerisce che alcuni argomenti, pur essendo meno frequenti, possono avere un impatto qualitativo maggiore sul pubblico, mentre altri temi, pur abbondantemente trattati, potrebbero non catturare la stessa attenzione o ricevere un giudizio più modesto. La combinazione di queste informazioni offre uno spunto prezioso per comprendere le dinamiche del mercato cinematografico statunitense di questo periodo, evidenziando quali temi erano più prolifici, quali più popolari e quali maggiormente apprezzati dal punto di vista qualitativo.

Table 30: Numero di film per topic dominante, 2016-2020

topic_dominante	n_film	popularity_media	vote_average_medio
1	297	16.52	6.22
2	350	15.79	6.41
3	353	20.82	6.22
4	323	19.35	6.36
5	327	15.83	6.20

Numero di film per topic dominante

Periodo 2016–2020



Nel periodo 2016-2020, osservando la distribuzione dei film per topic dominante, emerge una situazione abbastanza equilibrata: tutti e cinque i topic contano un numero simile di film, con valori che oscillano tra 297 e 353. Questo suggerisce che la produzione cinematografica di questo periodo non è concentrata su un singolo tema dominante, ma piuttosto si distribuisce in maniera relativamente uniforme tra i diversi argomenti individuati dall’LDA.

Se si considera la popolarità media dei film all’interno dei topic, si nota come alcuni topic più numerosi non corrispondano necessariamente a quelli più apprezzati dal pubblico: ad esempio, il topic 3, con 353 film, registra una popolarità media di 20.82, più alta rispetto agli altri topic, indicando che nonostante la produzione sia ampia, i film associati a questo topic attirano maggiore interesse. Al contrario, topic con numero di film simile possono avere popolarità media più bassa (topic 5 con 327 film e popolarità 15.83), segnalando che la quantità di contenuti non implica automaticamente un engagement superiore.


Per quanto riguarda il voto medio, i valori si mantengono piuttosto stabili tra 6.20 e 6.41, confermando come la percezione critica degli utenti non differisca drasticamente tra i topic, nonostante le variazioni nella popolarità e nella numerosità dei film. In sintesi, questo grafico e i valori della tabella permettono di osservare sia la distribuzione quantitativa dei film per topic che l’interazione tra produzione e gradimento del pubblico, offrendo una chiara panoramica della struttura tematica del periodo 2016-2020.

Table 31: Numero di film per topic dominante, 2021-2025

topic_dominante	n_film	popularity_media	vote_average_medio
1	283	38.72	5.72
2	280	53.72	5.76
3	298	37.57	5.59
4	304	41.93	5.72
5	309	58.17	5.66

Numero di film per topic dominante

Periodo 2021–2025



Per il periodo 2021-2025 emerge un quadro interessante sull'andamento dei topic dominanti nei film analizzati. In termini di numero di film per topic, si nota una distribuzione piuttosto equilibrata: i topic 1 e 2 contano rispettivamente 283 e 280 film, mentre i topic 3, 4 e 5 sono leggermente più numerosi, con 298, 304 e 309 film. Questo indica che nessun topic è eccessivamente prevalente, ma c'è una leggera concentrazione verso i topic 4 e 5.

Quando si guarda alla popolarità media dei film, il pattern diventa più differenziato: i topic 2 e 5 raggiungono valori significativamente più alti (53.72 e 58.17), segnalando che i film dominanti in questi topic tendono ad avere un seguito maggiore o una rilevanza culturale più marcata rispetto agli altri topic. Questi ultimi mostrano valori di popolarità media compresi tra 37.57 e 41.93, quindi ancora rilevanti ma meno prominenti.




Infine, analizzando il voto medio dei film, i valori oscillano tra 5.59 e 5.76, indicando una relativa uniformità della valutazione critica tra i topic. Non emergono topic particolarmente criticati o lodati, il che suggerisce che la distribuzione dei topic non sia associata a differenze sostanziali nella qualità percepita dai votanti.

In sintesi, per il periodo 2021-2025, i topic dominanti presentano una distribuzione abbastanza equilibrata in termini numerici, con una maggiore popolarità media concentrata nei topic 2 e 5. I voti medi, invece, rimangono

stabili, suggerendo che i film siano generalmente ben accolti indipendentemente dal topic. Questo quadro permette di capire sia quali argomenti hanno catturato l'attenzione del pubblico sia come la distribuzione dei contenuti si è evoluta rispetto ai periodi precedenti.

L'analisi dei topic LDA consente di osservare due aspetti complementari dei film: la numerosità dei film per topic e la popolarità media dei film all'interno di ciascun topic. La prima misura indica quanti film rientrano in ciascun tema identificato, fornendo un'idea della produttività o della frequenza di ciascun argomento nel catalogo. La seconda misura, invece, permette di valutare l'interesse relativo del pubblico: anche un topic con pochi film può avere una popolarità media elevata, segnalando che quei contenuti, pur meno numerosi, sono particolarmente seguiti o apprezzati dagli utenti.

Si osservino i seguenti grafici, utili per rafforzare i concetti espressi in precedenza.



Il grafico mostra l'andamento della popolarità media dei film per topic dominante nei tre periodi considerati: 2010-2015, 2016-2020 e 2021-2025. La visualizzazione è molto chiara e consente di osservare sia le differenze tra i topic nello stesso periodo sia l'evoluzione temporale della popolarità media.

Per il periodo 2010-2015, la popolarità media dei film è piuttosto omogenea tra i topic, con valori compresi indicativamente tra 14 e 17. Questo indica che, nonostante le differenze tematiche dei film, i topic non presentano variazioni significative nella popolarità.

Nel periodo 2016-2020, si nota un leggero aumento della popolarità media per alcuni topic, in particolare per il topic 3 e il topic 4, che raggiungono valori intorno a 20. Ciò suggerisce che alcune tipologie di film hanno iniziato ad attirare un pubblico più ampio o hanno avuto una maggiore visibilità in questo periodo.


Infine, nel periodo 2021-2025, la scala della popolarità media cambia significativamente: i valori passano dai 30-60, indicando un aumento generale della popolarità media dei film rispetto ai periodi precedenti. In particolare, i topic 2 e 5 emergono come quelli con popolarità media più alta, suggerendo che i film appartenenti a questi topic hanno riscosso un maggiore interesse nel pubblico. Questo andamento può riflettere trend contemporanei di consumo, marketing mirato, o un cambiamento nella natura dei film prodotti in questi topic.

Analisi della similarità semantica tra film e la relazione con la popolarità

Dopo aver analizzato i topic principali emergenti dalle trame dei film e le parole più distintive per genere, un passo successivo consiste nell'esaminare le relazioni semantiche tra i film stessi.

Un aspetto molto curioso consiste, quindi, nell'unione della disciplina del text mining con la network science. In particolare, l'analisi adesso si concentrerà sulla costruzione di reti per centralità semantica e delle parole per genere nelle trame.

Top 30 film per centralità semantica Periodo 2010–2015




Il primo risultato evidente è che *Swallowed Souls: The Making of Evil Dead 2* presenta il valore più alto, superiore a 40. Questo significa che la sua descrizione risulta semanticamente vicina a un numero elevato di altri film. Un risultato di questo tipo può dipendere dalla presenza di termini molto ricorrenti e trasversali, legati ad esempio al cinema horror, alla produzione cinematografica, al dietro le quinte o a parole narrative comuni. In questo senso, il film agisce come un nodo molto connesso nella rete semantica.

Subito dopo troviamo *As Cool as I Am*, *Monster High: Fright On!*, *Scooby-Doo! and the Beach Beastie*, *Like Sunday, Like Rain*, *Cavemen* e *Blue Lagoon: The Awakening*. Questi titoli non appartengono necessariamente allo stesso genere, ma condividono una caratteristica comune: le loro trame sembrano contenere parole o strutture narrative abbastanza diffuse da metterli in relazione con molti altri film. Per esempio, i contenuti familiari, teen, sentimentali, horror leggero o adventure tendono spesso a usare lessico ricorrente come amicizia, scuola, mistero, relazione, avventura, famiglia, salvataggio o trasformazione personale.

È interessante notare la presenza ricorrente di film legati a franchise o prodotti per un pubblico giovane/familiare, come diversi titoli di *Scooby-Doo!*, *Tom and Jerry*, *The Smurfs*, *Monster High* e altri contenuti animati o teen. Questo suggerisce che, nel periodo 2010-2015, una parte importante della centralità semantica è legata a contenuti con formule narrative abbastanza riconoscibili e ripetute: mistero, avventura, amicizia, gruppo di protagonisti, situazioni familiari o scolastiche. Questi elementi creano molte connessioni semantiche tra film diversi.

Allo stesso tempo, compaiono anche titoli horror o thriller come *Zombie Night*, *Zombie Shark*, *Cabin Fever*, *Patient Zero*, *Black Rock* e *A Deadly Adoption*. La loro presenza indica che anche il linguaggio del genere horror/thriller produce forti connessioni semantiche, probabilmente perché molte trame condividono termini legati a pericolo, morte, sopravvivenza, minaccia o mistero. Questi film diventano quindi centrali non perché siano necessariamente i più rilevanti dal punto di vista commerciale, ma perché occupano una posizione intermedia tra molte descrizioni simili.

Nel complesso, il grafico mostra che la centralità semantica non coincide automaticamente con il prestigio o la popolarità del film. Essa misura piuttosto quanto un titolo sia “vicino” ad altri titoli dal punto di vista della trama. I film più centrali sono quindi quelli che utilizzano un linguaggio narrativo molto condiviso all’interno del catalogo e che, per questo, funzionano come punti di raccordo tra gruppi di contenuti simili.



Nel periodo 2016-2020 il film più centrale è *All We Had*, con un degree semantico nettamente superiore agli altri, intorno a 46. Questo indica che la sua trama contiene elementi lessicali e narrativi molto trasversali, in grado di collegarlo a numerosi altri film. Subito dopo compaiono *I Believe*, *Mercy* e *Home Again*, tutti con valori elevati. Questi titoli sembrano collocarsi in un’area narrativa legata a relazioni personali, famiglia, ritorno, difficoltà individuali o percorsi emotivi: temi molto frequenti nelle trame e quindi capaci di generare numerose connessioni semantiche.


Rispetto al periodo precedente, qui emerge una centralità più marcata di film dal tono drammatico, sentimentale o familiare. Titoli come *Run Sweetheart Run*, *The Family Fang*, *Little Women*, *Life in a Year*, *Forever My Girl*, *I Still Believe* e *Fatal Affair* suggeriscono che molte connessioni semantiche ruotino intorno a relazioni, crisi personali, legami familiari, amore, perdita o trasformazione individuale. Questo non significa che tutti questi film appartengano allo stesso genere ufficiale, ma che le loro trame condividono un vocabolario narrativo simile.

Accanto a questa area più relazionale compaiono anche film thriller, horror o d'azione, come *Fist Fight*, *Don't Breathe*, *Body Cam*, *No Escape Room*, *He's Out There*, *Malicious*, *Incarnate* e *Big Legend*. La loro presenza mostra che anche i contenuti basati su pericolo, paura, minaccia e sopravvivenza generano molte connessioni semantiche. Tuttavia, rispetto al primo gruppo, questi titoli sembrano occupare una posizione leggermente meno centrale, con degree intorno a 16-18 nella parte bassa della classifica.

Un aspetto importante è che la distribuzione appare abbastanza concentrata: dopo i primi titoli, molti film presentano valori di degree simili, spesso tra 16 e 19. Questo indica che, al di là di pochi nodi molto centrali, esiste un gruppo ampio di film con centralità comparabile. In termini di rete, non abbiamo solo un titolo dominante, ma una fascia di film che funzionano come punti di raccordo tra diverse aree narrative del catalogo.

In breve, il grafico mostra che nel periodo 2016-2020 la centralità semantica è fortemente associata a contenuti con temi narrativi ampi e ricorrenti: famiglia, relazioni, crisi personali, ritorno, paura, minaccia e sopravvivenza. Questi film risultano centrali perché le loro trame condividono parole e strutture con molti altri titoli. L'analisi consente quindi di individuare non i film più popolari in senso commerciale, ma quelli più rappresentativi del linguaggio narrativo comune del catalogo Netflix USA in questo quinquennio.

Top 30 film per centralità semantica Periodo 2021-2025



Il periodo 2021-2025 mostra una situazione diversa rispetto ai periodi precedenti. Il degree semantico massimo è più contenuto: il film più centrale, Narco Sub, raggiunge circa 20 collegamenti, mentre nel 2010-2015 e nel 2016-2020 i titoli più centrali arrivavano a valori più elevati. Questo suggerisce che, nell'ultimo quinquennio, la rete semantica appare meno concentrata intorno a pochi film fortemente connessi e più distribuita tra diversi titoli con livelli di centralità simili.

Il primo gruppo di film più centrali comprende Narco Sub, Mislead, Sugar Mama e Shut In. Questi titoli sembrano rimandare a trame legate a crimine, inganno, pericolo, tensione o relazioni problematiche. La loro posizione elevata indica che usano un vocabolario narrativo abbastanza ricorrente nel catalogo recente, condividendo parole e temi con molti altri film. In questo senso, non sono necessariamente i film più popolari o più valutati, ma quelli che occupano una posizione più connessa nello spazio semantico delle trame.

Subito dopo compaiono titoli come Sniper: Rogue Mission, Due Justice, Buried in Barstow, Tom Clancy's Without Remorse, Terrifier 3, Intrusion, Heist 88, Trigger Warning, The Gray Man, The Gateway, The Black Phone 2 e Ruthless. La presenza di questi film suggerisce un rafforzamento di aree narrative legate ad azione, thriller, vendetta, criminalità, minaccia e sopravvivenza. Molti titoli sembrano condividere un lessico basato su conflitto, pericolo, missione, violenza o mistero; per questo diventano semanticamente centrali nella rete.

Accanto alla componente thriller/action, il grafico mostra anche alcuni titoli di tono diverso, come It's


Christmas Again, Dashing Through the Snow, Merry Little Batman, The Guardians of the Galaxy Holiday Special, Mea Culpa, Island Escape e HELP. Questo indica che la centralità semantica non riguarda un solo genere, ma può emergere anche da contenuti stagionali, familiari, avventurosi o drammatici, purché le loro trame condividano elementi lessicali con altri film del catalogo.

Un aspetto rilevante è la presenza di molti valori uguali o molto vicini, soprattutto nella parte centrale e finale della classifica, dove diversi titoli hanno degree semantico intorno a 12-14. Questo suggerisce una rete meno gerarchica: dopo i primi film, molti titoli occupano una posizione simile in termini di connessioni semantiche. In altre parole, il catalogo recente sembra avere più film con centralità comparabile, senza un forte dominio di pochi nodi.

Si può concludere che il grafico evidenzia che nel periodo 2021-2025 la centralità semantica è fortemente associata a trame di tensione, azione, crimine e pericolo, ma con una distribuzione più equilibrata rispetto ai periodi precedenti. I film più centrali rappresentano quindi i punti di raccordo tra le aree narrative più ricorrenti del catalogo recente, mostrando quali contenuti condividono maggiormente il linguaggio tematico dominante delle trame Netflix USA nell'ultimo quinquennio.

Dopo queste premesse, si arriva al momento in cui è interessante unire definitivamente le discipline di network science e text mining, passando alla visualizzazione delle reti dei sottogruppi appena analizzati.

Reti semantiche dei top 30 film nei tre periodi



Nel grafico relativo alle reti semantiche dei top 30 film nei tre periodi analizzati, ogni nodo rappresenta un film, mentre gli archi indicano relazioni di similarità semantica tra le trame. La dimensione dei nodi è proporzionale al degree, cioè al numero di connessioni che ciascun film stabilisce con altri film all'interno della rete. Di conseguenza, i nodi più grandi non sono necessariamente i film più popolari, ma quelli semanticamente più collegati ad altri titoli.

Nel periodo 2010-2015, la rete appare frammentata in più piccoli gruppi. Si osservano alcuni nuclei tematici abbastanza riconoscibili, come il gruppo legato a Scooby-Doo!, in cui titoli come Scooby-Doo! Music of the Vampire, Scooby-Doo! and the Beach Beastie, Scooby-Doo! Moon Monster Madness e Scooby-Doo! Camp Scare risultano collegati tra loro. Questo indica una forte continuità lessicale e narrativa tra film appartenenti allo stesso franchise o allo stesso universo di contenuti. Un altro piccolo gruppo riguarda titoli horror o survival, come Zombie Night, Zombie Shark, Black Rock, Cabin Fever: Patient Zero e Blue Lagoon: The Awakening. La presenza di diversi componenti separati suggerisce che nel primo periodo la similarità semantica è concentrata in sottoinsiemi specifici, spesso legati a saghe, franchise o generi ben delimitati.

Nel periodo 2016-2020, la rete risulta visivamente più integrata. Rispetto al quinquennio precedente, si nota un nucleo centrale più evidente attorno a film come Mercy, Dog Days, Run Sweetheart Run, All We Had, The True Adventures of Wolfboy e Home Again. Questa struttura suggerisce che, in questo periodo, alcuni film funzionano da punti di raccordo tra diversi contenuti semanticamente vicini. Il lessico delle trame sembra quindi creare connessioni più distribuite, meno isolate rispetto al periodo precedente. Accanto al nucleo principale compaiono comunque piccoli gruppi separati, come quello legato a Let It Snow e The Christmas

Chronicles: Part Two, oppure coppie isolate come *The Sea of Trees* e *Fist Fight*. Nel complesso, il periodo 2016-2020 mostra una maggiore coesione semantica tra i top 30 film, con alcuni nodi capaci di connettere più aree narrative.

Nel periodo 2021-2025, la rete assume una forma ancora diversa. Sono presenti più catene e sottogruppi collegati, soprattutto intorno a titoli thriller, action e crime come *Narco Sub*, *Chief of Station*, *Sniper: Rogue Mission*, *Trigger Warning*, *Due Justice*, *Mea Culpa*, *Heist 88*, *The Channel*, *Self Reliance* e *Sympathy for the Devil*. Questi collegamenti suggeriscono che, nell'ultimo periodo, la centralità semantica sia fortemente associata a trame basate su missioni, pericolo, crimine, vendetta, sopravvivenza e tensione. Rispetto al 2016-2020, la rete appare meno concentrata intorno a un unico nucleo centrale e più organizzata in percorsi o catene narrative, dove diversi film condividono elementi tematici ma senza formare un blocco compatto unico.

Dal confronto tra i tre periodi emerge quindi un'evoluzione interessante. Nel 2010-2015 la rete è più frammentata e dominata da piccoli cluster riconoscibili, spesso legati a franchise o generi specifici. Nel 2016-2020 aumenta la coesione: alcuni film diventano ponti semantici tra più contenuti, rendendo la rete più connessa. Nel 2021-2025, invece, la rete mostra una struttura più distribuita, con catene di film legate soprattutto a temi di azione, crimine e suspense.

In sintesi, questa visualizzazione permette di passare dalla semplice lista dei film semanticamente centrali a una lettura relazionale del catalogo. Non osserviamo più solo quali film hanno più connessioni, ma anche come questi film si collegano tra loro. La rete mostra che la similarità semantica non è distribuita in modo casuale: tende a formare gruppi coerenti per franchise, tono narrativo, genere o struttura della trama. Questo conferma l'utilità della rete semantica come strumento per interpretare l'organizzazione interna del catalogo Netflix USA nei tre periodi.


Dopo aver analizzato le reti semantiche generali, è stata costruita una seconda tipologia di rete con l'obiettivo di osservare le relazioni tra i film appartenenti allo stesso genere. In queste reti i nodi non rappresentano parole o unità lessicali, ma direttamente i film. Il legame tra due film viene costruito sulla base della somiglianza lessicale tra le rispettive trame.

La procedura parte dalla selezione di un genere specifico. Nello specifico, sono stati selezionati i cinque generi per importanza, in base alla frequenza, del dataset: drama, comedy, thriller, action, horror. Per ogni periodo temporale vengono considerate le trame dei film appartenenti a quel genere e il testo viene trasformato in parole singole attraverso un processo di tokenizzazione. Successivamente vengono eliminate le stopwords, cioè parole grammaticali molto frequenti ma poco informative, insieme a termini troppo generici o non utili all'interpretazione narrativa.

Per evitare che la rete sia dominata da parole comuni, le parole delle trame vengono pesate tramite TF-IDF. Questo indice assegna maggiore importanza ai termini che caratterizzano specificamente un film e minore importanza ai termini ricorrenti in molti documenti. A partire da questi pesi viene poi calcolata la cosine similarity tra coppie di film: due film sono considerati vicini quando condividono parole rilevanti nelle rispettive trame.

Nel grafico, quindi, ogni nodo rappresenta un film del genere considerato, mentre ogni arco indica una somiglianza lessicale tra due film. Lo spessore dell'arco rappresenta l'intensità della cosine similarity: archi più spessi indicano trame più simili dal punto di vista lessicale. La dimensione dei nodi rappresenta invece il degree, cioè il numero di collegamenti che ciascun film ha con altri film della rete. Per migliorare la leggibilità, non vengono mostrate tutte le etichette, ma solo quelle dei film più rilevanti, cioè quelli con maggiore centralità nella rete.

Questa analisi consente di osservare se, all'interno di uno stesso genere, i film tendano a formare piccoli gruppi narrativi, cioè insiemi di film accomunati da parole, temi o strutture di trama simili. La stessa procedura può essere replicata per altri generi, come Comedy, Drama o Horror, così da confrontare la struttura narrativa interna dei diversi generi.



Il genere Drama presenta una struttura molto frammentata. Non emerge una grande componente centrale che raccolga la maggioranza dei film, ma una molteplicità di piccoli gruppi. Questo risultato è coerente con la natura ampia del genere drammatico: il drama può includere storie familiari, biografiche, sentimentali, storiche, sociali o psicologiche, quindi è normale che le trame non convergano tutte verso un unico nucleo narrativo.


Nel periodo 2010-2015 si osservano diversi piccoli cluster separati. Alcuni titoli etichettati, come Joy, Jolene, 10 Years, Men, Women & Children, As Cool as I Am, Jesse Stone: Lost in Paradise, Jesse Stone: No Remorse e Noah, mostrano una certa capacità di collegamento con altri film della rete. In particolare, la vicinanza tra alcuni titoli suggerisce sottogruppi narrativi specifici: ad esempio, film legati a percorsi personali, relazioni familiari o vicende individuali. La rete non appare però compatta: i film drammatici del periodo sembrano distribuiti in molte piccole componenti, segno di una forte varietà tematica.

Nel periodo 2016-2020 la frammentazione resta evidente. Alcuni film, come The Secrets We Keep, The Great War, First Man, The Dirt, Alex Strangelove, All We Had e The Family Fang, emergono come nodi più visibili. La presenza di titoli come The Great War e First Man segnala sottogruppi con un possibile lessico legato a eventi storici, biografie o esperienze individuali eccezionali. Altri titoli rimandano invece a dimensioni familiari, relazionali o identitarie. Anche in questo periodo, quindi, il genere Drama non si organizza intorno a un unico tema dominante, ma rimane articolato in nuclei narrativi distinti.


Nel periodo 2021-2025 la rete continua a mostrare una struttura dispersa, ma alcuni gruppi risultano più riconoscibili. Tra i titoli etichettati compaiono The Channel, It's Christmas Again, The In Between, Big George Foreman, Something from Tiffany's, Heart of Champions, Deep Water e Shrapnel. Questi film suggeriscono una combinazione di sottotemi differenti: storie sentimentali o familiari, drammi sportivi o biografici, tensioni psicologiche e narrazioni legate al conflitto. La presenza di nodi più grandi indica che alcuni film condividono parole caratterizzanti con più titoli, ma anche qui non si forma una componente unica dominante.

Nel confronto tra i tre periodi, il risultato principale è la persistente eterogeneità del genere Drama. A differenza di generi più codificati, il drama raccoglie trame molto diverse tra loro e ciò si riflette nella rete: molti piccoli gruppi, poche connessioni estese e assenza di un centro unico. Questo non significa che la rete sia poco informativa; al contrario, mostra che il genere drammatico funziona come una categoria ampia, dentro cui convivono sottogeneri e registri narrativi diversi.


Rete film-film – Comedy
2010-2015



Rete film-film – Comedy
2016-2020



Rete film-film – Comedy
2021-2025



1 ● 2 ● 3 ● 4 ● 5 Cosine similarity — 0.2 — Degree — 0.15 — 0.25 — 0.35 Degree ● 1 ● 2 ● 3

Nel complesso, la rete del genere Comedy appare fortemente frammentata. Non emerge una componente centrale unica, ma molti piccoli gruppi separati. Questo risultato è abbastanza coerente con la natura del genere comico, che può includere sottogeneri molto diversi tra loro: commedia familiare, commedia romantica, animazione, parodia, teen comedy, commedia natalizia, action comedy e contenuti per ragazzi. Di conseguenza, le trame non condividono necessariamente un vocabolario comune stabile, ma tendono a organizzarsi in nuclei narrativi specifici.


Nel periodo 2010-2015 emergono diversi piccoli gruppi. Alcuni titoli etichettati, come *Phineas and Ferb: Summer Belongs to You!*, *Heavy Metal Mater*, *Moon Mater*, *Mater Private Eye*, *How to Train Your Dragon 2*, *#1 Cheerleader Camp*, *Scooby-Doo! and the Beach Beastie* e *Scooby-Doo! Moon Monster Madness*, indicano la presenza di sottogruppi legati soprattutto ad animazione, contenuti per ragazzi, avventura comica e franchise ricorrenti. La rete mostra quindi una comicità molto legata a prodotti seriali o familiari, con piccoli cluster costruiti intorno a personaggi e universi narrativi riconoscibili.

Nel periodo 2016-2020 la frammentazione resta evidente, ma compaiono alcuni nuclei più leggibili. Film come *The Lovers*, *Fist Fight*, *Dog Days*, *Home Again*, *Jumanji: Welcome to the Jungle* e diversi titoli legati a *Scooby-Doo!* suggeriscono una maggiore varietà interna. Alcuni gruppi sembrano riconducibili alla commedia relazionale o familiare, altri alla commedia scolastica, all'avventura comica o all'animazione. Anche qui non si osserva un unico centro del genere Comedy, ma una distribuzione in sottogruppi tematici.


Nel periodo 2021-2025 emergono invece alcuni gruppi riconoscibili legati alla commedia familiare, natalizia e animata. Titoli come *Vacation Friends*, *Best. Christmas. Ever!*, *A Brush with Christmas*, *Woody Woodpecker Goes to Camp*, *The Wonderful World of Mickey Mouse: Steamboat Silly* e *South Park the Streaming Wars Part 2* indicano la compresenza di sottogeneri diversi: commedie holiday, animazione, contenuti per famiglie e satira animata. La rete rimane dispersa, ma alcuni nodi più grandi indicano film che condividono lessico narrativo con più titoli, collocandosi come piccoli punti di raccordo all'interno del genere.

Dall'analisi dei tre periodi emerge che il genere Comedy mostra una struttura simile a quella del Drama, ma con nuclei tematici più riconoscibili intorno a franchise, animazione e commedie familiari. La frammentazione non va interpretata come un limite dell'analisi: indica piuttosto che la categoria Comedy è internamente molto ampia e contiene prodotti narrativi differenti. I film comici non si aggregano tutti intorno a un lessico comune, ma formano piccole componenti legate a contesti specifici, come scuola, famiglia, vacanze, Natale, avventura o personaggi seriali.


Rete film-film – Thriller
2010–2015



Rete film-film – Thriller
2016–2020



Rete film-film – Thriller
2021–2025




il genere Thriller presenta una struttura frammentata, ma rispetto a generi molto ampi come Drama e Comedy mostra alcuni nuclei tematici più riconoscibili. Questo è coerente con la natura del thriller, che tende a ruotare intorno a campi narrativi più ricorrenti: crimine, indagine, minaccia, fuga, rapimento, vendetta, sopravvivenza, violenza e operazioni segrete.

Nel periodo 2010-2015 la rete è composta da molti piccoli gruppi separati. Tra i film etichettati compaiono Texas Killing Fields, Wild Card, Criminal Activities, Seal Team Six: The Raid on Osama Bin Laden, A Deadly Adoption, Detention, The Gallows e The Final. Questi titoli suggeriscono sottogruppi diversi: da un lato thriller criminali e investigativi, dall'altro film legati a minacce, violenza e tensione psicologica. La rete non è compatta, ma mostra già una certa coerenza tematica intorno a situazioni di pericolo e conflitto.

Nel periodo 2016-2020 emergono alcuni cluster più leggibili. Titoli come Fatal Affair, I Am Wrath, Triple 9, Ava, Green Room, Den of Thieves e The Ottoman Lieutenant indicano aree narrative legate al crime, alla vendetta, all'azione violenta, alla fuga e alla minaccia. In particolare, i film con nodi più grandi sembrano funzionare come piccoli punti di raccordo tra trame lessicalmente simili. Anche in questo periodo la rete resta frammentata, ma il vocabolario del thriller appare più concentrato su nuclei ricorrenti rispetto a quanto osservato nella Comedy.

Nel periodo 2021-2025 la rete mostra alcuni gruppi ancora più evidenti, soprattutto nella parte centrale. Film come The Gray Man, Section 8, Sniper: G.R.I.T. - Global Response & Intelligence Team, Sniper: Rogue Mission, Buried in Barstow, Shut In, Nobody 2 e Sympathy for the Devil formano aree riconoscibili legate ad azione, intelligence, criminalità, fuga e sopravvivenza. Qui il thriller sembra sovrapporsi maggiormente all'action e al crime, con trame costruite intorno a missioni, minacce, inseguimenti e scontri.

Confrontando i tre periodi, il Thriller mantiene una struttura a piccoli cluster, ma nel periodo più recente alcuni nuclei appaiono più marcati. Questo può indicare una maggiore concentrazione del genere intorno a temi action-crime e survival thriller. La frammentazione resta comunque presente: il thriller non forma una rete unica, perché comprende sottotipi differenti, dal thriller psicologico al crime thriller, fino al thriller d'azione.



Il grafico mostra le reti film-film del genere Action nei tre periodi considerati: 2010-2015, 2016-2020 e 2021-2025. Nel complesso, le reti appaiono piuttosto frammentate: non si osserva un'unica grande componente centrale, ma diversi piccoli gruppi di film collegati tra loro. Questo suggerisce che, anche all'interno dello stesso genere, le trame dei film d'azione non sono omogenee, ma si organizzano in sottogruppi narrativi distinti.


Nel periodo 2010-2015 emergono diversi piccoli cluster. Alcuni film, come Green Lantern, One for the Money, 6 Bullets, Ben 10 Alien Swarm, Born to Race: Fast Track e Iron Man & Captain America: Heroes United, risultano etichettati perché occupano posizioni relativamente più importanti nella rete. La presenza di molti gruppi separati indica che il genere Action in questo periodo comprende prodotti narrativamente differenti: film di supereroi, azione criminale, avventura, corse e contenuti animati o televisivi. La rete mostra quindi una certa varietà interna, senza un unico tema dominante.

Nel periodo 2016-2020 la rete mantiene una struttura frammentata, ma alcuni gruppi appaiono leggermente più riconoscibili. Film come The Great War, The Outpost e The Wall risultano vicini nella parte centrale della rete, suggerendo una somiglianza lessicale legata a trame di guerra, missione o conflitto militare. Altri film etichettati, come Spider-Man: Far From Home, Game Over, Man!, Inside Man: Most Wanted e Justice League vs. Teen Titans, indicano invece la presenza di sottogruppi differenti, legati rispettivamente al supereroico, all'azione-comedy, al crime/action e all'animazione supereroistica. Anche in questo caso il genere Action non appare compatto, ma articolato in più nuclei tematici.

Nel periodo 2021-2025 si osservano alcuni gruppi più evidenti, soprattutto nella parte destra della rete. Film come The Channel, Narco Sub, The Gray Man, Section 8, Buried in Barstow e Island Escape sembrano collocarsi in aree relativamente connesse, suggerendo la presenza di trame accomunate da lessico legato a criminalità, missioni, fuga, operazioni e conflitto. Sono presenti anche riferimenti al filone supereroistico e animato, come Justice League: Crisis on Infinite Earths Part One e Justice League x RWBY: Super Heroes & Huntsmen, Part One. Rispetto ai periodi precedenti, la rete sembra contenere alcuni nuclei più visibili, ma rimane comunque composta da molte componenti separate.

Complessivamente, il genere Action mantiene una struttura narrativa molto eterogenea. Non emerge una rete unica e compatta, ma una successione di sottoreti che riflettono diverse declinazioni del genere: supereroi, guerra, criminalità, sopravvivenza, missioni e azione avventurosa. I film con nodi più grandi sono quelli con degree più elevato, cioè quelli che condividono elementi lessicali con un maggior numero di altri film. Questi

titoli possono essere interpretati come punti di raccordo tra trame simili, ma non necessariamente come film più popolari o qualitativamente migliori.



Rispetto a generi molto ampi come Drama e Comedy, la frammentazione dell'Horror appare più tematicamente coerente: i piccoli gruppi sembrano spesso riconducibili a nuclei narrativi tipici del genere, come contagio, creature mostruose, possessione, isolamento, case infestate, minaccia soprannaturale e sopravvivenza.

Nel periodo 2010-2015 emergono alcuni cluster riconoscibili. Titoli come *Zombie Shark*, *Black Rock* e *Cabin Fever: Patient Zero* sembrano collocarsi in un'area legata a contagio, isolamento e minaccia fisica. Un altro piccolo gruppo include *Sharktopus*, *Creature* e *Sharktopus vs. Pteracuda*, suggerendo un sottogenere più vicino al monster movie e all'horror creature-based. Sono presenti anche titoli come *The Final* e *The Body*, che richiamano invece forme di horror più psicologico o violento. La rete appare quindi dispersa, ma articolata in sottogruppi narrativi abbastanza leggibili.

Nel periodo 2016-2020 la rete continua a essere frammentata, ma alcuni nuclei si distinguono chiaramente. Titoli come *Annabelle: Creation*, *Finley*, *The Boy Behind the Door*, *Other Side of the Box* e *The Sandman* richiamano un lessico vicino al soprannaturale, alla minaccia domestica e alla paura legata a spazi chiusi o presenze inquietanti. Altri film, come *The Open House*, *He's Out There* e *The Super*, suggeriscono invece trame costruite intorno a isolamento, intrusione, pericolo domestico e suspense. In questo periodo l'Horror sembra quindi organizzarsi intorno a nuclei narrativi più riconoscibili rispetto al periodo precedente.

Nel periodo 2021-2025 compaiono alcuni gruppi associabili a horror contemporaneo, sequel e survival horror. Titoli come *Scream VI*, *HELP*, *Shut In*, *Birth/Rebirth*, *Separation*, *Totally Killer*, *Dead Sea* e *2/26/99* indicano una combinazione di filoni diversi: slasher, horror psicologico, body horror, isolamento e minaccia soprannaturale o traumatica. Anche qui non emerge una grande componente centrale, ma la rete mostra vari piccoli gruppi che riflettono sottogeneri specifici.

In conclusione, l'Horror mantiene una struttura discontinua ma semanticamente coerente. La frammentazione non indica assenza di struttura, ma la presenza di molti sottogeneri interni: zombie e contagio, creature horror, soprannaturale, home invasion, slasher, isolamento e trauma. Rispetto a Comedy e Drama, l'Horror sembra avere nuclei tematici più riconoscibili, anche quando la rete resta composta da componenti separate.

Dopo aver analizzato la struttura della rete semantica delle trame, l'analisi viene completata attraverso un modello di regressione lineare multipla. L'obiettivo è verificare se la posizione dei film nella rete semantica sia

associata alla loro popolarità. In questo modo, la network analysis non viene utilizzata soltanto in chiave descrittiva, ma anche come possibile fonte di variabili esplicative.

La variabile risposta del modello è la popolarità del film, trasformata in scala logaritmica tramite $\log_{1p}(\text{popularity})$. Questa trasformazione è stata adottata perché la popolarità presenta una distribuzione asimmetrica, con pochi film caratterizzati da valori molto elevati. L'uso della trasformazione logaritmica consente quindi di ridurre il peso degli estremi e di ottenere una relazione più stabile tra la risposta e i predittori.

A differenza di una stima separata per ciascun periodo, è stato costruito un unico modello sull'intero dataset. Il periodo temporale è stato inserito come variabile categoriale, distinguendo tra 2010-2015, 2016-2020 e 2021-2025. Questa scelta permette di confrontare direttamente i tre periodi all'interno della stessa struttura statistica, evitando interpretazioni separate e meno confrontabili.

Inoltre, il modello include interazioni tra il periodo e le principali misure di centralità. Questa specificazione consente di valutare non solo se le centralità semantiche siano associate alla popolarità, ma anche se tale associazione cambi nel tempo. In altri termini, il modello permette di verificare se una posizione più centrale nella rete semantica abbia lo stesso significato nei tre periodi oppure se il suo ruolo rispetto alla popolarità vari tra le diverse fasi temporali.

Il modello stima, quindi, la popolarità logaritmica dei film utilizzando, nello stesso modello, sia il periodo temporale sia alcune misure di centralità della rete semantica, controllando anche per `vote_average` e `vote_count`. La scelta di usare un unico modello con interazioni è metodologicamente più solida rispetto a tre regressioni separate, perché consente di verificare direttamente se l'associazione tra centralità semantica e popolarità cambi nei diversi periodi.

La categoria di riferimento è il periodo 2010-2015. Di conseguenza, l'intercetta pari a circa 1.781 rappresenta il valore atteso di `popularity_log` per il periodo 2010-2015 quando le altre variabili sono pari a zero. L'intercetta, in sé, non è la parte più interessante del modello; serve soprattutto come base tecnica rispetto alla quale vengono stimati gli altri coefficienti.

I coefficienti dei periodi sono entrambi positivi e statisticamente significativi. Il periodo 2016-2020 ha un coefficiente pari a circa 0.163 con p-value pari a 0.004, mentre il periodo 2021-2025 ha un coefficiente molto più alto, pari a circa 0.725, con p-value inferiore a 0.001. Questo significa che, a parità delle altre variabili incluse nel modello, i film dei periodi successivi tendono ad avere una popolarità logaritmica più elevata rispetto ai film del periodo 2010-2015. L'effetto è particolarmente marcato per il periodo 2021-2025.

Le variabili di controllo risultano molto rilevanti. `vote_average` ha un coefficiente positivo e altamente significativo, pari a circa 0.090, indicando che film con valutazioni medie più alte tendono ad avere anche una maggiore popolarità. Anche `vote_count` è positivo e altamente significativo: all'aumentare del numero di voti cresce la popolarità attesa. Questo risultato è coerente, perché i film più votati sono generalmente anche più visibili e quindi più popolari.

Le misure di centralità della rete semantica, considerate nel periodo di riferimento 2010-2015, mostrano invece un ruolo molto più debole. `degree`, `eigenvector` e `pagerank` non risultano statisticamente significativi. `betweenness` presenta un coefficiente negativo e un p-value pari a circa 0.051, quindi si colloca appena oltre la soglia convenzionale del 5%. Questo suggerisce una possibile associazione negativa, ma il risultato va interpretato con cautela: non è abbastanza forte da poter essere considerato pienamente significativo secondo il criterio classico.

Le interazioni tra periodo e centralità servono a capire se l'effetto delle misure di rete cambi nel tempo. In generale, quasi tutte le interazioni non risultano statisticamente significative. Questo significa che non emerge una prova forte del fatto che la relazione tra centralità semantica e popolarità sia diversa nei tre periodi. Alcune interazioni, come `periodo2021-2025:degree` e `periodo2021-2025:eigenvector`, hanno p-value intorno a 0.098 e 0.103, quindi sono debolmente suggestive, ma non sufficienti per affermare con sicurezza una differenza tra periodi.

Nel complesso, il modello indica che la popolarità è spiegata soprattutto da variabili più direttamente legate alla ricezione del film, cioè `vote_average` e `vote_count`, e dal periodo temporale. Le misure di centralità

semantica sembrano avere un contributo più limitato: non emergono effetti forti e stabili, né interazioni chiaramente significative con il periodo.

La qualità complessiva del modello è discreta. L'R-quadrato multiplo è pari a circa 0.456, mentre l'R-quadrato aggiustato è circa 0.454. Questo significa che il modello spiega circa il 45% della variabilità della popolarità logaritmica. È un valore abbastanza buono per un'analisi osservazionale su dati culturali e testuali, dove la popolarità dipende da molti fattori non osservati, come marketing, distribuzione, cast, franchise, budget e dinamiche di piattaforma.

Il test F globale è altamente significativo, con p-value inferiore a 0.001. Quindi il modello, nel suo insieme, ha capacità esplicativa superiore a un modello senza predittori. Tuttavia, l'interpretazione deve restare prudente: il modello non dimostra che la posizione semantica di un film nella rete causi maggiore o minore popolarità. Mostra piuttosto che, una volta controllati periodo, voto medio e numero di voti, le centralità reticolari aggiungono un contributo meno evidente rispetto alle variabili di ricezione del pubblico.

In sintesi:

Table 32: Sintesi interpretativa del modello di regressione sulla popularity logaritmica

Blocco del modello	Risultato	Interpretazione
Periodo	2016-2020 e 2021-2025 significativi	I film dei periodi più recenti mostrano valori attesi più alti di <code>popularity_log</code> rispetto al periodo 2010-2015.
Centralità semantiche	Effetti generalmente non significativi; <code>betweenness</code> marginale	La posizione nella rete semantica non mostra un effetto forte e stabile sulla popolarità.
Interazioni periodo $\times$ centralità	Generalmente non significative	Non emerge una prova robusta che il rapporto tra centralità semantica e popolarità cambi chiaramente nei tre periodi.
Variabili di controllo	<code>vote_average</code> e <code>vote_count</code> altamente significative	La popolarità è spiegata soprattutto da variabili legate alla valutazione e all'engagement del pubblico.
Qualità del modello	$R^2 = 0.456$; R^2 aggiustato = 0.454	Il modello spiega circa il 45% della variabilità della <code>popularity_logaritmica</code> .

Sentiment Analysis

Dopo aver analizzato la struttura lessicale, tematica e semantica delle trame, l'ultima parte dell'analisi si concentra sul tono emotivo dei contenuti testuali. Le analisi precedenti hanno permesso di individuare le parole più frequenti, i bigrammi ricorrenti, i termini distintivi per genere, i topic principali e le relazioni semantiche tra film. Tuttavia, queste tecniche descrivono soprattutto di cosa parlano i film e quanto siano simili tra loro, mentre non permettono di valutare direttamente il tipo di polarità emotiva associata al linguaggio utilizzato nelle trame.

Per questo motivo viene introdotta la sentiment analysis, con l'obiettivo di osservare se le descrizioni dei film presentino un orientamento prevalentemente positivo, negativo o neutro. In questo contesto, il sentiment non deve essere interpretato come giudizio qualitativo sul film, ma come misura del tono linguistico della trama: una descrizione può contenere termini negativi perché racconta conflitti, pericoli o eventi drammatici, senza che ciò implichi necessariamente una valutazione negativa del contenuto.

Questa analisi consente quindi di completare il percorso di text mining aggiungendo una dimensione interpretativa diversa: non solo quali parole ricorrono, quali temi emergono e quali film sono semanticamente vicini, ma anche quale tonalità emotiva caratterizza le trame nei diversi periodi e, se utile, nei diversi generi o topic.

Per la sentiment analysis è stato utilizzato il lessico Bing, un dizionario che classifica le parole in due categorie principali: positive e negative. Le parole contenute nelle trame sono state confrontate con questo lessico,

in modo da calcolare per ciascun film il numero di termini positivi e negativi presenti nella descrizione. Successivamente, è stato costruito un punteggio di sentiment dato dalla differenza tra parole positive e parole negative.

Questa misura consente di valutare l'orientamento emotivo del linguaggio utilizzato nelle trame. Un valore positivo indica una prevalenza di termini positivi, mentre un valore negativo segnala una maggiore presenza di termini negativi. È importante precisare che il sentiment non rappresenta un giudizio sulla qualità del film, ma descrive il tono lessicale della trama: una descrizione può risultare negativa perché contiene parole associate a conflitti, pericoli, morte o tensione narrativa.

Infine, Per tenere conto della diversa lunghezza delle trame, oltre al punteggio grezzo è stato calcolato anche un punteggio normalizzato, ottenuto dividendo la differenza tra parole positive e negative per il totale delle parole sentimentali individuate.

Table 33: Sintesi del sentiment delle trame, periodo 2010-2015

n_film	sentiment_medio	sentiment_medio_norm	positive_medio	negative_medio	popularity_media
2046	-1.239	-0.316	1.451	2.69	15.997

Nel periodo 2010-2015, la sentiment analysis delle trame evidenzia una prevalenza di termini negativi rispetto a quelli positivi.

In media, ogni trama contiene circa 1.45 parole positive e 2.69 parole negative, producendo un sentiment medio pari a -1.239. Anche il punteggio normalizzato, pari a -0.316, conferma un orientamento complessivamente negativo del linguaggio utilizzato nelle descrizioni. Questo risultato non deve essere interpretato come una valutazione negativa dei film, ma come indicazione del fatto che molte trame fanno riferimento a conflitti, pericoli, problemi, tensioni o eventi drammatici.

La popularity media dei film inclusi nell'analisi è pari a circa 16, valore che può essere utilizzato come riferimento descrittivo per eventuali confronti con gli altri periodi.

Table 34: Sintesi del sentiment delle trame, periodo 2016-2020

n_film	sentiment_medio	sentiment_medio_norm	positive_medio	negative_medio	popularity_media
1508	-1.278	-0.357	1.17	2.448	17.706

Nel periodo 2016-2020, la sentiment analysis delle trame conferma una prevalenza del lessico negativo rispetto a quello positivo. L'analisi è stata condotta su 1508 film, quindi su un numero inferiore rispetto al periodo 2010-2015, ma comunque sufficientemente ampio per descrivere l'orientamento complessivo delle trame.

In media, ogni trama contiene circa 1.17 parole positive e 2.45 parole negative. Di conseguenza, il sentiment medio è pari a -1.278, valore leggermente più negativo rispetto al periodo 2010-2015, dove era pari a -1.239. Anche il sentiment medio normalizzato, pari a -0.357, conferma questa tendenza: le parole negative non solo sono più numerose in valore assoluto, ma risultano prevalenti anche tenendo conto del totale delle parole sentimentali individuate.

La popularity media dei film inclusi nell'analisi è pari a 17.706, leggermente superiore rispetto al periodo precedente. Questo suggerisce che, pur in presenza di un tono medio più negativo, i film del periodo 2016-2020 mostrano una popolarità media più alta. Tuttavia, questo dato deve essere interpretato solo in modo descrittivo: non si può concludere che il sentiment negativo generi maggiore popolarità, bensì che in questo periodo contenuti con trame mediamente più orientate al negativo risultano comunque associati a una maggiore visibility media nel dataset.

Table 35: Sintesi del sentiment delle trame, periodo 2021-2025

n_film	sentiment_medio	sentiment_medio_norm	positive_medio	negative_medio	popularity_media
1375	-1.267	-0.334	1.212	2.479	46.532

Nel periodo 2021-2025, la sentiment analysis delle trame conferma ancora una volta una prevalenza di termini negativi rispetto a quelli positivi. L'analisi è stata condotta su 1375 film, quindi su un numero leggermente inferiore rispetto ai periodi precedenti, ma comunque sufficiente per osservare l'orientamento medio del linguaggio utilizzato nelle descrizioni.

In media, ogni trama contiene circa 1.21 parole positive e 2.48 parole negative. Il sentiment medio è pari a -1.267, valore molto simile a quello del periodo 2016-2020, che era -1.278. Anche il sentiment medio normalizzato, pari a -0.334, conferma una prevalenza del lessico negativo, ma leggermente meno marcata rispetto al periodo precedente, dove il valore normalizzato era -0.357.

Il dato più rilevante riguarda la popularity media, pari a 46.532, nettamente superiore rispetto ai periodi precedenti. Questo conferma quanto già emerso nelle analisi precedenti: nel periodo 2021-2025 i film presentano valori medi di popularity molto più elevati. Tuttavia, anche in questo caso non si può interpretare il sentiment negativo come causa della maggiore popolarità. Più correttamente, si può dire che nel periodo recente le trame mantengono un tono mediamente orientato al negativo, mentre la popularity media aumenta sensibilmente, probabilmente per effetto di altri fattori come maggiore visibilità dei titoli, franchise più riconoscibili, dinamiche di piattaforma o cambiamenti nella scala della variabile popularity.

Si passa ora all'analisi del sentiment per genere.




Table 36: Sintesi del sentiment medio per genere, periodo 2010-2015

Genere	N film	Sentiment medio	Sentiment medio normalizzato	Positive medio	Negative medio
Horror	360	-2.592	-0.661	0.858	3.450
Mystery	153	-2.307	-0.642	0.980	3.288
War	24	-2.167	-0.640	0.833	3.000
Western	22	-2.545	-0.599	1.000	3.545
Thriller	486	-2.317	-0.594	0.959	3.276
Crime	202	-2.149	-0.533	1.094	3.243
Action	418	-1.998	-0.454	1.294	3.292
Science Fiction	228	-1.846	-0.446	1.232	3.079
Adventure	224	-1.379	-0.346	1.487	2.866
Drama	780	-1.127	-0.310	1.483	2.610
History	29	-0.552	-0.252	1.862	2.414
TV Movie	165	-0.588	-0.242	1.582	2.170
Animation	196	-0.796	-0.217	1.791	2.587
Fantasy	181	-0.873	-0.217	1.790	2.663
Comedy	712	-0.697	-0.188	1.612	2.309
Family	251	-0.375	-0.134	2.004	2.378
Romance	303	-0.254	-0.049	1.950	2.205
Music	85	0.388	0.136	2.106	1.718
Documentary	137	0.423	0.187	2.263	1.839

Il grafico e la tabella descrivono il sentiment medio normalizzato per genere nel periodo 2010-2015. Il grafico consente di osservare visivamente l'ordinamento dei generi dal tono più negativo a quello più positivo, mentre la tabella permette di leggere i valori numerici esatti, includendo anche il numero di film analizzati e la media delle parole positive e negative individuate nelle trame.

Nel complesso emerge una chiara prevalenza del sentiment negativo nella maggior parte dei generi. Questo risultato è coerente con quanto osservato anche nell'analisi generale del sentiment delle trame: le descrizioni dei film tendono spesso a contenere parole associate a conflitti, pericoli, crisi, morte, paura, mistero o difficoltà. Tuttavia, è importante ribadire che questo non significa che i film siano valutati negativamente, ma solo che il linguaggio delle trame utilizza più termini classificati come negativi dal lessico Bing.

I generi con il sentiment più negativo sono Horror, Mystery, War, Western, Thriller e Crime. In particolare, l'Horror presenta un sentiment medio normalizzato pari a -0.661, con una media di 0.858 parole positive e 3.450 parole negative per film. Anche Mystery mostra un valore molto basso, pari a -0.642, seguito da War con -0.640, Western con -0.599, Thriller con -0.594 e Crime con -0.533. Questi risultati sono molto coerenti dal punto di vista narrativo: horror, thriller, crime e mystery sono generi costruiti intorno a paura, crimine, suspense, minaccia e tensione; war e western richiamano invece conflitti, violenza e sopravvivenza.

Anche Action e Science Fiction presentano valori negativi abbastanza marcati, rispettivamente -0.454 e -0.446. In questi casi, il lessico negativo può essere legato a combattimenti, missioni, catastrofi, pericoli o scenari distopici. Adventure e Drama sono ancora negativi, ma meno estremi: Adventure ha un sentiment normalizzato pari a -0.346, mentre Drama registra -0.310. Questo suggerisce che anche questi generi includono conflitti e difficoltà narrative, ma con un tono meno cupo rispetto a horror, crime o thriller.

I generi più vicini allo zero sono History, TV Movie, Animation, Fantasy, Comedy, Family e Romance. In particolare, Romance presenta un valore quasi neutro, pari a -0.049, con una media di 1.950 parole positive e 2.205 parole negative. Anche Family è relativamente vicino allo zero, con -0.134, e Comedy registra -0.188. Questi valori indicano una minore distanza tra parole positive e negative: le trame di questi generi possono contenere ostacoli o conflitti, ma il tono lessicale appare meno sbilanciato verso il negativo.

Gli unici due generi con sentiment medio normalizzato positivo sono Music e Documentary. Music presenta

un valore pari a 0.136, con 2.106 parole positive e 1.718 parole negative in media; Documentary registra il valore più positivo, pari a 0.187, con 2.263 parole positive e 1.839 parole negative. Questo suggerisce che, nel periodo 2010-2015, le trame o descrizioni dei documentari e dei film musicali usano più spesso termini associati a scoperta, successo, creatività, crescita personale, performance o racconto biografico.

La tabella aggiunge anche un'informazione importante sulla numerosità dei generi. Alcuni risultati, come quelli di Drama con 780 film, Comedy con 712 film, Thriller con 486 film e Action con 418 film, sono basati su gruppi molto numerosi e quindi più stabili. Altri generi, come War con 24 film, Western con 22 film e History con 29 film, devono essere interpretati con maggiore cautela, perché derivano da un numero più ridotto di titoli.

In sintesi, il grafico e la tabella mostrano che nel periodo 2010-2015 il sentiment delle trame varia in modo coerente con le caratteristiche narrative dei generi. I generi più cupi, conflittuali o legati alla suspense sono quelli con il sentiment più negativo, mentre i generi musicali e documentaristici risultano gli unici mediamente positivi.




Table 37: Sintesi del sentiment medio per genere, periodo 2010-2015

Genere	N film	Sentiment medio	Sentiment medio normalizzato	Positive medio	Negative medio
Western	25	-2.200	-0.627	1.040	3.240
Horror	319	-2.263	-0.595	0.846	3.110
Thriller	391	-2.115	-0.583	0.844	2.959
Mystery	131	-2.183	-0.569	0.863	3.046
Crime	175	-1.783	-0.535	0.897	2.680
Action	316	-1.877	-0.474	1.044	2.921
Science Fiction	179	-1.564	-0.420	1.022	2.587
Drama	557	-1.162	-0.343	1.138	2.300

Genere	N film	Sentiment medio	Sentiment medio normalizzato	Positive medio	Negative medio
History	52	-0.788	-0.339	0.981	1.769
War	23	-1.043	-0.331	1.000	2.043
Fantasy	131	-1.382	-0.313	1.420	2.802
Adventure	178	-1.028	-0.295	1.376	2.404
Comedy	462	-0.812	-0.256	1.281	2.093
Animation	121	-0.950	-0.196	1.628	2.579
TV Movie	102	-0.618	-0.181	1.539	2.157
Music	49	-0.673	-0.141	1.469	2.143
Romance	192	-0.422	-0.130	1.552	1.974
Family	148	-0.236	-0.056	1.662	1.899
Documentary	109	-0.101	-0.021	1.394	1.495

Nel periodo 2016-2020, vi è la conferma di una prevalenza generalizzata del sentiment negativo nelle trame, ma con alcune differenze rilevanti tra i generi. Rispetto al periodo 2010-2015, in questo caso nessun genere presenta un sentiment medio normalizzato positivo: anche i generi meno negativi, come Documentary, Family, Romance e Music, restano leggermente sotto lo zero. Questo indica che, nel quinquennio 2016-2020, il linguaggio delle trame è complessivamente più orientato verso termini negativi, anche nei generi solitamente associati a contenuti più leggeri o positivi.

I generi con sentiment più negativo sono Western, Horror, Thriller, Mystery, Crime e Action. In particolare, Western presenta il valore più basso, con un sentiment medio normalizzato pari a -0.627. Tuttavia, questo risultato va interpretato con cautela, perché il genere Western include solo 25 film: il valore può quindi essere influenzato da pochi titoli particolarmente cupi o violenti. Subito dopo troviamo Horror con -0.595, Thriller con -0.583, Mystery con -0.569 e Crime con -0.535. Questi risultati sono coerenti con la natura narrativa di questi generi, spesso centrati su paura, crimine, indagini, minacce, violenza e tensione.

Anche Action e Science Fiction mostrano un orientamento negativo piuttosto marcato, rispettivamente -0.474 e -0.420. Nel caso dell'Action, il risultato può essere collegato alla presenza di termini associati a combattimenti, missioni, pericoli o vendette. Per la Science Fiction, invece, il lessico negativo può derivare da trame legate a catastrofi, minacce esterne, scenari distopici, invasioni o sopravvivenza.

I generi intermedi, come Drama, History, War, Fantasy e Adventure, presentano valori negativi ma meno estremi. Drama, ad esempio, ha un sentiment medio normalizzato pari a -0.343, mentre Adventure registra -0.295. Questo indica che anche questi generi includono conflitti e difficoltà narrative, ma con una minore intensità negativa rispetto a horror, thriller o crime. Anche qui la numerosità va considerata: Drama è basato su 557 film, quindi il risultato è più stabile; War, invece, include solo 23 film, quindi il valore va letto con maggiore prudenza.

Nella parte alta del grafico, cioè tra i generi meno negativi, si trovano Documentary, Family, Romance, Music, TV Movie e Animation. Documentary è il genere più vicino alla neutralità, con un sentiment medio normalizzato pari a -0.021. Questo significa che, in media, le parole positive e negative nelle descrizioni documentaristiche sono quasi bilanciate. Anche Family presenta un valore poco negativo, pari a -0.056, mentre Romance si colloca a -0.130. Questi risultati sono coerenti con generi che tendono a includere più termini legati a relazioni, crescita, affetti, musica, famiglia o esperienze personali, anche se rimangono comunque presenti elementi di conflitto narrativo.

La tabella permette inoltre di osservare il rapporto tra parole positive e negative. Per esempio, nel genere Horror si registrano in media 0.846 parole positive e 3.110 parole negative per film, mentre nel genere Documentary i valori sono molto più vicini, con 1.394 parole positive e 1.495 parole negative. Questo aiuta a comprendere perché Documentary risulti quasi neutro, mentre Horror, Thriller o Mystery siano molto più sbilanciati verso il negativo.

In sintesi, nel periodo 2016-2020 il sentiment delle trame risulta complessivamente più negativo rispetto al periodo precedente, perché anche i generi più “leggeri” o informativi non raggiungono valori positivi. La

distribuzione resta comunque coerente con le caratteristiche narrative dei generi: horror, thriller, mystery, crime e action si collocano nella parte più negativa, mentre documentary, family, romance e music si avvicinano maggiormente alla neutralità. Questo conferma che il sentiment analysis riesce a catturare differenze interpretabili nel tono linguistico delle trame.




Table 38: Sintesi del sentiment medio per genere, periodo 2021-2025

Genere	N film	Sentiment medio	Sentiment medio normalizzato	Positive medio	Negative medio
Action	338	-1.675	-0.416	1.175	2.849
Adventure	140	-0.993	-0.229	1.386	2.379
Animation	139	-0.906	-0.257	1.388	2.295
Comedy	426	-0.862	-0.232	1.275	2.136
Crime	179	-2.050	-0.510	1.017	3.067
Documentary	105	0.276	0.117	1.686	1.410
Drama	411	-1.066	-0.295	1.297	2.363
Family	143	-0.434	-0.093	1.664	2.098
Fantasy	126	-1.079	-0.291	1.310	2.389
History	41	-0.220	-0.082	1.659	1.878
Horror	305	-2.302	-0.636	0.764	3.066
Music	61	0.787	0.268	2.180	1.393
Mystery	150	-2.313	-0.630	0.853	3.167
Romance	141	-0.631	-0.125	1.376	2.007
Science Fiction	174	-1.351	-0.372	1.063	2.414
TV Movie	35	-0.600	-0.222	1.200	1.800
Thriller	397	-1.982	-0.537	0.960	2.942

Genere	N film	Sentiment medio	Sentiment medio normalizzato	Positive medio	Negative medio
War	19	-1.211	-0.326	0.947	2.158
Western	21	-2.190	-0.524	0.905	3.095

Nel periodo 2021-2025 si ha una struttura del sentiment molto simile a quella osservata nei periodi precedenti: la maggior parte dei generi presenta un sentiment medio normalizzato negativo, mentre solo pochi generi si collocano sopra lo zero. Anche in questo caso, il sentiment non va interpretato come giudizio sulla qualità dei film, ma come misura del tono lessicale delle trame.

I generi con sentiment più negativo sono Horror, Mystery, Thriller, Western e Crime. In particolare, Horror presenta un sentiment medio normalizzato pari a -0.636, Mystery -0.630, Thriller -0.537, Western -0.524 e Crime -0.510. Questi valori sono coerenti con la natura narrativa di questi generi, spesso costruiti intorno a paura, crimine, minacce, omicidi, tensione, segreti e pericolo. La tabella conferma questa interpretazione: Horror ha in media 0.764 parole positive e 3.066 parole negative per film, mentre Mystery presenta 0.853 parole positive e 3.167 parole negative.


Anche Action, Science Fiction, War, Drama e Fantasy mostrano un orientamento negativo. Action registra un valore pari a -0.416, Science Fiction -0.372, War -0.326, Drama -0.295 e Fantasy -0.291. In questi casi, il tono negativo può derivare da trame basate su conflitti, missioni, battaglie, scenari pericolosi, crisi personali o mondi immaginari caratterizzati da minacce e ostacoli. Per il genere War, il valore deve comunque essere interpretato con cautela, perché il numero di film è molto basso, pari a 19.

Nella fascia più vicina allo zero troviamo Comedy, Adventure, TV Movie, Romance, Family e History. Questi generi presentano un sentiment meno sbilanciato verso il negativo. Ad esempio, Family ha un sentiment medio normalizzato pari a -0.093, Romance -0.125 e History -0.082. Questo suggerisce che, pur essendo presenti elementi di conflitto narrativo, il linguaggio delle trame è più bilanciato tra parole positive e negative rispetto ai generi più cupi.

Gli unici generi con sentiment positivo sono Music e Documentary. Music registra il valore più alto, pari a 0.268, con 2.180 parole positive e 1.393 parole negative in media. Documentary mostra invece un valore pari a 0.117, con 1.686 parole positive e 1.410 parole negative. Questo risultato è coerente con il fatto che i contenuti musicali e documentaristici possono utilizzare un lessico più legato a creatività, performance, successo, racconto personale, scoperta o crescita.

Nel complesso, il periodo 2021-2025 conferma una distinzione piuttosto netta tra generi dal tono più cupo, come horror, mystery, thriller, crime e western, e generi dal tono più neutro o positivo, come music, documentary, family e romance. Rispetto al periodo 2016-2020, si osserva inoltre il ritorno di alcuni valori positivi, in particolare per Music e Documentary, mentre nel periodo precedente tutti i generi risultavano negativi. Questo suggerisce che, pur rimanendo dominante un linguaggio orientato al conflitto e alla tensione, nell'ultimo quinquennio alcuni generi recuperano una tonalità più positiva.

Dopo aver analizzato il sentiment per genere, si considera ora il sentiment medio dei topic individuati tramite LDA. Questa analisi consente di verificare se i diversi nuclei tematici emersi dalle trame siano associati a tonalità linguistiche differenti. In questo caso, il confronto non riguarda più i generi cinematografici ufficiali, ma i gruppi tematici ricavati automaticamente dal modello topic.




Nel periodo 2010-2015 tutti i topic hanno un sentiment medio normalizzato negativo. Questo significa che, in tutti e cinque i gruppi tematici, le parole classificate come negative dal lessico Bing prevalgono mediamente su quelle positive. Il risultato è coerente con quanto osservato anche nell'analisi generale delle trame: molte descrizioni cinematografiche fanno riferimento a conflitti, difficoltà, pericoli, morte, misteri o tensioni narrative.

Il topic 1 è quello meno negativo, con un valore vicino a -0.15. Questo suggerisce che i film appartenenti a questo topic presentano un maggiore equilibrio tra parole positive e negative. Considerando che in precedenza questo topic era stato associato a temi come vita quotidiana, relazioni personali, scuola, musica e amicizia, il risultato è coerente: si tratta di un'area tematica più relazionale e meno cupa rispetto agli altri topic.

I topic 2 e 3 mostrano valori negativi intermedi, circa tra -0.27 e -0.30. Questi topic sembrano quindi caratterizzati da una prevalenza moderata di lessico negativo, ma non estrema. Possono rappresentare contenuti in cui sono presenti difficoltà familiari, viaggi, conflitti o tensioni sociali, ma con un tono meno fortemente negativo rispetto ai topic più cupi.

I topic 4 e 5 sono invece quelli con sentiment più negativo. Il topic 4 si colloca intorno a -0.42, mentre il topic 5 raggiunge circa -0.45. Questo indica una maggiore concentrazione di parole negative nelle trame associate a questi topic. Il risultato è interpretabile alla luce dell'assegnazione tematica precedente: il topic 4 era legato ad avventura, missioni, prigionie, salvataggi e contenuti anche fantastici o pericolosi; il topic 5 era invece chiaramente associato a crimine e mistero, con parole come murder, death, mysterious e killer. È quindi naturale che questi topic presentino un orientamento lessicale più negativo.

Il grafico conferma che il sentiment dei topic non è uniforme: pur essendo tutti orientati al negativo, alcuni gruppi tematici risultano decisamente più cupi di altri. I topic più relazionali o legati alla vita quotidiana presentano un sentiment meno negativo, mentre quelli associati a crimine, mistero, pericolo e azione mostrano valori più bassi. Quest'analisi completa l'interpretazione dei topic LDA, perché non si limita a descrivere di cosa parlano i film, ma aggiunge anche un'informazione sul tono emotivo del linguaggio utilizzato nelle trame.



Anche nel quinquennio 2016-2020, come già osservato per il periodo 2010-2015, tutti i topic presentano valori negativi. Questo significa che, indipendentemente dal tema individuato dal modello LDA, nelle trame prevalgono mediamente parole classificate come negative rispetto a quelle positive.


Il topic 1 è quello meno negativo, con un valore vicino a -0.25. In base all'interpretazione precedente dei topic, questo gruppo era legato a contenuti come game, save, house, city, team e true. Si tratta quindi di un topic con elementi di azione, gruppo, ambientazioni urbane o sfide, ma il suo sentiment non è tra i più estremi. Questo suggerisce che, pur contenendo parole legate a difficoltà o missioni, il tono lessicale resta relativamente meno cupo rispetto agli altri topic.

Il topic 2 presenta un valore leggermente più negativo, intorno a -0.28. Questo topic era stato associato a storie di formazione, scuola, relazioni familiari e crescita personale, con parole come love, college, school, daughter, journey e mother. Il sentiment negativo moderato è coerente con trame che possono includere difficoltà personali, conflitti familiari o momenti di cambiamento, ma senza raggiungere i livelli più cupi dei topic più orientati al crimine o alla minaccia.

Il topic 3 è nettamente il più negativo, con un sentiment medio normalizzato vicino a -0.57. Questo risultato è molto coerente con la sua interpretazione tematica: il topic 3 era caratterizzato da parole come fight, gang, police, mystery, dark e forces. Si tratta quindi di un gruppo fortemente legato ad azione, crimine, conflitto, investigazione e tensione. La forte prevalenza di lessico negativo riflette la presenza di trame basate su pericolo, violenza, mistero o minaccia.

I topic 4 e 5 mostrano valori negativi intermedi, entrambi intorno a -0.33. Il topic 4 era stato associato a contenuti storici e bellici, con parole come history, battle, american, death, justice e war. Il sentiment negativo è quindi prevedibile, perché questi contenuti richiamano guerra, morte e conflitto. Il topic 5, invece, combinava elementi di mistero e dinamiche familiari, con parole come school, love, mysterious, father, son, mother, daughter e discovers. Anche qui il tono negativo può dipendere dalla compresenza di relazioni familiari e suspense narrativa.

Complessivamente, il grafico conferma che nel periodo 2016-2020 il sentiment dei topic è interamente orientato al negativo, ma con intensità diverse. I topic più legati a formazione, relazioni o contenuti urbani presentano valori meno estremi, mentre il topic associato ad azione, crimine e investigazione mostra il sentiment più negativo. Questa analisi rafforza l'interpretazione dei topic LDA, perché permette di associare non solo un contenuto tematico, ma anche una tonalità emotiva alle diverse aree narrative individuate nelle trame.



Anche in questo ultimo quinquennio tutti i topic presentano valori negativi, quindi in ciascun gruppo tematico individuato dall'LDA le parole negative prevalgono mediamente su quelle positive.

Il topic 2 è quello meno negativo, con un valore intorno a -0.21. In base all'interpretazione precedente, questo topic era associato a contenuti più sentimentali, musicali o legati a eventi speciali, con parole come love, music, christmas, special, interviews e history. Il fatto che sia il topic meno negativo è quindi coerente: pur contenendo ancora elementi problematici o conflittuali, il suo linguaggio appare più bilanciato rispetto agli altri topic.

I topic 3 e 4 si collocano in una fascia intermedia, con valori intorno a -0.34 e -0.35. Il topic 3 era stato collegato a storie di formazione, contesti scolastici, dinamiche familiari e tensioni personali, mentre il topic 4 era più vicino a crime e mystery, con parole come murder, killer, city, father e journey. Entrambi mostrano quindi una prevalenza di lessico negativo, ma non raggiungono i valori più estremi del grafico.

I topic 1 e 5 sono invece quelli con sentiment più negativo. Il topic 1 si colloca intorno a -0.38 ed era stato associato a mistero, thriller, agenti, team, passato e situazioni da risolvere. Il topic 5 ha un valore simile, poco sotto -0.37, ed era legato ad action/adventure, pericoli, scoperte, battaglie e salvataggi. In entrambi i casi il risultato è interpretabile: trame basate su minacce, missioni, conflitti e situazioni pericolose tendono naturalmente a contenere più parole negative.

Si può concludere che anche nel periodo 2021-2025 il sentiment dei topic resta orientato al negativo, ma con differenze di intensità. I topic più vicini a contenuti musicali, sentimentali o legati a eventi speciali risultano meno negativi, mentre quelli associati a thriller, azione, pericolo e conflitto mostrano un tono più

cupo. Questa analisi consente quindi di completare l'interpretazione dei topic LDA: oltre a sapere quali temi emergono, possiamo osservare anche quale orientamento emotivo caratterizza ciascun gruppo tematico.

Conclusioni

In conclusione, il lavoro ha permesso di analizzare il catalogo Netflix USA da due prospettive complementari: quella della network science e quella del text mining. La prima parte ha consentito di studiare la struttura relazionale del catalogo, osservando come film, attori, registi e generi si connettano tra loro nei diversi periodi. Attraverso le misure di centralità, gli indicatori globali, le community detection e le ego-network, è stato possibile individuare i nodi più rilevanti, i generi più centrali e le trasformazioni della rete nel tempo. L'analisi ha mostrato che il catalogo presenta una struttura fortemente connessa, ma non uniforme: alcuni generi e alcuni attori/registi assumono un ruolo più centrale perché collegano molte parti della rete, mentre altri occupano posizioni più periferiche o specializzate.

La parte di text mining ha invece permesso di approfondire il contenuto testuale dei film, concentrandosi su titoli e trame. L'analisi lessicale ha evidenziato le parole e i bigrammi più frequenti, mentre il TF-IDF ha permesso di individuare i termini più distintivi per genere, mostrando come ogni categoria cinematografica sia caratterizzata da un lessico specifico. Il topic modeling LDA ha consentito di identificare nuclei tematici ricorrenti nelle trame, mentre la cosine similarity e la rete semantica hanno permesso di osservare quali film risultano più simili tra loro e quali occupano una posizione centrale nello spazio semantico del catalogo. Infine, la sentiment analysis ha aggiunto una dimensione emotiva all'analisi, mostrando che molte trame utilizzano un linguaggio prevalentemente orientato al negativo, soprattutto nei generi e nei topic legati a crimine, mistero, guerra, horror, azione e tensione narrativa.

Nel complesso, le due discipline hanno prodotto risultati coerenti e integrabili. La network science ha mostrato come il catalogo è strutturato in termini di relazioni tra entità, mentre il text mining ha mostrato di cosa parlano i contenuti e con quale tono linguistico vengono descritti. L'integrazione tra le due prospettive permette quindi una lettura più completa del catalogo: non solo una collezione di film, ma un sistema relazionale e semantico in cui generi, persone, temi e descrizioni testuali contribuiscono insieme a definire l'identità dell'offerta Netflix USA nei diversi periodi.

Un risultato importante riguarda anche la relazione tra struttura semantica e popolarità. Le analisi hanno mostrato che la centralità semantica non coincide necessariamente con la popularity: un film può essere molto connesso ad altri dal punto di vista della trama senza essere necessariamente più popolare. La popolarità sembra invece dipendere maggiormente da variabili legate alla visibilità e all'interazione del pubblico, come il numero di voti e il voto medio, oltre che da fattori esterni non osservati direttamente nel dataset.

In sintesi, il lavoro conferma l'utilità di combinare network science e text mining per analizzare un catalogo audiovisivo complesso. La prima disciplina consente di ricostruire la struttura delle relazioni, la seconda permette di interpretare il contenuto linguistico e tematico. Insieme, offrono una rappresentazione più ricca e articolata dell'evoluzione del catalogo Netflix USA, evidenziando sia le dinamiche strutturali sia quelle narrative e semantiche che caratterizzano i film nei tre periodi analizzati.